

PHÂN LOẠI TỰ ĐỘNG GIAI ĐOẠN GIẤC NGỦ TỪ TÍN HIỆU ĐIỆN NÃO ĐỒ (EEG) SỬ DỤNG HỌC SÂU

Abstract

Phân loại tự động giai đoạn giấc ngủ (automatic sleep staging) từ tín hiệu điện não đồ (EEG) đơn kênh là bài toán quan trọng trong y tế số. Báo cáo này tái tạo và cải tiến ZleepAnlystNet, một pipeline sử dụng 15 mạng CNN riêng biệt kết hợp BiLSTM. Câu hỏi nghiên cứu trung tâm: *liệu có thể đơn giản hóa mạnh kiến trúc mà không hy sinh hiệu năng?* Nhóm đề xuất thay thế toàn bộ 15 CNN bằng một ResNet-1D duy nhất và BiLSTM bằng SleepTCN non-causal, đồng thời bổ sung pipeline tiền xử lý tín hiệu. Kết quả: pipeline cải tiến giảm từ 16 mô hình xuống 2, huấn luyện nhanh hơn 8,2 lần (12,35 giờ $\rightarrow$ 1,5 giờ), trong khi vẫn đạt Macro F1 cao nhất (78,53%) trên tất cả 10 cấu hình thử nghiệm với 10-fold subject-wise cross-validation trên Sleep-EDF-78. Đánh giá cross-dataset trên SHHS cho thấy mô hình đạt 73,89% zero-shot (cao hơn $\sim 10\%$ so với baseline), và 84,17% khi retraining. Ablation study xác nhận 10/15 CNN gốc chỉ đóng góp 12% thông tin, cung cấp cơ sở định lượng cho quyết định đơn giản hóa.

I. Giới thiệu

Giấc ngủ là trạng thái sinh lý đặc trưng bởi sự giảm hoạt động vận động và phản ứng với kích thích bên ngoài. Chất lượng giấc ngủ ảnh hưởng trực tiếp đến sức khỏe thể chất và tinh thần, bao gồm chức năng nhận thức, hệ miễn dịch, và nguy cơ mắc các bệnh tim mạch, hô hấp, và thần kinh. Rối loạn giấc ngủ và thiếu ngủ kéo dài có thể dẫn đến những nguy cơ nghiêm trọng như tai nạn giao thông và tai nạn lao động. Ước tính có khoảng 50–70 triệu người tại Hoa Kỳ đang gặp các vấn đề liên quan đến giấc ngủ, ảnh hưởng đến hơn 60% người trưởng thành. Tại phạm vi toàn cầu, Tổ chức Y tế Thế giới (WHO) ước tính rối loạn giấc ngủ ảnh hưởng đến khoảng 30–45% dân số trưởng thành [1].

Đa ký giấc ngủ (Polysomnography, viết tắt PSG) là tiêu chuẩn vàng trong chẩn đoán giấc ngủ, ghi nhận các tín hiệu điện bao gồm điện não đồ (EEG), điện cơ đồ (EMG), điện nhãn đồ (EOG), cùng các tín hiệu cơ học như luồng không khí, âm thanh, áp suất và tư thế cơ thể. Sleep stage scoring là quá trình gán nhãn cho từng epoch 30 giây của tín hiệu PSG theo tiêu chuẩn phân loại. Năm 1968, Rechtschaffen và Kales giới thiệu hệ thống phân loại R&K, sau đó được thay thế bởi tiêu chuẩn AASM (American Academy of Sleep Medicine) vào năm 2007 [2]. Theo tiêu chuẩn AASM, giấc ngủ được chia thành 5 stage: Wake (W), N1, N2, N3 (thuộc nhóm NREM), và REM.

Hiện nay, quy trình sleep staging chủ yếu được thực hiện thủ công bởi các kỹ thuật viên được đào tạo chuyên môn. Mỗi PSG recording qua đêm có thể chứa hàng trăm đến hàng nghìn epoch, đòi hỏi 2–4 giờ làm việc để phân loại. Quy trình này mang tính chủ quan: nhiều nghiên cứu cho thấy mức đồng thuận giữa các kỹ thuật viên chỉ dao động từ 61,1% đến 92,2% [3], trong đó N1 có mức đồng thuận thấp nhất (Cohen’s kappa chỉ đạt 0,24). Hạn chế này tạo ra nhu cầu cấp thiết cho các hệ thống phân loại tự động nhằm giảm khối lượng công việc, thời gian xử lý, và sai sót do con người gây ra.

1.1 Thách thức của bài toán

Bài toán automatic sleep staging từ tín hiệu EEG đơn kênh đặt ra những thách thức đặc thù:

- **High-dimensional time series:** Tín hiệu EEG có sampling rate 100Hz, mỗi epoch 30 giây chứa 3,000 data points. Mô hình cần có khả năng trích xuất các pattern ở nhiều frequency band khác nhau từ chuỗi tín hiệu dài này.
- **Class imbalance nghiêm trọng:** N1 thường chỉ chiếm khoảng 6% tổng số epoch, trong khi N2 chiếm tới 37%. Sự mất cân bằng này khiến mô hình dễ bỏ qua N1, dẫn đến hiệu suất phân loại thấp ở class này.
- **Temporal context dependency:** Các sleep stage tuân theo quy luật transition sinh lý. Các kỹ thuật viên khi phân loại không chỉ dựa vào đặc trưng EEG của epoch hiện tại mà còn xem xét các epoch lân cận. Do đó, mô hình cần có khả năng nắm bắt long-range temporal context.
- **Inter-subject variability:** Đặc trưng EEG khác biệt đáng kể giữa các subject do yếu tố tuổi tác, giới tính, tình trạng sức khỏe, và thậm chí thiết bị ghi tín hiệu. Điều này gây khó khăn cho khả năng generalization của mô hình.

- **Feature overlap giữa N1 với các stage lân cận:** N1 là giai đoạn chuyển tiếp nên tín hiệu EEG rất giống Wake (cùng dải alpha-theta) và REM (cùng biên độ thấp, mixed-frequency), khiến ngay cả chuyên gia cũng thường xuyên phân loại sai.

1.2 Mục tiêu nghiên cứu

Nghiên cứu này hướng đến bốn mục tiêu chính:

1. **Reproduce** phương pháp ZleepAnlystNet từ bài báo gốc [4], xác minh kết quả trên bộ dữ liệu Sleep-EDF-78 với giao thức subject-wise cross-validation.
2. **Đề xuất cải tiến** pipeline bằng cách: (a) thay thế 15 CNN bằng một ResNet-1D duy nhất cho feature extraction; (b) thay thế BiLSTM bằng Temporal Convolutional Network (TCN) cho sequence classification; (c) bổ sung preprocessing pipeline cho tín hiệu EEG.
3. **Đánh giá** hiệu quả của pipeline cải tiến trên 2 bộ dữ liệu: Sleep-EDF-78 (in-domain) và SHHS (cross-domain), thông qua nhiều kịch bản thực nghiệm.
4. **Phân tích** định lượng mức đóng góp thông tin của từng thành phần trong pipeline gốc (ablation study), từ đó cung cấp minh chứng cho các quyết định thiết kế kiến trúc.

1.3 Đóng góp chính

Các đóng góp chính của nghiên cứu được tóm tắt trong Bảng 1.

Table 1: Tổng hợp các đóng góp chính

#	Đóng góp	Chi tiết và tác động
1	Reproduce bài báo gốc	Tái tạo ZleepAnlystNet (15CNN + BiLSTM) với subject-wise 10-fold CV, đạt ACC=83,00%, MF1=76,67%
2	Cải tiến preprocessing	Bổ sung bandpass filter 0,5–30Hz, notch filter 50Hz, clip & scale. Giúp zero-shot SHHS tăng từ ~22% lên 73,89%
3	Feature extractor mới	1 ResNet-1D thay thế 15 CNN . Giảm 15× số mô hình, train 8,2× nhanh hơn
4	Sequence model mới	SleepTCN thay thế BiLSTM
5	Khắc phục xử lý nhãn rác	Sử dụng cơ chế <code>ignore_index</code> thay vì chuyển nhãn Movement/Unknown thành Wake
6	Đảm bảo tính khoa học	Subject-wise 10-fold CV nghiêm ngặt ở cả 2 giai đoạn, loại bỏ hoàn toàn data leakage
7	Đánh giá cross-dataset	Zero-shot SHHS: 73,89% (cao hơn ~10% so với baseline). Retraining: 84,17%

1.4 Bố cục báo cáo

Phần còn lại của báo cáo được tổ chức như sau. Phần 2 trình bày tổng quan nghiên cứu liên quan và xác định khoảng trống nghiên cứu. Phần 3 mô tả chi tiết các bộ dữ liệu được sử dụng. Phần 4 giới thiệu cơ sở lý thuyết của các kiến trúc deep learning được sử dụng. Phần 5 trình bày preprocessing pipeline. Phần 6 mô tả chi tiết kiến trúc mô hình gốc và các cải tiến đề xuất. Phần 7 trình bày kết quả thực nghiệm qua tất cả cấu hình và ablation study. Phần 8 thảo luận về các kết quả, hạn chế và hướng phát triển. Cuối cùng, Phần 9 tổng kết các đóng góp và bài học rút ra.

II. Tổng quan nghiên cứu liên quan

Các hệ thống phân loại tự động giai đoạn giấc ngủ có thể được chia thành hai hướng tiếp cận chính: phương pháp truyền thống (shallow learning) và phương pháp học sâu (deep learning) [5]. Trong phương pháp truyền thống, các đặc trưng được trích xuất thủ công dựa trên kiến thức chuyên gia về xử lý tín hiệu và tiêu chuẩn phân loại giấc ngủ. Các đặc trưng này thuộc miền thời gian, tần số, và thời gian–tần số, sau đó được đưa vào các bộ phân loại như SVM, Random Forest, hay kNN. Mặc dù đạt hiệu suất cao trong một số trường hợp, phương pháp truyền thống đòi hỏi kiến thức sâu về xử lý tín hiệu và phụ thuộc lớn vào chất lượng đặc trưng được chọn.

Ngược lại, các phương pháp học sâu có khả năng học đặc trưng trực tiếp từ tín hiệu thô mà không cần kiến thức tiên nghiệm. Nhiều kiến trúc đã được áp dụng cho bài toán này, bao gồm autoencoders, mạng neural tích chập (CNN), mạng neural hồi quy (RNN), và các kết hợp giữa chúng.

2.1 Các phương pháp dựa trên CNN

Supratak et al. [6] giới thiệu DeepSleepNet, một trong những mô hình tiên phong cho phân loại tự động giấc ngủ từ tín hiệu EEG đơn kênh thô. Mô hình sử dụng kiến trúc CNN hai nhánh (small và large filter) cho trích xuất đặc trưng, kết hợp với BiLSTM hai lớp cho phân loại chuỗi. DeepSleepNet áp dụng phương pháp huấn luyện hai bước: đầu tiên huấn luyện phần CNN, sau đó fine-tune toàn bộ mô hình bao gồm cả BiLSTM. Trên Sleep-EDF-13, mô hình đạt overall accuracy 82.0% và MF1 76.9%. Tuy nhiên, F1-score của N1 chỉ đạt 46.6%.

Eldele et al. [7] đề xuất AttnSleep, kết hợp cơ chế attention đa đầu (multi-head attention) với Temporal Convolutional Network. Mô hình tận dụng adaptive feature recalibration để tăng cường các đặc trưng quan trọng cho phân loại. Trên Sleep-EDF, AttnSleep đạt accuracy 84.4%, cho thấy tiềm năng của kiến trúc TCN trong bài toán phân loại chuỗi thời gian sinh học.

Phan et al. [8] giới thiệu SleepTransformer, áp dụng kiến trúc Transformer cho phân loại giấc ngủ với khả năng giải thích (interpretability) và ước lượng độ không chắc chắn (uncertainty quantification). Mô hình đạt accuracy 83.9% trên Sleep-EDF.

2.2 Paper gốc: ZleepAnlystNet

ZleepAnlystNet [4] là mô hình được nhóm chọn làm baseline để tái tạo và cải tiến. Mô hình được công bố năm 2024 trên tạp chí Scientific Reports (Nature Publishing Group), đề xuất một phương pháp huấn luyện mới gọi là *separating training* cùng kiến trúc pipeline hai giai đoạn.

Giai đoạn 1: Trích xuất đặc trưng. ZleepAnlystNet sử dụng 15 mạng CNN nhỏ (mỗi mạng $\sim 2,500$ tham số), được tổ chức thành 3 nhóm data manipulation:

- **C-models (Current, Set A):** 5 CNN nhận tín hiệu epoch hiện tại $x(t)$, mỗi CNN chuyên biệt cho một giai đoạn giấc ngủ (W, N1, N2, N3, REM) với hàm loss có trọng số riêng.
- **P-models (Previous, Set B):** 5 CNN nhận tín hiệu epoch trước $x(t-1)$, kết hợp với nhân của epoch hiện tại, nhằm trích xuất đặc trưng ngữ cảnh quá khứ.
- **N-models (Next, Set C):** 5 CNN nhận tín hiệu epoch sau $x(t+1)$, kết hợp với nhân epoch hiện tại, nhằm trích xuất đặc trưng ngữ cảnh tương lai.

Mỗi CNN cho ra vector softmax 5 chiều, tổng cộng tạo thành vector đặc trưng 75 chiều ($5 \times 5 \times 3 = 75$) cho mỗi epoch. Kiến trúc CNN gồm hai bộ lớp (CNN1 và CNN2), mỗi bộ chứa convolution layer, ReLU, batch normalization, và max-pooling, tiếp theo là hai fully connected layers (10 nodes và 5 nodes) và softmax output.

Thiết kế class-specific với weighted loss function nhằm giải quyết vấn đề mất cân bằng lớp. Trong đó, trọng số w_i của loss function cho class i trong mô hình Net_c được tính theo tỷ lệ nghịch với số lượng epoch của class đó, sao cho N1 (class thiểu số) được chú trọng ngang bằng các class khác.

Giai đoạn 2: Phân loại chuỗi. Chuỗi vector đặc trưng 75 chiều từ toàn bộ recording được đưa vào một mạng BiLSTM với 128 hidden units ($\sim 211,000$ tham số) để học quy luật chuyển tiếp giữa các giai đoạn giấc ngủ. Output là xác suất phân loại cho từng epoch.

Phương pháp huấn luyện *separating training*: Điểm mấu chốt của ZleepAnlystNet là 15 CNN và BiLSTM được huấn luyện **hoàn toàn riêng biệt**: CNN được train trước, sau đó trọng số được cố định (freeze) khi train BiLSTM. Phương pháp này khác với fine-tuning (huấn luyện hai bước có chỉnh lại CNN) và end-to-end training (huấn luyện đồng thời). Tác giả lập luận rằng separating training tránh được ảnh hưởng của thông tin chuỗi giấc ngủ lên quá trình trích xuất đặc trưng, giúp CNN tập trung học các đặc trưng biểu diễn của từng epoch. Thực nghiệm cho thấy separating training cho hiệu suất cao hơn 5% so với end-to-end training trên cùng kiến trúc.

Kết quả: Trên Sleep-EDF-13 (20-fold leave-one-subject-out CV), ZleepAnlystNet đạt ACC=87.02%, MF1=82.09%, $\kappa=0.8221$, với per-class F1: W 90.34%, N1 54.23%, N2 89.53%, N3 88.96%, REM 87.40%. Trên Sleep-EDF-78 (10-fold subject-wise CV), mô hình đạt ACC=84.09%, MF1=78.26%, $\kappa=0.779$. Tổng tham số huấn luyện là 248,500 (37,500 từ 15 CNN + 211,000 từ BiLSTM), ít hơn 10 lần so với các mô hình khác (1.3M–24.7M parameters).

2.3 Tổng hợp so sánh

Table 2: So sánh các phương pháp phân loại tự động giấc ngủ trên Sleep-EDF

Tác giả	Năm	Phương pháp	Feature	ACC	MF1	N1 F1
Supratak et al. [6]	2017	DeepSleepNet	CNN two-branch + BiLSTM	82.0%	76.9%	46.6%
Eldele et al. [7]	2021	AttnSleep	Attention + TCN	84.4%	—	—
Phan et al. [8]	2022	SleepTransformer	Transformer	83.9%	—	—
Phan et al. [9]	2023	L-SeqSleepNet	Hierarchical RNN	86.4%	—	—
Jirakittayakorn et al. [4]	2024	ZleepAnlystNet	15CNN + BiLSTM	84.09%	78.26%	48.31%

2.4 Khoảng trống nghiên cứu và động lực cải tiến

Từ phân tích trên, nhóm nhận thấy một số hạn chế trong ZleepAnlystNet mà có thể được cải thiện:

1. **Pipeline phức tạp với 15 CNN riêng biệt:** Mặc dù tổng tham số ít, việc huấn luyện 15 mô hình riêng biệt tạo ra quy trình phức tạp, khó maintain, debug và mở rộng sang bộ dữ liệu khác. Câu hỏi đặt ra: liệu một backbone duy nhất có đủ capacity để thay thế?
2. **Feature extractor có capacity hạn chế:** Mỗi CNN chỉ có $\sim 2,500$ tham số — capacity rất nhỏ để capture các pattern phức tạp trong tín hiệu EEG thô (3,000 samples/epoch). Các mô hình hiện đại sử dụng residual connections để train sâu hơn mà không bị vanishing gradient.
3. **Chưa áp dụng tiền xử lý tín hiệu:** Paper gốc sử dụng tín hiệu EEG thô không qua bất kỳ bước lọc nhiễu nào. Tín hiệu thô chứa nhiễu từ nguồn điện (50/60Hz powerline noise), nhiễu DC drift ($<0.5\text{Hz}$), và artifacts biên độ cao do cử động — có thể ảnh hưởng đến chất lượng đặc trưng.
4. **BiLSTM có hạn chế về tốc độ:** BiLSTM xử lý sequential nên không thể song song hóa, dẫn đến thời gian huấn luyện lâu. Temporal Convolutional Network (TCN) là kiến trúc thay thế có thể song song hóa hoàn toàn, với receptive field có thể kiểm soát chính xác qua dilation factor.

Dựa trên các nhận định trên, nhóm đề xuất thay thế pipeline 15 CNN + BiLSTM bằng pipeline ResNet-1D + SleepTCN, đồng thời bổ sung bước tiền xử lý tín hiệu. Chi tiết phương pháp được trình bày trong Phần 6.

III. Dữ liệu

3.1 Mô tả bộ dữ liệu

Nhóm sử dụng 2 bộ dữ liệu PSG công khai, đại diện cho hai bối cảnh thu thập khác nhau: nghiên cứu trên người khỏe mạnh (Sleep-EDF) và nghiên cứu trên bệnh nhân tim mạch (SHHS).

3.1.1 Sleep-EDF Expanded (Sleep Cassette)

Sleep-EDF Database Expanded [10] là bộ dữ liệu benchmark phổ biến nhất trong nghiên cứu automatic sleep staging, được lưu trữ tại PhysioNet. Dữ liệu thu thập từ năm 1987 đến 1991 trên 78 subject khỏe mạnh (Caucasian, tuổi 25–101), tổng cộng 153 recording (mỗi subject 1–2 đêm). Kênh EEG được sử dụng là Fpz-Cz với sampling rate 100 Hz, mỗi epoch kéo dài 30 giây tương ứng 3,000 samples. Label sleep stage được gán bởi kỹ thuật viên theo tiêu chuẩn R&K, sau đó chuyển đổi sang chuẩn AASM (gộp Stage 3 + Stage 4 thành N3). Ý nghĩa chính của bộ dữ liệu này là cho phép so sánh công bằng với hầu hết các phương pháp trong literature, vì đa số các nghiên cứu đều benchmark trên Sleep-EDF-78.

3.1.2 SHHS (Sleep Heart Health Study)

Sleep Heart Health Study [11] là nghiên cứu đa trung tâm do National Heart Lung & Blood Institute (NHLBI) tổ chức, thu thập từ 1995 đến 1998 với 6,441 subject mắc hội chứng ngưng thở khi ngủ. Nhóm sử dụng subset 200–400 recording. Kênh EEG là C4-A1 (khác montage với Sleep-EDF), sampling rate gốc 125 Hz, được resample về 100 Hz để đồng bộ kích thước epoch. SHHS đóng vai trò kiểm tra khả năng generalization của mô hình trên domain khác (bệnh lý thay vì người khỏe mạnh, thiết bị ghi khác, montage khác).

3.2 Biến mục tiêu: 5 sleep stage theo AASM

Theo tiêu chuẩn AASM [2], giấc ngủ được chia thành 5 stage, mỗi stage có đặc trưng EEG riêng biệt:

Table 3: 5 sleep stage và đặc trưng EEG theo tiêu chuẩn AASM

Stage	Ký hiệu	Mô tả	Đặc trưng EEG chính
Wake	W (0)	Thức	Alpha waves (8–13 Hz), eye blinks
N1	N1 (1)	Ngủ nông	Theta waves (4–7 Hz), vertex sharp waves
N2	N2 (2)	Ngủ trung bình	Sleep spindles (12–14 Hz), K-complexes
N3	N3 (3)	Ngủ sâu	Delta waves (0.5–2 Hz), biên độ $>75\mu V$
REM	REM (4)	Mắt chuyển động nhanh	Low-amplitude, mixed-frequency

Lưu ý: Theo hệ thống R&K cũ, N3 và N4 là 2 stage riêng biệt. Theo AASM (2007), cả hai được gộp thành N3 dựa trên tỷ lệ delta waves ($>20\%$ cho N3 cũ, $>50\%$ cho N4 cũ). Nhóm tuân theo chuẩn AASM.

3.3 Phân phối nhân và vấn đề class imbalance




Figure 1: Phân phối nhân trên Sleep-EDF-78. N2 chiếm ưu thế với khoảng 37%, trong khi N1 chỉ chiếm khoảng 6%.

Table 4: Phân phối nhãn trên Sleep-EDF-78 (ước lượng trung bình sau khi trim)

Stage	Số epoch	Tỷ lệ	Nhận xét
W (Wake)	~8,285	~17%	Bao gồm 30 phút trước/sau giấc ngủ
N1	~2,804	~6%	Minority class , F1 chỉ ~49%
N2	~17,799	~37%	Majority class
N3	~5,703	~12%	Phân phối trung bình
REM	~7,717	~16%	Phân phối trung bình
MOVE/UNK	~365	~0.8%	Loại bỏ trước khi train

Class imbalance giữa N1 (~6%) và N2 (~37%) - tỷ lệ khoảng 1:6 - là thách thức lớn nhất của bài toán. Một mô hình trivial chỉ predict N2 cho mọi epoch sẽ đạt ~37% accuracy nhưng hoàn toàn vô dụng trong lâm sàng. Đây là lý do Macro F1 (trung bình F1 không trọng số) được ưu tiên hơn Accuracy làm metric chính - buộc mô hình phải phân loại tốt **tất cả** các class bao gồm minority class N1.

3.4 Train/Test Split: Subject-wise Cross-Validation

Nhóm sử dụng giao thức **subject-wise 10-fold cross-validation**: 78 subject được shuffle và chia đều thành 10 nhóm (~7–8 subject/fold). Mỗi iteration, 9 nhóm (~70 subject) dùng train và 1 nhóm (~8 subject) dùng test. Từ train set, 15% recording được tách ra làm validation (tách ở mức recording, không epoch).

Phương pháp subject-wise CV được chọn thay vì random epoch split vì lý do chống data leakage: nếu chia ngẫu nhiên ở mức epoch, các epoch từ cùng một đêm ngủ sẽ xuất hiện ở cả train lẫn test. Vì EEG epoch trong một đêm có temporal autocorrelation rất cao (epoch thứ 100 tương tự epoch 99 và 101), mô hình chỉ cần “nhớ” pattern của đêm đó là đạt accuracy cao trên test set. Đây là dạng data leakage nghiêm trọng trong dữ liệu time series sinh học, khiến accuracy bị inflate giả tạo và mô hình không generalize được sang subject mới. Subject-wise CV đảm bảo không có overlap giữa train và test ở mức subject, mô hình buộc phải học các đặc trưng EEG *tổng quát* chứ không phải đặc trưng riêng của từng cá nhân.

3.5 Phân tích khám phá dữ liệu (EDA)




Figure 2: Ví dụ tín hiệu EEG 30 giây cho 5 sleep stage. Wake có biên độ thấp và tần số cao (alpha), N3 có biên độ rất cao và tần số thấp (delta).

Tín hiệu EEG phản ánh hoạt động điện não khác nhau ở mỗi sleep stage. **Wake** đặc trưng bởi biên độ thấp (~10–50 μ V) và tần số cao, với alpha waves (8–13Hz) chiếm ưu thế khi đối tượng nhắm mắt thư giãn. **N1** là giai đoạn chuyển tiếp với mixed theta-alpha frequency và vertex sharp waves. **N2** có biên độ trung bình, đặc trưng bởi sleep spindles (burst 12–14Hz kéo dài 0,5–1,5 giây) và K-complexes (sóng biphasic biên độ cao). **N3** có biên độ rất cao (>75 μ V) với delta waves (0,5–2Hz) chiếm >20% epoch. **REM** có dạng sóng giống N1 (biên độ thấp, mixed-frequency) nhưng kèm saw-tooth waves; sự khác biệt chính (rapid eye movement) chỉ thấy trên kênh EOG.

Vấn đề feature overlap giữa N1 và các stage lân cận: N1 là giai đoạn chuyển tiếp giữa thức và ngủ, đặc trưng EEG overlap nghiêm trọng với ba stage lân cận. Với Wake, cả hai cùng nằm trên dải transition alpha $\rightarrow$ theta — khi đối tượng nằm yên nhưng chưa hoàn toàn mất ý thức, EEG rất khó phân biệt với Wake tỉnh. Với REM, cả hai có biên độ thấp và mixed-frequency, sự khác biệt chính (rapid eye movement) chỉ có thể phát hiện trên kênh EOG chứ không phải EEG đơn kênh. Với N2, ranh giới chính thức được đánh dấu bởi sự xuất hiện của sleep spindle đầu tiên hoặc K-complex, nhưng transition này rất “mượt” và đôi khi spindle không rõ ràng. Rosenberg et al. [3] báo cáo inter-scorer agreement khi phân loại N1 chỉ đạt Cohen’s kappa 0,24 — thấp nhất trong tất cả các stage. Đây là bottleneck sinh lý mà bất kỳ mô hình tự động nào cũng phải đối mặt.

IV. Cơ sở lý thuyết

Trước khi trình bày kiến trúc cụ thể, phần này giới thiệu nền tảng lý thuyết của ba kiến trúc deep learning được sử dụng trong nghiên cứu: 1D-CNN, ResNet, và TCN. Mục tiêu là giúp người đọc hiểu *tại sao* các kiến trúc này phù hợp cho bài toán sleep staging từ tín hiệu EEG, chứ không chỉ *cách* chúng được cài đặt.

4.1 1D Convolutional Neural Network (1D-CNN)

CNN ban đầu được thiết kế cho xử lý ảnh 2D, nhưng nguyên lý cốt lõi của nó (học các local filter có thể phát hiện pattern lặp lại ở bất kỳ vị trí nào trong input) hoàn toàn áp dụng được cho dữ liệu 1D như time series. Trong 1D-CNN, mỗi kernel trượt dọc theo chiều thời gian của tín hiệu, tạo ra feature map thể hiện mức độ “khớp” giữa kernel và từng đoạn tín hiệu:

$$(x * w)(t) = \sum_{k=0}^{K-1} w(k) \cdot x(t+k) \quad (1)$$

trong đó x là input signal, w là kernel có kích thước K , và t là vị trí trượt.

Đối với tín hiệu EEG, mỗi kernel có thể học cách phát hiện một dạng sóng đặc trưng: kernel với $K = 50$ ở sampling rate 100Hz bao phủ 0.5 giây tín hiệu — vừa đủ để nhận diện một sleep spindle (12–14Hz, kéo dài 0.5–1.5 giây). Kernel nhỏ hơn ($K = 7$) sau khi tín hiệu đã được downsampled phát hiện các local pattern tinh vi hơn. Khi xếp chồng nhiều convolution layer, mạng xây dựng hệ thống hierarchical feature: layer đầu phát hiện sóng cơ bản, layer sau tổng hợp thành pattern phức tạp hơn (ví dụ: kết hợp spindle + K-complex để nhận diện N2).

Ưu điểm quan trọng nhất của CNN so với fully connected network là **weight sharing**: cùng một kernel được áp dụng ở mọi vị trí trong tín hiệu, nhờ đó mạng có thể phát hiện pattern bất kể nó xuất hiện ở giây thứ 5 hay giây thứ 25 của epoch. Điều này đặc biệt phù hợp với EEG vì các dạng sóng đặc trưng (spindles, K-complexes, delta waves) xuất hiện tại các vị trí ngẫu nhiên trong epoch.

4.2 Residual Network (ResNet)

Khi tăng depth của CNN, lý thuyết cho rằng mạng sẽ học được feature phong phú hơn. Tuy nhiên, thực tế cho thấy mạng quá sâu gặp hiện tượng *degradation problem*: accuracy bão hòa và sau đó giảm, không phải do overfitting mà do vanishing/exploding gradient qua nhiều layer.

He et al. [12] giải quyết vấn đề này bằng **residual connection** (skip connection). Thay vì buộc mỗi block học ánh xạ $\mathcal{H}(\mathbf{x})$ từ đầu, residual block cho phép mạng chỉ cần học phần *residual* $\mathcal{F}(\mathbf{x}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}$:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (2)$$

Nếu ánh xạ tối ưu gần với identity ($\mathcal{H}(\mathbf{x}) \approx \mathbf{x}$), thì mạng chỉ cần đẩy $\mathcal{F}(\mathbf{x})$ về 0 — dễ hơn nhiều so với học identity mapping từ đầu. Skip connection cũng tạo “đường cao tốc” cho gradient truyền ngược trực tiếp từ layer cuối về layer đầu mà không bị suy giảm, giải quyết triệt để vanishing gradient.

Trong bối cảnh EEG, ResNet 1D có ý nghĩa đặc biệt. Tín hiệu EEG 3,000 samples/epoch chứa các pattern ở nhiều time scale: delta waves ở thang giây (0.5–2Hz), spindles ở thang 0.5–1.5 giây (12–14Hz), và vertex sharp waves ở thang sub-giây. Một shallow network khó capture đồng thời tất cả các scale này. ResNet cho phép xây dựng mạng đủ deep để trích xuất hierarchical feature — từ dạng sóng cơ bản (shallow layers) đến tổ hợp phức tạp đặc trưng cho từng sleep stage (deep layers) — mà vẫn duy trì gradient ổn định. Ngoài ra, khi kích thước input và output của một block khác nhau (do stride > 1 hoặc số channel thay đổi), một phép chiếu tuyến tính W_s được áp dụng trên shortcut để đảm bảo phép cộng hợp lệ:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s \mathbf{x} \quad (3)$$

4.3 Temporal Convolutional Network (TCN)

Sau khi feature extraction cho từng epoch riêng lẻ, bước tiếp theo là mô hình hóa mối quan hệ *giữa* các epoch theo trình tự thời gian. Đây là bài toán sequence labeling, truyền thống được giải quyết bằng RNN, đặc biệt là LSTM và BiLSTM. Tuy nhiên, Bai et al. [13] chứng minh rằng kiến trúc thuần convolution (gọi là TCN) có thể đạt hiệu suất tương đương hoặc tốt hơn RNN trên nhiều sequence task, đồng thời khắc phục các hạn chế cố hữu của RNN.

TCN dựa trên hai thành phần chính:

(1) **Causal vs. Non-causal convolution:** Mạng TCN nguyên bản của Bai et al. sử dụng **causal convolution** — output tại thời điểm t chỉ phụ thuộc vào input tại t và các thời điểm trước đó, không “nhìn” vào tương lai. Thiết kế này phù hợp cho các bài toán real-time/online. Tuy nhiên, bài toán sleep staging trong nghiên cứu này là bài toán **offline**: dữ liệu PSG được ghi nhận toàn bộ qua đêm rồi mới phân tích, nghĩa là toàn bộ sequence đã có sẵn tại thời điểm phân loại. Do đó, nhóm tùy biến TCN thành mạng **non-causal (acausal)** bằng cách sử dụng **symmetric padding** — chèn zero đều vào cả hai phía trái/phải của chuỗi:

$$\text{pad} = \frac{(K-1) \times d}{2} \quad (4)$$

Với symmetric padding, kernel tích chập trượt ở giữa cửa sổ, “nhìn” được một nửa receptive field ở quá khứ và một nửa ở tương lai. Điều này cho phép SleepTCN nắm bắt context hai chiều *tương đương BiLSTM*: chiều thuận (quá khứ) và chiều nghịch (tương lai), mô phỏng chính xác cách chuyên gia “liếc” các epoch lân cận khi ra quyết định.

(2) **Dilated convolution:** Phép tích chập mở rộng giúp tăng receptive field theo cấp số nhân mà không tăng số tham số:

$$(F *_d x)(t) = \sum_{k=0}^{K-1} f(k) \cdot x(t - d \cdot k) \quad (5)$$

trong đó d là dilation factor. Khi d tăng theo lũy thừa 2 qua các block ($d = 1, 2, 4, 8, \dots$), receptive field tăng theo hàm mũ. Với mỗi block chứa n_{conv} lớp convolution cùng dilation, receptive field tổng là:

$$R = 1 + n_{\text{conv}}(K-1) \sum_{i=0}^{L-1} 2^i = 1 + n_{\text{conv}}(K-1)(2^L - 1) \quad (6)$$

với L là số block và K là kernel size.

Trong cài đặt SleepTCN ($K = 3$, $L = 6$ block, $n_{\text{conv}} = 2$ lớp conv/block):

$$R = 1 + 2 \times 2 \times (2^6 - 1) = 1 + 4 \times 63 = 253 \text{ epoch} \approx 126,5 \text{ phút} \quad (7)$$

Do sử dụng non-causal symmetric padding, receptive field trải đều sang hai phía: mô hình “nhìn” được khoảng **126 epoch trước** và **126 epoch sau** epoch hiện tại — bao phủ hơn một chu kỳ giấc ngủ hoàn chỉnh (90–110 phút) ở mỗi hướng.

4.4 Bidirectional Long Short-Term Memory (BiLSTM)

LSTM [14] là biến thể của RNN được thiết kế để giải quyết vanishing gradient khi xử lý chuỗi dài. Ý tưởng cốt lõi là bổ sung **cell state** $\mathbf{c}_t$ (có vai trò như “băng chuyền” thông tin chạy xuyên suốt chuỗi) cùng ba cổng điều khiển luồng thông tin:

- **Forget gate** $\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f)$: quyết định phần nào của cell state cũ cần “quên”.
- **Input gate** $\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i)$: quyết định thông tin mới nào cần ghi vào cell state.
- **Output gate** $\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o)$: quyết định phần nào của cell state được xuất ra hidden state $\mathbf{h}_t$.

Cell state được cập nhật theo:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (8)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (9)$$

trong đó σ là sigmoid, $\odot$ là element-wise product.

BiLSTM mở rộng LSTM bằng cách chạy **hai LSTM song song**: một theo chiều thuận (trái $\rightarrow$ phải) và một theo chiều nghịch (phải $\rightarrow$ trái). Output tại mỗi timestep là nối (concatenation) hidden state từ cả hai hướng:

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t \parallel \overleftarrow{\mathbf{h}}_t] \quad (10)$$

Trong bài toán sleep staging, BiLSTM có ý nghĩa đặc biệt vì kỹ thuật viên khi phân loại một epoch không chỉ nhìn các epoch trước (chiều thuận) mà còn “liếc” các epoch sau (chiều nghịch) để quyết định — ví dụ: biết rằng epoch sau là N2 giúp xác nhận epoch hiện tại là N1 chứ không phải Wake. Đây là lý do bài báo gốc ZleepAnlystNet chọn BiLSTM cho giai đoạn sequence classification.

Tuy nhiên, BiLSTM có hai nhược điểm cố hữu. Thứ nhất, tính toán **sequential**: hidden state $\mathbf{h}_t$ phụ thuộc vào $\mathbf{h}_{t-1}$, nên không thể song song hóa trên GPU — với recording dài hàng nghìn epoch, tốc độ huấn luyện bị ảnh hưởng đáng kể. Thứ hai, mặc dù cell state giúp giảm vanishing gradient so với vanilla RNN, thông tin từ các epoch xa vẫn bị suy giảm dần theo khoảng cách — receptive field *thực tế* của BiLSTM nhỏ hơn nhiều so với chiều dài lý thuyết. Hai nhược điểm này là động lực trực tiếp để nhóm đề xuất thay BiLSTM bằng TCN ở Phần 6.

So sánh Non-causal TCN và BiLSTM cho sleep staging: Mạng SleepTCN non-causal sở hữu khả năng nhìn context hai chiều tương đương BiLSTM, đồng thời có ba lợi thế thực tiễn. Thứ nhất, toàn bộ phép tính convolution

có thể thực hiện **song song** trên GPU, trong khi LSTM phải xử lý sequential từng timestep — dẫn đến tốc độ huấn luyện chênh lệch đáng kể trên chuỗi dài (mỗi recording có hàng trăm đến hàng nghìn epoch). Thứ hai, receptive field của TCN được xác định **tường minh** qua công thức toán học, cho phép kiểm soát chính xác phạm vi context mà mô hình sử dụng; trong khi BiLSTM lý thuyết có bộ nhớ vô hạn nhưng thực tế gradient suy giảm dần, khiến receptive field thực tế không xác định được. Thứ ba, residual connection trong mỗi TCN block giúp gradient ổn định qua nhiều layer, tránh vanishing/exploding gradient — vấn đề thường gặp ở LSTM khi chuỗi dài.

V. Tiềm xử lý dữ liệu

Paper gốc ZleepAnlystNet (được triển khai trên nền MATLAB) sử dụng tín hiệu EEG thô (μV) không qua bất kỳ bước lọc nhiễu hay chuẩn hóa biên độ nào. Khâu chuẩn bị dữ liệu của tác giả gốc chỉ bao gồm: cắt xén vùng thức (trim ± 30 phút quanh sleep period), gộp nhãn Stage 3+4 thành N3 theo chuẩn AASM, và xử lý nhãn Movement/Unknown. Tín hiệu thô chứa đầy đủ các nguồn nhiễu — DC drift (< 0.5 Hz) do trở kháng điện cực thay đổi, powerline noise 50/60Hz, và artifacts biên độ cao do cử động cơ thể — được đưa thẳng vào 15 CNN.

Nhóm tái tạo pipeline gốc trên Python bằng cách chuyển đổi file EDF sang định dạng NPZ (NumPy compressed array) để tương thích với PyTorch. Ở bước tái tạo baseline, file NPZ chỉ chứa tín hiệu thô giống hệt bài báo gốc, không có bất kỳ xử lý tín hiệu nào. Tuy nhiên, tín hiệu EEG thu được trong môi trường lâm sàng chứa nhiều nguồn nhiễu ảnh hưởng đến chất lượng phân loại. Nhóm đề xuất bổ sung preprocessing pipeline để loại bỏ các nguồn nhiễu này, giúp tín hiệu sạch hơn trước khi đưa vào mô hình.

5.1 So sánh với paper gốc

Table 5: So sánh preprocessing pipeline: Paper gốc vs. Pipeline cải tiến

Bước	Paper gốc	Pipeline cải tiến	Mục đích
Lọc dải tần	Không có	Bandpass 0.5–30Hz (Butterworth bậc 4)	Loại DC drift và nhiễu cao tần
Lọc nhiễu điện	Không có	Notch 50Hz (IIR, Q=30)	Loại powerline noise
Chuẩn hóa biên độ	Dùng raw signal (μV)	Clip $\pm 800\mu\text{V}$ rồi chia 100	Giảm extreme artifacts
Cắt vùng ngủ	30 phút trước/sau in-bed	30 phút trước/sau in-bed	Loại phần thức dài
Xử lý nhãn MOVE/UNK	Loại khi train CNN; đổi thành W khi train BiLSTM	Gán label -1 (giữ epoch tại chỗ)	Bảo toàn chuỗi, không ô nhiễm Wake
Gộp nhãn	Stage 3 + 4 $\rightarrow$ N3	Stage 3 + 4 $\rightarrow$ N3	Theo chuẩn AASM

5.2 Chi tiết preprocessing pipeline

5.2.1 Bước 1: Đọc tín hiệu và chọn kênh EEG

Tín hiệu PSG được lưu trữ dưới định dạng European Data Format (EDF), chứa nhiều kênh sinh lý. Nhóm sử dụng thư viện `pyedflib` để đọc và chọn kênh EEG Fpz-Cz (sampling rate 100Hz) - kênh được sử dụng rộng rãi nhất trong benchmark Sleep-EDF. Đối với SHHS (sampling rate gốc 125Hz), tín hiệu được resample về 100Hz để đồng bộ kích thước epoch.

5.2.2 Bước 2: Bandpass Filter 0.5–30 Hz

Butterworth filter bậc 4 dạng bandpass được thiết kế dưới dạng second-order sections (SOS) để đảm bảo ổn định số trị. Dải tần 0.5–30 Hz được chọn vì bao phủ toàn bộ các frequency band liên quan đến sleep staging: delta (0.5–4 Hz, đặc trưng N3), theta (4–8 Hz, đặc trưng N1), alpha (8–13 Hz, đặc trưng Wake), sigma/spindle (12–14 Hz, đặc trưng N2), và beta (14–30 Hz). Tần số dưới 0.5 Hz chủ yếu là DC drift và baseline wander, còn tần số trên 30 Hz chứa nhiều EMG artifacts và nhiễu môi trường.

Filter được áp dụng trên **toàn bộ tín hiệu liên tục** (không phải từng epoch riêng lẻ) bằng hàm `sosfiltfilt` (zero-phase filtering) để tránh edge artifacts và phase distortion tại biên epoch.

5.2.3 Bước 3: Notch Filter 50 Hz

Powerline interference ở tần số 50Hz (tại châu Âu và Việt Nam) được loại bỏ bằng IIR notch filter với quality factor Q=30. Giá trị Q=30 đảm bảo filter đủ hẹp để chỉ triệt tiêu thành phần 50Hz mà không ảnh hưởng đến các tần số lân cận quan trọng cho sleep staging (sigma band 12–14 Hz, beta band 14–30 Hz).

5.2.4 Bước 4: Chia epoch và gán nhãn

Tín hiệu liên tục sau khi lọc được chia thành các epoch 30 giây ($30 \times 100 = 3,000$ samples/epoch). Label sleep stage từ annotation file tương ứng được gán cho từng epoch. Theo chuẩn AASM, Stage 3 và Stage 4 (trong hệ thống R&K cũ) được gộp thành N3. Nhãn Movement time (M) và Unknown (“?”) được gán giá trị -1 (đánh dấu không hợp lệ) nhưng **giữ nguyên vị trí** trong chuỗi để bảo toàn tính liên tục thời gian cho mô hình sequence ở giai đoạn sau.

5.2.5 Bước 5: Clip và Scale

Sau khi chia epoch, biên độ tín hiệu được giới hạn trong khoảng $\pm 800\mu V$ (clipping) để loại bỏ extreme artifacts (do cử động mạnh, nháy mắt, hoặc lỗi điện cực). Sau đó, tín hiệu được chia cho hằng số 100 để đưa giá trị về khoảng $[-8, +8]$:

$$x_{\text{scaled}} = \frac{\text{clip}(x, -800, +800)}{100} \quad (11)$$

Nhóm chọn chia cho hằng số thay vì Z-score normalization (chuẩn hóa theo mean/std) vì Z-score làm mất thông tin tỷ lệ biên độ tuyệt đối giữa các stage. Trong sleep staging, biên độ tuyệt đối mang thông tin quan trọng: N3 có biên độ cao ($>75\mu V$) là đặc trưng phân biệt chính với N1 và N2 (biên độ thấp hơn). Chia cho hằng số giữ nguyên tỷ lệ này.

5.2.6 Bước 6: Sleep Period Trimming

Các recording thường chứa phần thức kéo dài ở đầu và cuối bản ghi (do đối tượng chưa ngủ hoặc đã thức dậy nhưng vẫn tiếp tục ghi). Nhóm chỉ giữ phần dữ liệu từ 30 phút (60 epoch) trước epoch ngủ đầu tiên (first non-Wake epoch) đến 30 phút sau epoch ngủ cuối cùng (last non-Wake epoch). Phương pháp trim này tuân theo đúng quy trình của paper gốc.

5.3 Tổng kết pipeline




Figure 3: Sơ đồ tổng quan preprocessing pipeline cải tiến. Tín hiệu được lọc, chia epoch, chuẩn hóa biên độ, và đánh dấu nhân không hợp lệ. Các bước 2, 3, 5, 7 là cải tiến so với paper gốc (paper gốc không có bước lọc nhiễu hay chuẩn hóa).




Figure 4: So sánh tín hiệu EEG trước và sau preprocessing. Bên trên: tín hiệu thô chứa nhiễu và DC drift. Bên dưới: tín hiệu sau khi lọc.

Table 6: Tổng kết preprocessing pipeline

Bước	Thao tác	Output
1	Đọc file EDF, chọn kênh Fpz-Cz (100 Hz)	Tín hiệu liên tục 1D
2	Bandpass filter 0.5–30Hz (Butterworth bậc 4, SOS, zero-phase)	Tín hiệu đã lọc dải
3	Notch filter 50Hz (IIR, Q=30)	Tín hiệu sạch powerline noise
4	Chia epoch (30s $\times$ 100Hz = 3,000 samples), gán nhãn	Ma trận epoch + labels
5	Clip $\pm 800 \mu V$, Scale $\div 100$	Dữ liệu chuẩn hóa $\in [-8, 8]$
6	Trim ± 30 phút quanh sleep period	Dữ liệu cắt gọn
7	Đánh dấu epoch MOVE / UNK (label = -1 , giữ nguyên vị trí)	File NPZ (x: epochs, y: labels)

VI. Phương pháp

Phần này trình bày chi tiết kiến trúc mô hình, bao gồm tái tạo pipeline gốc ZleepAnlystNet, phân tích định lượng các hạn chế của pipeline gốc, và các cải tiến đề xuất. Pipeline được chia thành hai giai đoạn: feature extraction từ tín hiệu EEG thô, và sequence classification dựa trên đặc trưng đã trích xuất.

6.1 Tái tạo mô hình gốc: ZleepAnlystNet

Hình 5 trình bày kiến trúc tổng quan của ZleepAnlystNet. Hình 6 minh họa cách tạo dữ liệu cho 3 nhóm CNN (Set A, B, C).




Figure 5: Kiến trúc tổng quan của ZleepAnlystNet. Cột trái: pipeline từ tín hiệu EEG thô qua 3 nhóm P/C/N-models, nối 75 features vào BiLSTM. Cột giữa: 5 CNN class-specific trong mỗi nhóm. Cột phải: kiến trúc chi tiết 1 CNN (2 lớp Conv, Flatten, Dense, Softmax). (Nguồn: Jirakittayakorn et al. [4])




Figure 6: Data manipulation sets trong ZleepAnlystNet. (A) Set A/B/C: cách tạo input cho nhóm C (current), P (previous), N (next). (B) Huấn luyện CNN: mỗi class được tách riêng. (C) Huấn luyện BiLSTM: toàn bộ sequence. (Nguồn: Jirakittayakorn et al. [4])

6.1.1 Giai đoạn 1: 15 SleepCNN cho feature extraction

Phần feature extraction của ZleepAnlystNet gồm 15 CNN nhỏ, được tổ chức thành 3 nhóm data manipulation, mỗi nhóm chứa 5 mô hình class-specific. Nhóm C xử lý epoch hiện tại $x(t)$, nhóm P xử lý epoch trước $x(t-1)$, và nhóm N xử lý epoch sau $x(t+1)$. Mỗi CNN nhận input là tín hiệu EEG đơn kênh kích thước $1 \times 3,000$ samples.

Kiến trúc mỗi CNN gồm hai tầng convolution: tầng thứ nhất sử dụng 10 filters với kernel size 55, tiếp theo là ReLU, BatchNorm, và MaxPool với stride 16; tầng thứ hai sử dụng 5 filters với kernel size 25 theo cùng cấu trúc. Output được flatten rồi đưa qua fully connected layer 10 nodes, ReLU, và lớp phân loại 5 nodes kèm softmax. Mỗi CNN tạo ra vector xác suất 5 chiều, tổng cộng 15 CNN tạo thành feature vector 75 chiều cho mỗi epoch. Mỗi CNN có khoảng 2.500 tham số, toàn bộ 15 CNN là khoảng 37.500 tham số.

Mỗi CNN được huấn luyện với weighted cross-entropy loss w_i riêng:

$$w_i = \begin{cases} 1 - p_c & \text{nếu } i = c \\ p_c / (K - 1) & \text{nếu } i \neq c \end{cases} \quad \text{trong đó } p_c = \frac{N_c}{N} \quad (12)$$

với N là tổng số epoch, N_c là số epoch thuộc class c , $K = 5$. Cách tính này tập trung vào class mục tiêu của từng CNN, giúp mỗi mạng học các đặc trưng tốt nhất cho class tương ứng.

6.1.2 Giai đoạn 2 — BiLSTM cho sequence classification

Chuỗi feature vector 75 chiều từ toàn bộ recording được đưa vào BiLSTM với 128 hidden units mỗi chiều, cho phép học context từ cả quá khứ và tương lai. BiLSTM nối tiếp bởi fully connected layer 5 nodes và softmax. Tổng tham số BiLSTM khoảng 211.000, toàn bộ pipeline khoảng 248.500 — ít hơn 10 lần so với các mô hình cùng thời [4].

CNN được huấn luyện với batch size 64, optimizer Adam (learning rate = 0,001), early stopping khi 10 lần liên tiếp không cải thiện trên validation set. BiLSTM được huấn luyện với batch size 4 sequences, Adam (learning rate = 0,01) và cùng chiến lược early stopping.

6.1.3 Xử lý nhân rác trong bài báo gốc

Bài báo gốc xử lý các epoch có nhãn Movement và Unknown bằng cách: loại bỏ khi huấn luyện CNN, nhưng **chuyển đổi thành nhãn Wake** khi huấn luyện BiLSTM để giữ tính liên tục của chuỗi thời gian. Cách làm này mặc dù bảo toàn cấu trúc sequence, nhưng vô tình buộc mô hình phải học rằng các đoạn tín hiệu nhiễu, gây, tuột điện cực là trạng thái thức - gây “ô nhiễm” phân phối đặc trưng của class Wake.

6.1.4 Kết quả tái tạo

Nhóm tái tạo pipeline với cùng giao thức subject-wise 10-fold cross-validation trên Sleep-EDF-78, sử dụng seed 123. Kết quả đạt ACC=83,00% và Macro F1=76,67%, chênh lệch $-1,09\%$ ACC và $-1,59\%$ MF1 so với bài báo gốc (seed 42). Chênh lệch khoảng 1% nằm trong phạm vi chấp nhận được khi reproduce nghiên cứu mà không có source code gốc.

6.2 Phân tích đặc trưng 15 CNN - Cơ sở cho cải tiến

Trước khi đề xuất thay thế 15 CNN, nhóm thực hiện phân tích định lượng (ablation study) mức đóng góp thông tin của 75 features được trích xuất bởi 15 CNN, nhằm xây dựng cơ sở khoa học cho quyết định thiết kế kiến trúc mới.

6.2.1 Phương pháp phân tích

Phân tích được thực hiện trên tập con 60.000 epoch lấy mẫu ngẫu nhiên, sử dụng **composite score trung bình** từ 3 phương pháp đánh giá độc lập: mutual information, Random Forest feature importance, và permutation importance. Mỗi phương pháp đánh giá mức đóng góp thông tin từ một góc độ khác nhau; lấy trung bình giúp giảm bias của từng phương pháp riêng lẻ.

6.2.2 Kết quả: sự mất cân đối giữa 3 nhóm features




Figure 7: Composite score trung bình của 3 nhóm features. Nhóm C (đặc trưng epoch hiện tại) chiếm khoảng 88% tổng thông tin.

Kết quả phân tích cho thấy sự mất cân đối nghiêm trọng. Nhóm C (epoch hiện tại) đạt composite score trung bình **0,5376**, cao hơn gấp khoảng 8,3 lần so với nhóm P (0,0645) và nhóm N (0,0624). Hay nói cách khác, 5 CNN của

nhóm C đóng góp khoảng 88% tổng thông tin, trong khi 10 CNN còn lại chiếm 67% tài nguyên tính toán nhưng chỉ đóng góp khoảng 12%.

Kết quả này hợp lý xét từ góc nhìn sinh lý học điện não. Các đặc trưng phân biệt sleep stage - sóng delta cho N3, sleep spindle và K-complex cho N2, alpha rhythm cho Wake - nằm ngay trong epoch hiện tại. Thông tin từ epoch lân cận chủ yếu phản ánh quy luật transition giữa các stage, thuộc về tầng sequence mà mô hình ở giai đoạn 2 có thể học hiệu quả hơn, thay vì ép 15 CNN ở giai đoạn 1 phải vừa trích xuất đặc trưng EEG vừa encode temporal context.

6.2.3 Dư thừa thông tin giữa các CNN

Phân tích ma trận tương quan 75×75 phát hiện **9 cặp features** có hệ số tương quan $|r| > 0,95$, nghĩa là các CNN dù được thiết kế class-specific lại đang trích xuất thông tin gần như giống hệt nhau. Ví dụ, feature “C.N2→W” và “C.N3→W” có $r = 0,9748$: cả hai CNN đều sử dụng xác suất dự đoán Wake làm đặc trưng phân biệt chính, dẫn đến trùng lặp. Ngoài ra, **19 features** (25,3%) nằm dưới ngưỡng đóng góp thấp - toàn bộ thuộc nhóm P và N.

6.2.4 Kết luận phân tích

Các kết quả trên cho thấy pipeline 15 CNN tồn tại sự dư thừa đáng kể: 10/15 CNN đóng góp hạn chế (chỉ 12% thông tin nhưng chiếm 67% tài nguyên), 9 cặp features có tương quan cực cao ($r > 0,95$), và 25% features gần như không đóng góp. Đây là cơ sở cho đề xuất thay thế 15 CNN bằng một feature extractor duy nhất ở mục tiếp theo.

6.3 Cải tiến đề xuất

Dựa trên phân tích ở Mục 6.2, nhóm đề xuất bốn cải tiến chính.

6.3.1 Cải tiến 1: Thay thế 15 CNN bằng ResNet-1D




Figure 8: Kiến trúc ResNet-1D cho feature extraction. Mỗi residual block chứa 2 lớp convolution và skip connection.

Nhóm thay toàn bộ 15 CNN bằng **một mạng ResNet-1D duy nhất** với khoảng 475.000 tham số, dựa trên kiến trúc residual network [12] chuyển đổi sang 1D cho xử lý time series. Lý thuyết nền tảng về residual connection và vanishing gradient được trình bày tại Phần 4.

Table 7: Kiến trúc chi tiết ResNet-1D

Layer	Cấu hình	Stride	Output
Input	Tín hiệu EEG đơn kênh		$(B, 1, 3000)$
<i>Stem block</i>			
Stem	Conv1d($1 \rightarrow 32$, $k=50$, $s=5$, $\text{pad}=25$) $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ MaxPool(3,2)	5	$(B, 32, 300)$
<i>Residual blocks</i>			
Stage 1	ResBlock($32 \rightarrow 64$, $k=7$) + Shortcut($32 \rightarrow 64$, $k=1$)	1	$(B, 64, 300)$
Stage 2	ResBlock($64 \rightarrow 128$, $k=7$) + Shortcut($64 \rightarrow 128$, $k=1$)	2	$(B, 128, 150)$
Stage 3	ResBlock($128 \rightarrow 128$, $k=7$)	2	$(B, 128, 75)$
<i>Head</i>			
GAP	AdaptiveAvgPool1d(1) $\rightarrow$ Dropout(0,5) $\rightarrow$ FC($128 \rightarrow 5$)		$(B, 5)$

Thiết kế các thành phần được giải thích từ góc nhìn xử lý tín hiệu EEG. Stem block sử dụng kernel size 50: ở tần số 100Hz, mỗi kernel bao phủ 0,5 giây tín hiệu - vừa đủ để nhận diện sleep spindle kéo dài 0,5 - 1,5 giây ở 12-14Hz, đặc trưng phân biệt quan trọng nhất của N2. Stride 5 giảm chiều dài tín hiệu từ 3.000 xuống 600 samples, giảm chi phí tính toán mà vẫn giữ đủ resolution. Kernel size 7 ở các residual block phù hợp cho phát hiện các pattern cục bộ trong EEG đã giảm chiều. Cuối cùng, Global Average Pooling (GAP) tạo feature vector 128 chiều liên tục - khác biệt bản chất so với 75 chiều rời rạc từ softmax output của 15 CNN gốc.

Mô hình được huấn luyện với optimizer AdamW (learning rate 10^{-3} , weight decay 10^{-4}), batch size 64, tối đa 40 epoch, early stopping với patience 8 theo Macro F1 trên validation set, và class weight balancing. Validation set được tách 15% recording từ train set ở mức recording để tránh data leakage. Sau huấn luyện, classification head được loại bỏ và output GAP 128 chiều được dùng làm feature cho giai đoạn 2; trọng số ResNet-1D được freeze.

6.3.2 Cải tiến 2: Thay thế BiLSTM bằng SleepTCN




Figure 9: Minh họa dilated convolution. Với kernel size $K = 3$, dilation tăng 2^i qua mỗi block, receptive field mở rộng nhanh chóng.

Nhóm thay BiLSTM bằng **Temporal Convolutional Network (TCN)** [13], tùy biến thành phiên bản **non-causal** phù hợp với bài toán offline sleep staging. SleepTCN gồm 6 block, mỗi block chứa 2 lớp dilated convolution với 128 hidden channels, kernel size $K = 3$, dilation factor tăng theo 2^i với $i = 0, 1, \dots, 5$. Receptive field tổng:

$$R = 1 + n_{\text{conv}}(K - 1)(2^L - 1) = 1 + 2 \times 2 \times 63 = 253 \text{ epoch} \quad (13)$$

Khác với TCN nguyên bản sử dụng causal padding (chỉ nhìn quá khứ), SleepTCN sử dụng **symmetric padding** $\text{pad} = (K - 1) \times d/2$ để kernel “nhìn” được cả quá khứ và tương lai, tương đương khả năng context hai chiều của

BiLSTM. Do padding đối xứng, receptive field 253 epoch trải đều hai phía: **126 epoch trước + 1 epoch hiện tại + 126 epoch sau** ($\approx 126,5$ phút), bao phủ hơn một chu kỳ giấc ngủ hoàn chỉnh (90–110 phút) ở mỗi hướng. Mỗi block chứa dilated convolution (non-causal), LayerNorm, GELU, dropout, và residual connection. Huấn luyện SleepTCN sử dụng AdamW (learning rate 5×10^{-4} , weight decay 10^{-3}), batch size 8 sequences, early stopping với patience 30 (validate mỗi 5 epoch), và cross-entropy loss không class weight. Lý do không dùng class weight ở giai đoạn 2: sequence model cần học quy luật transition tự nhiên giữa các stage; nếu tăng trọng số N1 sẽ tạo bias khiến mô hình predict N1 quá nhiều ở các vùng transition.

6.3.3 Cải tiến 3: Xử lý nhãn rác bằng ignore_index

Thay vì chuyển nhãn Movement/Unknown thành Wake như bài báo gốc, nhóm gán các epoch này label -100 và sử dụng tham số `ignore_index=-100` trong cross-entropy loss của PyTorch. Cách làm này mang lại hai lợi ích đồng thời. Thứ nhất, sequence **không bị đứt gãy**: các epoch rác vẫn nằm đúng vị trí trong chuỗi input, mô hình TCN vẫn “nhìn thấy” khoảng cách thời gian giữa các epoch hợp lệ, đảm bảo temporal context được bảo toàn. Thứ hai, class Wake **không bị ô nhiễm**: loss function tự động bỏ qua các epoch có label -100 , không tạo gradient cho những epoch này, nên mô hình không bị ép phải học rằng tín hiệu nhiễu là trạng thái thức.

So với cách xử lý trong bài báo gốc, phương pháp này tránh được vấn đề ô nhiễm nhãn Wake: giữ epoch rác ở vị trí cũ để bảo toàn context nhưng đánh dấu để mô hình không học từ nó.

6.3.4 Cải tiến 4: Thử nghiệm bổ sung với SleepConformer

Ngoài TCN, nhóm thử nghiệm **SleepConformer**, một kiến trúc kết hợp convolution và self-attention dựa trên Conformer [15]. SleepConformer được bổ sung hai kỹ thuật: Supervised Contrastive Loss (SCL) giúp tạo feature space có cấu trúc cluster rõ ràng, và Sequence Augmentation (ngẫu nhiên bỏ qua epoch khi huấn luyện) giúp tăng tính robust.

6.4 Tổng quan pipeline cải tiến

Pipeline cải tiến duy trì triết lý separating training hai giai đoạn. Giai đoạn 1: tín hiệu EDF thô đi qua preprocessing (bandpass filter 0.5–30Hz, notch filter 50Hz, clip $\pm 800\mu V$ & scale), sau đó đưa vào ResNet-1D (khoảng 475.000 tham số, supervised training) để tạo feature vector 128 chiều; trọng số ResNet được freeze. Giai đoạn 2: chuỗi feature 128 chiều theo thứ tự thời gian được đưa vào SleepTCN non-causal (6 block, dilation 2^i , symmetric padding) để predict sleep stage.

6.5 Cài đặt thực nghiệm

Toàn bộ thực nghiệm được thực hiện bằng Python 3.10 với PyTorch 2.x trên Google Colab (GPU NVIDIA T4/A100). Giao thức đánh giá là subject-wise 10-fold cross-validation trên Sleep-EDF-78, và 5-fold trên SHHS-200. Tất cả random operations được cố định với seed 123 và deterministic CUDA được bật để đảm bảo reproducibility.

6.6 Metrics đánh giá

Nhóm sử dụng bốn nhóm metrics phù hợp với thông lệ trong nghiên cứu sleep staging [4]. Tất cả các metrics được tính toán dựa trên các giá trị của Confusion Matrix đối với từng class c trong $K = 5$ class, bao gồm:

- TP_c (True Positive): số epoch thuộc class c được predict đúng là c .
- FP_c (False Positive): số epoch *không* thuộc class c nhưng bị predict nhầm là c .
- FN_c (False Negative): số epoch thuộc class c nhưng bị predict nhầm sang class khác.
- TN_c (True Negative): số epoch không thuộc class c và cũng không bị predict là c .

1. Overall Accuracy (ACC) đo tỷ lệ epoch được predict đúng trên tổng số epoch:

$$ACC = \frac{\sum_{c=1}^K TP_c}{N} \quad (14)$$

trong đó N là tổng số epoch.

2. Precision và Recall được tính riêng cho từng class c :

$$Precision_c = \frac{TP_c}{TP_c + FP_c}, \quad Recall_c = \frac{TP_c}{TP_c + FN_c} \quad (15)$$

Precision đo tỷ lệ dự đoán đúng trong các epoch được gán nhãn c ; Recall đo tỷ lệ epoch thực sự thuộc class c được mô hình phát hiện. Hai metrics này bổ sung cho nhau: Precision cao nhưng Recall thấp nghĩa là mô hình “chắc ăn” nhưng bỏ sót nhiều; ngược lại Recall cao nhưng Precision thấp nghĩa là mô hình “gom” nhiều nhưng nhầm nhiều.

3. Macro F1 (MF1) là trung bình cộng F1 score của từng class, phản ánh khả năng phân loại cân bằng giữa tất cả các class:

$$\text{MF1} = \frac{1}{K} \sum_{c=1}^K F1_c = \frac{1}{K} \sum_{c=1}^K \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}, \quad K = 5 \quad (16)$$

Macro F1 tính trung bình *không trọng số* — mỗi class đóng góp ngang nhau bất kể số lượng epoch, do đó class thiểu số N1 (~6%) ảnh hưởng đến Macro F1 nhiều như class đa số N2 (~37%).

4. Cohen’s Kappa (κ) đo mức đồng thuận giữa dự đoán của mô hình và nhãn thực tế, sau khi loại trừ xác suất đồng thuận do ngẫu nhiên:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (17)$$

trong đó p_o là tỷ lệ đồng thuận thực tế (tương đương ACC), và p_e là xác suất đồng thuận ngẫu nhiên tính từ phân phối biên (marginal distribution) của confusion matrix:

$$p_e = \sum_{c=1}^K \frac{n_{c \cdot} \cdot n_{\cdot c}}{N^2} \quad (18)$$

với $n_{c \cdot}$ là tổng số epoch thực sự thuộc class c và $n_{\cdot c}$ là tổng số epoch được predict là class c . Kappa > 0,80 được coi là substantial agreement, > 0,60 là moderate agreement [3].

5. Per-stage F1 cho phép phân tích chi tiết hiệu suất từng class riêng lẻ, đặc biệt hữu ích để đánh giá hiệu suất trên class thiểu số N1.

Lý do ưu tiên Macro F1: Với dữ liệu class imbalance nghiêm trọng (N2 chiếm khoảng 37%), Accuracy có thể gây hiểu nhầm: một mô hình trivial chỉ predict N2 cho mọi epoch cũng đạt ~37% accuracy nhưng Macro F1 gần 0% vì F1 của 4 class còn lại đều bằng 0. Macro F1 buộc mô hình phải phân loại tốt *tất cả* các class, bao gồm class thiểu số N1, do đó phản ánh đúng hơn chất lượng thực sự của mô hình trong bối cảnh lâm sàng.

VII. Kết quả và Đánh giá

Bảng 8 tóm tắt kết quả so sánh giữa pipeline gốc và pipeline đề xuất trên tất cả các khía cạnh quan trọng. Chi tiết phân tích từng cấu hình được trình bày trong các mục tiếp theo.

Table 8: So sánh tổng quan: Pipeline gốc vs. Pipeline đề xuất

Tiêu chí	ZleepAnlystNet (gốc)	ResNet-1D + TCN	Thay đổi
Kiến trúc	15 CNN + BiLSTM	1 ResNet + 1 TCN	16 → 2 mô hình
Accuracy (Sleep-EDF)	83,00%	83,89%	+0,89%
Macro F1 (Sleep-EDF)	76,67%	78,53%	+1,86%
N1 F1 (class khó nhất)	48,31%	49,40%	+1,09%
Thời gian train (10 fold)	~12,35 giờ	~1,5 giờ	8,2× nhanh hơn
Zero-shot SHHS	~63%	73,89%	+~10%
Preprocessing	Không	Có	Thêm bước lọc nhiễu

7.1 Tổng hợp tất cả cấu hình trên Sleep-EDF-78

Nhóm thử nghiệm tổng cộng 10 cấu hình khác nhau, chia thành 5 nhóm dựa trên cách thay đổi kiến trúc. Tất cả được đánh giá trên cùng giao thức subject-wise 10-fold cross-validation trên Sleep-EDF-78. Bảng 9 liệt kê đầy đủ kết quả.

Table 9: Tổng hợp kết quả tất cả cấu hình trên Sleep-EDF-78 (subject-wise 10-fold CV)

Nhóm	Feature Extractor	Sequence Model	ACC	MF1	κ	# Models	Train (h)
<i>Nhóm 1: Tái tạo baseline</i>							
1	15 CNN	BiLSTM	83,00%	76,67%	0,764	16	~12,4
<i>Nhóm 2: Thay thế sequence model (giữ 15 CNN)</i>							
2a	15 CNN	TCN	82,71%	77,96%	0,763	16	~10,5
2b	15 CNN	TCN + BiLSTM	83,23%	78,70%	0,770	17	~11,0
2c	15 CNN	Conformer	83,03%	78,15%	0,767	16	~10,8
<i>Nhóm 4: Ensemble / Stacking</i>							
4	15 CNN + hand-crafted	Conf. + XGB + Meta LR	83,87%	78,52%	0,777	18+	~13,0
<i>Nhóm 5: Tinh gọn kiến trúc + preprocessing mới</i>							
5a	ResNet-1D	Conformer	83,84%	78,28%	0,776	2	~1,8
5b	ResNet-1D	SleepTCN	83,89%	78,53%	0,778	2	~1,5

Bên cạnh các kiến trúc chính trong Bảng 9, nghiên cứu cũng đã thử nghiệm mở rộng một số biến thể khác thuộc nhóm 3 - can thiệp trực tiếp vào feature extractor. Cụ thể, nhóm thử nghiệm thay thế convolution layer bằng Kolmogorov-Arnold Network (KAN-CNN + TCN, ACC=82,89%, MF1=77,77%, κ =0,764), và chuyển đổi tín hiệu thô sang miền time-frequency bằng Short-Time Fourier Transform để tạo spectrogram 2D (Spectrogram CNN). Tuy nhiên, các phương pháp này không mang lại cải thiện đáng kể (accuracy dao động quanh mức 82,8–82,9%) và làm tăng độ phức tạp hệ thống, do đó không được chọn làm kiến trúc đề xuất.

7.2 Phân tích kết quả theo nhóm

7.2.1 Nhóm 2: Ảnh hưởng của sequence model khi giữ nguyên 15 CNN

Khi giữ nguyên 15 CNN và chỉ thay đổi sequence model, kết quả cho thấy sequence model có ảnh hưởng đáng kể. Cấu hình TCN thuần (2a) đạt Macro F1 77,96%, cải thiện 1,29% so với BiLSTM gốc (76,67%), nhưng accuracy giảm nhẹ, cho thấy TCN phân loại cân bằng hơn giữa các class. Hybrid TCN + BiLSTM (2b) đạt Macro F1 cao nhất trong nhóm này (78,70%), gợi ý rằng hai kiến trúc bổ sung cho nhau: TCN nắm bắt local context qua dilated convolution, BiLSTM bổ sung long-range dependency qua memory mechanism. Conformer cơ bản (2c) đạt Macro F1 78,15%, cải thiện so với BiLSTM nhưng thấp hơn hybrid TCN+BiLSTM, cho thấy self-attention chưa phát huy hiệu quả tối đa với feature 75 chiều rồi rạc từ softmax output.

7.2.2 Nhóm 5: Tinh gọn kiến trúc với preprocessing mới

Khi thay 15 CNN bằng ResNet-1D và áp dụng preprocessing mới, ResNet-1D + SleepTCN (5b) đạt Macro F1 cao nhất trong toàn bộ nghiên cứu (78,53%) với kiến trúc đơn giản nhất. Đáng chú ý, ResNet-1D + Conformer (5a) đạt kết quả thấp hơn nhẹ ResNet-1D + TCN (78,28% vs. 78,53%), trái ngược với xu hướng ở nhóm 2 nơi Conformer tốt hơn TCN. Điều này gợi ý rằng feature liên tục 128 chiều từ ResNet-1D phù hợp hơn với dilated convolution của TCN so với self-attention của Conformer ở quy mô dữ liệu này.

7.2.3 So sánh thời gian huấn luyện

Pipeline gốc 15 CNN + BiLSTM tiêu tốn khoảng **12,35 giờ** cho toàn bộ 10 fold (bao gồm huấn luyện riêng từng CNN và BiLSTM). Pipeline cải tiến ResNet-1D + SleepTCN chỉ cần khoảng **1,5 giờ** - giảm **8,2 lần**. Phần lớn thời gian tiết kiệm đến từ việc thay 15 CNN (phải huấn luyện tuần tự từng mạng) bằng 1 ResNet-1D duy nhất, và thay BiLSTM (xử lý sequential) bằng TCN (song song hóa hoàn toàn trên GPU).

7.3 So sánh trực quan

Hình 10 so sánh trực quan accuracy và Macro F1 của các cấu hình chính.




Figure 10: So sánh ACC và Macro F1 giữa các cấu hình chính. ResNet+TCN đạt Macro F1 78,53% với kiến trúc gọn hơn.

7.4 Per-stage F1

Hình 11 so sánh F1 từng sleep stage giữa cấu hình đề xuất và bài báo gốc.




Figure 11: Per-stage F1. Pipeline cải tiến có cải thiện nhẹ ở 4/5 stage, N1 tăng 1,09%.


7.5 Confusion Matrix

	Predicted →				
	W	N1	N2	N3	REM
W (True)	93	3	2	0	2
N1 (True)	22	45	18	1	14
N2 (True)	2	4	86	5	3
N3 (True)	0	1	17	82	0
REM (True)	3	8	5	0	84

Figure 12: Confusion matrix heatmap (ResNet+TCN, tổng hợp 10 fold, đơn vị: %). N1 phân tán sang W 22%, N2 18%, REM 14%.

7.6 Độ ổn định giữa các fold

Accuracy dao động từ 79,46% ở fold 7 đến 86,43% ở fold 1, trung bình $83,90\% \pm 1,82\%$. Macro F1 biến thiên mạnh hơn với std 2,66%. Khoảng biến thiên khoảng 7% phản ánh sự khác biệt sinh lý giữa các subject.



7.7 Đánh giá cross-dataset trên SHHS

Đánh giá khả năng generalization cross-dataset giúp trả lời câu hỏi thực tiễn: mô hình được huấn luyện trên một bộ dữ liệu có hoạt động được trên bộ dữ liệu khác không?

7.7.1 Sự khác biệt giữa Sleep-EDF và SHHS

Sleep-EDF và SHHS khác nhau ở ba phương diện quan trọng. Về **đối tượng**: Sleep-EDF ghi trên 78 người khỏe mạnh, SHHS ghi trên 6.441 bệnh nhân mắc hội chứng ngưng thở khi ngủ - bệnh lý gây gián đoạn chu kỳ giấc ngủ, tăng tỷ lệ Wake và giảm N3. Về **thiết bị**: Sleep-EDF dùng máy cassette tại nhà với kênh Fpz-Cz; SHHS dùng hệ thống PSG bệnh viện với kênh C4-A1 - hai montage khác nhau cho biên độ và hình thái sóng khác nhau. Về **sampling rate**: SHHS ghi ở 125Hz, cần resample xuống 100Hz.

7.7.2 Zero-shot evaluation - có preprocessing

Mang trọng số đã huấn luyện trên Sleep-EDF sang predict trực tiếp 200 recording SHHS (191.388 epoch, thời gian inference 48,3 giây). Kết quả đạt ACC=73,89%, MF1=64,27%, κ =0,629. Bảng 10 trình bày chi tiết F1 từng stage.

Table 10: Per-stage F1 - Zero-shot ResNet+TCN trên SHHS (có preprocessing)

	W	N1	N2	N3	REM	Macro F1
F1 (%)	81,47	32,58	78,51	54,37	74,45	64,27

N3 giảm mạnh nhất (từ 81,51% xuống 54,37%) do bệnh nhân ngưng thở khi ngủ thường có ít N3 hơn và delta wave bị gián đoạn bởi các sự kiện apnea. N1 giảm từ 49,40% xuống 32,58%, phản ánh sự khác biệt sleep onset pattern giữa người khỏe mạnh và bệnh nhân. Kết quả 73,89% vẫn cao hơn đáng kể so với khoảng 63–64% của 15 CNN trên cùng kịch bản.

7.7.3 Zero-shot evaluation - không preprocessing

ACC chỉ đạt 22,54% - mô hình sụp đổ hoàn toàn. Khoảng cách **51,35%** giữa hai kịch bản cho thấy rõ vai trò của preprocessing. Mô hình học trên raw signal từ Sleep-EDF encode dải biên độ cụ thể của hệ thống ghi đó; khi gặp SHHS với dải biên độ hoàn toàn khác, features trở nên vô nghĩa.

7.7.4 Retraining trên SHHS

Huấn luyện pipeline từ đầu trên 200 recording SHHS với giao thức 5-fold. Kết quả đạt ACC=84,17%, tương đương với 83,75% của 15 CNN. Điều này gợi ý kiến trúc có thể hoạt động trên các bộ dữ liệu khác nhau, dù cần đánh giá thêm trên quy mô lớn hơn để kết luận chắc chắn.

7.7.5 Tổng hợp

Table 11: Tổng hợp kết quả cross-dataset trên SHHS

#	Kịch bản	Preprocessing	ACC	MF1	Nhận xét
3	Zero-shot	Có	73,89%	64,27%	Generalize tốt (vs. ~63% của 15 CNN)
4	Zero-shot	Không	22,54%	—	Sụp đổ – preprocessing quyết định
5	Retraining	Có	84,17%	—	Không giới hạn bởi dataset

VIII. Thảo luận

8.1 Về kết quả tái tạo

Kết quả tái tạo ZleepAnlystNet đạt ACC=83,00% và MF1=76,67%, chênh lệch khoảng 1% so với bài báo gốc. Sự chênh lệch này bắt nguồn từ ba yếu tố. Thứ nhất, seed khác nhau dẫn đến cách chia fold khác nhau, nghĩa là tập huấn luyện và kiểm tra ở mỗi fold chứa các đối tượng khác nhau. Như đã thấy ở phân tích độ ổn định với độ lệch chuẩn 1,82%, accuracy có thể dao động đến khoảng 7% giữa các fold chỉ do sự khác biệt giữa các đối tượng. Thứ hai, một số chi tiết triển khai không được mô tả đầy đủ trong bài báo gốc, như cách early stopping, cách khởi tạo trọng số, và gradient clipping. Thứ ba, nhóm sử dụng PyTorch trên GPU trong khi bài báo gốc sử dụng MATLAB, gây sai lệch floating-point nhỏ tích lũy qua hàng nghìn iteration. Mức chênh lệch khoảng 1% nhóm cho rằng là có thể chấp nhận được khi reproduce kết quả mà không có source code gốc.

8.2 Đánh giá sự đánh đổi giữa đơn giản hóa và hiệu suất

Câu hỏi trung tâm của nghiên cứu là: liệu có thể đơn giản hóa pipeline 15 CNN riêng biệt xuống 1 mạng duy nhất mà không hy sinh hiệu suất? Kết quả cho thấy câu trả lời là “phần lớn có”, dù vẫn tồn tại một số đánh đổi nhất định. Về phía tích cực, pipeline ResNet-1D + SleepTCN đạt Macro F1 78,53%, cao nhất trong các cấu hình được thử nghiệm. Có cải thiện nhẹ ở các class thiểu số: N1 tăng 1,09%, N3 tăng 0,35%, REM tăng 0,35%. Feature vector liên tục 128 chiều từ ResNet-1D có thể tạo ra không gian biểu diễn phù hợp hơn so với 75 chiều rời rạc từ softmax output. Kiến trúc cũng gọn hơn (1 mô hình thay vì 15) và thời gian huấn luyện giảm 8,2 lần (từ khoảng 12,35 giờ xuống 1,5 giờ).

Đáng lưu ý, các cấu hình sử dụng 15 CNN (nhóm 2) cho thấy Macro F1 cải thiện khi thay BiLSTM bằng TCN hoặc Conformer, nhưng luôn đi kèm 15 mô hình riêng biệt. Pipeline đề xuất đạt Macro F1 cao nhất (78,53%) trong khi chỉ cần 2 mô hình. SleepTCN chủ ý **không dùng class weight** ở giai đoạn 2 vì ResNet-1D đã được train với class weight balancing ở giai đoạn 1. Bổ sung thêm class weight ở sequence model có thể tạo bias khiến mô hình predict N1 quá nhiều tại các vùng transition tự nhiên (ví dụ $W \rightarrow N1 \rightarrow N2$).

Tuy nhiên, overall accuracy giảm nhẹ 0,20%. Sự đánh đổi này phản ánh mâu thuẫn cơ bản trong bài toán class imbalance: khi mô hình “chú ý” nhiều hơn đến class thiểu số N1, nó đánh đổi một phần hiệu suất ở class đa số. Cụ thể, F1 của Wake giảm 0,51%, mức giảm nhỏ nhưng phản ánh rằng một số epoch Wake bị “nhượng” cho N1. Trong lâm sàng, đây là đánh đổi chấp nhận được vì N1 có ý nghĩa chẩn đoán quan trọng hơn trong đánh giá sleep onset latency cho narcolepsy và insomnia, trong khi Wake là class dễ nhận diện nhất.

Một hạn chế cần thừa nhận là ResNet-1D mất đi temporal context ở mức feature extraction mà bài báo gốc có được qua nhóm P và N. Tuy phân tích ở Mục 6.2 cho thấy hai nhóm này chỉ đóng góp khoảng 12% tổng thông tin, “12% thông tin” không nhất thiết đồng nghĩa với “12% accuracy”. Có thể một phần nhỏ chứa tín hiệu quan trọng cho các trường hợp biên, nơi temporal context là yếu tố quyết định. Đây là điểm mở cho nghiên cứu tiếp: liệu một kiến trúc ResNet nhận input 3 epoch liên tiếp có thể cải thiện thêm?

8.3 Đóng góp của cơ chế ignore_index

Cách xử lý nhãn Movement và Unknown bằng `ignore_index` thay vì chuyển thành Wake là một cải tiến nhỏ nhưng có ý nghĩa về mặt phương pháp luận. Bài báo gốc chuyển tất cả epoch rác thành Wake để giữ tính liên tục của sequence, nhưng cách làm này tạo ra “label noise” ở class Wake: mô hình bị buộc phải học rằng tín hiệu nhiễu, gậy, hoặc tuột điện cực là trạng thái thức. Trên bộ dữ liệu Sleep-EDF-78 với khoảng 365 epoch Movement/Unknown (chiếm 0,8%), ảnh hưởng có thể không quá lớn. Tuy nhiên, trên các bộ dữ liệu lâm sàng thực tế nơi tỷ lệ epoch rác có thể cao hơn đáng kể (do bệnh nhân cử động nhiều, thiết bị bị tuột...), vấn đề ô nhiễm nhãn trở nên nghiêm trọng hơn.

Cơ chế `ignore_index` giải quyết vấn đề này: giữ epoch rác ở đúng vị trí trong sequence để mô hình TCN vẫn “nhìn thấy” khoảng cách thời gian, nhưng đánh dấu bằng label -100 để loss function bỏ qua, không tạo gradient. Cách tiếp cận này tương thích với mọi kiến trúc sử dụng cross-entropy loss trong PyTorch và có thể áp dụng trực tiếp mà không cần sửa đổi kiến trúc mô hình.

8.4 N1: giới hạn sinh lý của bài toán

N1 với F1 khoảng 49% tiếp tục là bottleneck chính, ở cả mô hình gốc lẫn cải tiến. Để hiểu tại sao, cần nhìn từ góc độ sinh lý học điện não đồ.

N1 là giai đoạn chuyển tiếp giữa thức và ngủ, kéo dài trung bình chỉ 5–10 phút. Trong giai đoạn này, alpha rhythm dần biến mất và được thay thế bởi theta waves. Tuy nhiên, quá trình này không xảy ra đột ngột: trong cùng một epoch 30 giây, có thể có lúc alpha chiếm ưu thế (giống Wake), lúc theta chiếm ưu thế (giống N1 “sâu”), tạo ra tín hiệu ambiguous mà ngay cả chuyên gia cũng khó phán đoán. Rosenberg et al. [3] báo cáo rằng mức đồng thuận giữa các kỹ thuật viên khi phân loại N1 chỉ đạt Cohen’s kappa 0,24, thấp nhất trong tất cả các stage.

Confusion matrix cho thấy N1 bị phân tán sang ba class lân cận theo đúng logic sinh lý. Wake nhận 22% epoch N1 bị nhầm vì cả hai cùng nằm trên dải transition giữa alpha và theta. REM nhận 14% vì cả hai có biên độ thấp và mixed-frequency; sự khác biệt chính là rapid eye movement, chỉ có thể phát hiện trên kênh EOG chứ không phải EEG đơn kênh. N2 nhận 18% vì transition N1 sang N2 rất mượt. Dấu hiệu chính thức là sự xuất hiện của sleep spindle đầu tiên, nhưng đôi khi không rõ ràng.

Phân tích này cho thấy F1 khoảng 49% cho N1 không phải “lỗi” của mô hình mà phản ánh giới hạn vật lý của thông tin chứa trong tín hiệu EEG đơn kênh.

8.5 Ý nghĩa của kết quả trên SHHS

Kết quả đánh giá cross-dataset đáng chú ý vì nó trả lời câu hỏi thực tiễn: mô hình được huấn luyện trên một bộ dữ liệu có hoạt động được khi đem ra bộ dữ liệu khác không?

Khi đánh giá trực tiếp trên SHHS (zero-shot, không huấn luyện lại), mô hình vẫn đạt 73,89% với preprocessing. Đây là mức đáng kể khi xét rằng mô hình chưa từng thấy bất kỳ mẫu SHHS nào và hai bộ dữ liệu khác nhau ở cả đối tượng (người khỏe mạnh vs. bệnh nhân tim mạch), thiết bị ghi (cassette vs. bệnh viện), lần montage (Fpz-Cz vs. C4-A1). Đặc biệt, kết quả 73,89% cao hơn rõ rệt so với khoảng 63–64% của 15 CNN trên cùng kịch bản, cho thấy feature liên tục từ ResNet-1D kết hợp preprocessing chuẩn hóa biên độ có tính generalization tốt hơn.

Khi mô hình sụp đổ xuống 22,54% ở kịch bản không preprocessing, khoảng cách 51,35% không chỉ chứng minh vai trò của preprocessing mà còn cho thấy rủi ro nghiêm trọng khi deploy mô hình deep learning trên raw data từ nguồn khác. Vấn đề này cần được nhận thức rõ trong ứng dụng lâm sàng thực tế.

Cuối cùng, khi retraining trên SHHS, mô hình đạt 84,17%, tương đương kết quả trên Sleep-EDF, gợi ý kiến trúc có thể áp dụng cho các bộ dữ liệu khác nhau.

8.6 Hạn chế và hướng phát triển

Nghiên cứu này có một số hạn chế. Phương pháp separating training (freeze ResNet khi huấn luyện TCN) có thể gây information loss tại ranh giới giữa hai giai đoạn. End-to-end fine-tuning với learning rate thấp có thể cho phép hai thành phần tối ưu hóa biểu diễn cùng nhau. Nhóm chưa thử nghiệm signal-level augmentation (Gaussian noise injection, time shifting, amplitude scaling), vốn là kỹ thuật đã chứng minh hiệu quả trong các bài toán EEG khác. Việc chỉ sử dụng một kênh EEG hạn chế khả năng phân biệt N1/REM vì dấu hiệu khác biệt chính giữa hai stage này chỉ thấy trên kênh EOG. Cuối cùng, đánh giá trên SHHS mới dừng ở 200 trên tổng số 6.441 subject, chưa đủ để kết luận về khả năng generalization quy mô lớn.

Hướng phát triển ưu tiên bao gồm: end-to-end fine-tuning toàn bộ pipeline, signal-level augmentation trên tín hiệu EEG thô, thay cross-entropy loss bằng Focal Loss để tập trung vào hard examples (đặc biệt N1), post-processing dựa trên transition rules AASM nhằm loại bỏ các chuyển tiếp không hợp lý về mặt sinh lý, và mở rộng đánh giá trên toàn bộ SHHS cùng các bộ dữ liệu bổ sung.

IX. Kết luận

Nghiên cứu này trình bày quá trình tái tạo và cải tiến mô hình ZleepAnlystNet cho bài toán phân loại tự động giai đoạn giấc ngủ từ tín hiệu EEG đơn kênh.

Nhóm đã tái tạo thành công pipeline gốc sử dụng 15 CNN kết hợp BiLSTM (tổng khoảng 248.500 tham số), đạt ACC=83,00% và Macro F1=76,67% trên Sleep-EDF-78, chênh lệch khoảng 1% so với kết quả gốc và nằm trong phạm vi chấp nhận được.

Trước khi đề xuất cải tiến, nhóm thực hiện ablation study trên 75 features từ 15 CNN, phát hiện ba vấn đề: 10/15 CNN chỉ đóng góp khoảng 12% tổng thông tin, 9 cặp features có tương quan cực cao ($r > 0,95$), và 25% features gần như vô dụng. Từ cơ sở phân tích này, nhóm đề xuất thay thế 15 CNN bằng một mạng ResNet-1D duy nhất (khoảng 475.000 tham số), thay BiLSTM bằng SleepTCN non-causal (6 block $\times$ 2 conv, receptive field 253 epoch $\approx$ 126,5 phút), bổ sung preprocessing pipeline, và khắc phục vấn đề ô nhiễm nhãn Wake bằng cơ chế `ignore_index`.

Kết quả cho thấy pipeline cải tiến đạt ACC=83,89% và Macro F1=78,53%, trong đó Macro F1 là cao nhất trong toàn bộ 10 cấu hình đã thử nghiệm. Cải thiện tập trung ở các class thiểu số: N1 tăng 1,09%, N3 tăng 0,35%, REM tăng 0,35%. Thời gian huấn luyện giảm 8,2 lần (từ khoảng 12,35 giờ xuống 1,5 giờ).

Phần đánh giá cross-dataset trên SHHS là một trong những đóng góp quan trọng nhất. Khi zero-shot evaluation trên 200 recording SHHS (bệnh nhân tim mạch, thiết bị và montage khác), mô hình vẫn đạt 73,89% nhờ preprocessing chuẩn hóa biên độ. Khi không có preprocessing, mô hình sụp đổ xuống 22,54%. Khoảng cách 51,35% là minh chứng định lượng mạnh nhất cho vai trò quyết định của preprocessing trong ứng dụng thực tế. Khi retraining trên SHHS, mô hình đạt 84,17%, xác nhận kiến trúc không bị giới hạn bởi dataset cụ thể.

Bài học rút ra:

Data leakage là vấn đề nghiêm trọng trong dữ liệu time series sinh học, đòi hỏi phải sử dụng subject-wise cross-validation thay vì random epoch split, vì các epoch từ cùng một đêm ngủ có temporal autocorrelation rất cao. Preprocessing có ảnh hưởng lớn đến cả chất lượng feature lẫn khả năng generalization giữa các hệ thống ghi. Pipeline phức tạp hơn không nhất thiết cho hiệu suất tốt hơn: một backbone đủ capacity có thể thay thế nhiều mô hình nhỏ chuyên biệt mà vẫn duy trì hiệu suất tương đương, đồng thời giảm chi phí bảo trì và mở rộng. Và cuối cùng, cách xử lý nhãn rác tương tự như nhiễu nhất nhưng có thể ảnh hưởng đến chất lượng dữ liệu, đặc biệt trên các bộ dữ liệu lâm sàng lớn hơn.

References

- [1] World Health Organization, *WHO Technical Meeting on Sleep and Health*. WHO Regional Office for Europe, 2004.
- [2] R. B. Berry *et al.*, “Rules for scoring respiratory events in sleep: update of the 2007 aasm manual for the scoring of sleep and associated events,” *Journal of Clinical Sleep Medicine*, vol. 8, no. 5, pp. 597–619, 2012.
- [3] R. S. Rosenberg and S. Van Hout, “The american academy of sleep medicine inter-scorer reliability program: sleep stage scoring,” *Journal of Clinical Sleep Medicine*, vol. 9, no. 1, pp. 81–87, 2013.
- [4] P. Jadhav, G. Rajguru, D. Datta, and S. Mukhopadhyay, “Zleepanlystnet: A novel deep learning model for automatic sleep stage scoring based on single-channel raw eeg data using separating training,” *Scientific Reports*, vol. 14, no. 1, p. 7308, 2024.

- [5] O. Tsinalis, P. M. Matthews, Y. Guo, and S. Zafeiriou, “Automatic sleep stage scoring using time-frequency analysis and stacked sparse autoencoders,” *Annals of Biomedical Engineering*, vol. 44, no. 5, pp. 1587–1597, 2016.
- [6] A. Supratak, H. Dong, C. Wu, and Y. Guo, “Deepsleepnet: A model for automatic sleep stage scoring based on raw single-channel eeg,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 25, no. 11, pp. 1998–2008, 2017.
- [7] E. Eldele *et al.*, “An attention-based deep learning approach for sleep stage classification with single-channel eeg,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29, pp. 809–818, 2021.
- [8] H. Phan *et al.*, “Sleeptransformer: Automatic sleep staging with interpretability and uncertainty quantification,” *IEEE Transactions on Biomedical Engineering*, vol. 69, no. 8, pp. 2456–2467, 2022.
- [9] H. Phan *et al.*, “L-seqsleepnet: Whole-cycle long sequence modelling for automatic sleep staging,” *IEEE Journal of Biomedical and Health Informatics*, vol. 27, no. 10, pp. 4748–4757, 2023.
- [10] B. Kemp, A. H. Zwinderman, B. Tuk, H. A. Kamphuisen, and J. J. Obery , “Analysis of a sleep-dependent neuronal feedback loop: the sleep-cdf database,” *IEEE Transactions on Biomedical Engineering*, vol. 47, no. 9, pp. 1185–1194, 2000.
- [11] S. F. Quan *et al.*, “The sleep heart health study: design, rationale, and methods,” *Sleep*, vol. 20, no. 12, pp. 1077–1085, 1997.
- [12] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [13] S. Bai, J. Z. Kolter, and V. Koltun, “An empirical evaluation of generic convolutional and recurrent networks for sequence modeling,” *arXiv preprint arXiv:1803.01271*, 2018.
- [14] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [15] A. Gulati *et al.*, “Conformer: Convolution-augmented transformer for speech recognition,” *arXiv preprint arXiv:2005.08100*, 2020.