# Lựa chọn kiến trúc và tiền xử lý khi chuyển bộ dữ liệu trong phân giai đoạn giấc ngủ từ EEG đơn kênh

## Đánh giá có kiểm soát trên Sleep-EDF và SHHS1

Ngô Nhật Quân[a,*], Phạm Thái Sơn[a], Tri Nguyen Ho Duy[a] và Tri Nguyen[a]

[a]*Khoa Hệ thống Thông tin, Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh, Khu phố 34, phường Linh Xuân, Thành phố Hồ Chí Minh, Việt Nam*

Bản dịch tiếng Việt để đọc đối chiếu với bản thảo BSPC

Ngô Nhật Quân: 23521258@gm.uit.edu.vn *(Tác giả liên hệ)
Phạm Thái Sơn: 23521361@gm.uit.edu.vn
Tri Nguyen Ho Duy: trinhd@uit.edu.vn
Tri Nguyen: tringuyen@uit.edu.vn

### Tóm tắt

**Bối cảnh.** Lựa chọn mô hình và tiền xử lý làm thay đổi độ chính xác, chi phí và sai số khi chuyển quần thể của hệ thống phân giai đoạn giấc ngủ tự động, nhưng tác động của chúng hiếm khi được kiểm tra trên dữ liệu không dùng trong quá trình phát triển.

**Phương pháp.** Sáu cấu hình EEG đơn kênh được huấn luyện trên 78 đối tượng Sleep-EDF với cùng các phân hoạch mười fold theo đối tượng. Khả năng chuyển quần thể zero-shot được khảo sát trên 180 người tham gia Sleep Heart Health Study Visit 1 (SHHS1), sau đó được kiểm tra trên 500 người tham gia khác theo một giao thức đã cam kết từ trước.

**Kết quả.** Mạng dư một chiều kết hợp mạng tích chập thời gian (ResNet-1D-TCN) trên đầu vào lọc thông dải (E3) đạt $\mathrm{macro}$-F1 gộp 0.7904 trên Sleep-EDF và, dù có số tham số gấp $4.37\times$ đối chứng CNN-BiLSTM (E0), suy luận nhanh hơn $3.76\times$ và huấn luyện nhanh hơn $10.2\times$, vì E0 cần số bước tối ưu nhiều gấp $22.5\times$. Trên 500 người tham gia tiếp theo, E3 cải thiện $\mathrm{macro}$-F1 trung bình theo đối tượng so với E0 thêm 0.0467 ($\mathrm{CI}_{95\%}$ 0.0403–0.0531), so với chuẩn hóa $z$-score theo bản ghi (E6) thêm 0.0293 (0.0231–0.0354) và so với đầu vào không lọc (E2) thêm 0.0515 (0.0460–0.0571), xác nhận cả ba giả thuyết xác định trước. Qua các seed đã đánh giá, cấu hình chỉ lọc thông dải (E4) vượt E0 và E2 0.031–0.070, lớn hơn khoảng chênh lệch giữa các seed quan sát được của E4 (0.019), và $z$-score trượt trên cửa sổ 90 phút, dù làm thang đầu vào của hai đoàn hệ khớp nhau, vẫn kém E4. E0 và E3 phân loại hơn 72% epoch N3 (ngủ sâu) thành N2, dù một ngưỡng biên độ chọn trên Sleep-EDF vẫn tách được 84% số epoch này khỏi N2; cả đổi thang biên độ lẫn thích nghi miền đều không loại bỏ được lỗi này mà không làm giảm hiệu năng ở các giai đoạn khác.

**Kết luận.** Lọc thông dải đóng góp phần lớn lợi ích khi chuyển quần thể nhưng không giải quyết được lỗi nhầm N3 thành N2. Khi so sánh các quy trình, cần báo cáo biến thiên giữa các lần huấn luyện và xác nhận kết quả trên dữ liệu giữ lại.

**Từ khóa:** phân giai đoạn giấc ngủ; EEG đơn kênh; mạng tích chập thời gian; tiền xử lý; dịch chuyển miền; kiểm định ngoài.

## 1. Giới thiệu

Phân giai đoạn giấc ngủ gán một trong năm nhãn W, N1, N2, N3 và REM cho mỗi đoạn (epoch) 30 giây của bản ghi đa ký giấc ngủ. Chấm thủ công chậm, đòi hỏi nhân sự được đào tạo và không hoàn toàn tái lập được: trong chương trình đánh giá độ tin cậy giữa người chấm của Viện Hàn lâm Y học Giấc ngủ Hoa Kỳ, mức đồng thuận thấp nhất ở N1 [1]. Vì vậy, hệ thống tự động không thể chỉ được đánh giá bằng độ chính xác tổng thể, vốn bị chi phối bởi các giai đoạn xuất hiện nhiều nhất, mà còn bằng các chỉ số cân bằng giữa các lớp, độ ổn định giữa các cá nhân và hành vi khi thiết bị ghi, cấu hình điện cực hoặc quần thể thay đổi.

Các kết quả đã công bố trong lĩnh vực này khó so sánh với nhau. Các nghiên cứu đồng thời khác nhau về phiên bản dữ liệu, cách chia đối tượng, quy tắc cắt bớt đoạn thức, lọc, chuẩn hóa, độ dài chuỗi và quy tắc chọn mô hình, khiến tác động của kiến trúc khó tách khỏi các khác biệt khác trong quy trình. Trong phát triển thực tế, điều quan trọng là lựa chọn nào trong quy trình cải thiện dự đoán, chi phí tính toán của chúng là bao nhiêu và lợi ích có được duy trì trên quần thể khác hay không. Trả lời các câu hỏi này đòi hỏi các phân hoạch đánh giá dùng chung, mô tả rõ những gì thay đổi giữa các cấu hình và dữ liệu đánh giá không ảnh hưởng đến các lựa chọn được so sánh.

Chúng tôi dùng ZleepAnlystNet [2], một mô hình đơn kênh hai giai đoạn kết hợp một nhóm bộ mã hóa tích chập chuyên biệt theo lớp với BiLSTM, làm đối chứng nội bộ E0, được tái triển khai theo giao thức hiện tại. E1 thay BiLSTM bằng mạng tích chập thời gian (TCN) [3], dùng lại bộ mã hóa và đặc trưng đã lưu nhưng thay thiết lập huấn luyện mô hình chuỗi. E2 thay 75 đặc trưng của E1, mô tả epoch hiện tại, liền trước và liền sau (C/P/N), bằng 128 đặc trưng từ một bộ mã hóa dư [4] chỉ nhận epoch hiện tại, đồng thời thay cách huấn luyện và lựa chọn bộ mã hóa. Vì vậy, mỗi bước so sánh các cấu hình hoàn chỉnh chứ không cô lập một thay đổi kiến trúc đơn lẻ. Sau đó, các đối chiếu tiền xử lý khảo sát việc lọc và xử lý biên độ trong cùng mô hình ResNet-1D-TCN và cùng cấu hình huấn luyện. Nghiên cứu không đề xuất kiến trúc mới: đóng góp của nó là một phép so sánh có kiểm soát giữa các thành phần đã có, với các phát hiện chính sau đó được kiểm tra trên những người tham gia nằm ngoài quá trình phát triển.

Chúng tôi đặt ba câu hỏi:

(i) Trong các thay đổi được đánh giá, gồm mô hình chuỗi, bộ mã hóa epoch, lọc tín hiệu và xử lý biên độ, thay đổi nào giải thích khác biệt về độ chính xác, chi phí tính toán và khả năng chuyển sang quần thể khác?

(ii) Các khác biệt giữa quy trình có được duy trì trên những người tham gia không đóng vai trò nào trong quá trình phát triển hay không, và chúng có lớn hơn biến thiên giữa các lần huấn luyện hay không?

(iii) Sau khi chuyển quần thể, lỗi phân giai đoạn nào chiếm ưu thế, chúng phụ thuộc vào biên độ đầu vào như thế nào, và hiệu chỉnh tiên nghiệm, trọng số lớp hoặc thích nghi miền có giảm được chúng mà không gây tổn thất ở các giai đoạn khác hay không?

Các đóng góp của chúng tôi tương ứng với các câu hỏi này.

(1) Chúng tôi cho thấy quy trình ResNet-1D-TCN đã triển khai chạy nhanh hơn ba đến bốn lần so với đối chứng CNN-BiLSTM dù có nhiều tham số hơn, và chỉ cần khoảng một phần mười thời gian huấn luyện vì mỗi fold chỉ huấn luyện hai mạng thay vì mười sáu. Trong các thay đổi được đánh giá, lọc thông dải, chứ không phải bộ mã hóa hay mô hình chuỗi, đóng góp phần lớn lợi thế khi chuyển quần thể: không lọc, cùng mô hình đạt kết quả gần đối chứng.

(2) Chúng tôi xác nhận lợi thế này trên 500 người tham gia SHHS1 giữ lại theo giao thức cố định trước khi xử lý dữ liệu của họ. Qua năm seed của biến thể chỉ lọc thông dải và hai seed của mỗi cấu hình so sánh, các đối chiếu của nó với đối chứng và với mô hình không lọc vượt khoảng chênh lệch giữa các seed quan sát được, trong khi biến thể chỉ lọc thông dải và biến thể có đổi thang cố định, vốn có chênh lệch thang đầu vào bị chuẩn hóa theo lô triệt tiêu phần lớn, chênh nhau ít hơn khoảng đó. Khoảng tin cậy tính với mô hình cố định phản ánh việc lấy mẫu người tham gia nhưng không phản ánh việc huấn luyện lại.

(3) Chúng tôi xác định nhầm N3 thành N2 là lỗi chung khi chuyển quần thể, lặp lại ở mọi quy trình zero-shot và trên mẫu giữ lại. Khảo sát quét biên độ đầu vào cho thấy lỗi này phụ thuộc vào biên độ tín hiệu nhưng biên độ không giải thích được toàn bộ lỗi, và mô tả đầu vào theo từng giai đoạn cho thấy phần lớn epoch N3 của SHHS1 vẫn tách được khỏi N2 bằng một ngưỡng biên độ chọn trên Sleep-EDF. Trong các thí

nghiệm có đối chứng tương ứng, hiệu chỉnh tiên nghiệm, trọng số lớp, thích nghi chuẩn hóa theo lô và thích nghi miền đối kháng đều không giảm được lỗi này mà không làm giảm hiệu năng ở các giai đoạn khác; thất bại của hiệu chỉnh tiên nghiệm vẫn còn khi tiên nghiệm được ước lượng từ 500 bản ghi.

## 2. Nghiên cứu liên quan

DeepSleepNet kết hợp CNN hai nhánh với BiLSTM để nắm bắt hình thái epoch và phụ thuộc theo thời gian [5]. AttnSleep đưa cơ chế chú ý vào đặc trưng đa độ phân giải [6], còn SleepTransformer áp dụng tự chú ý cùng định lượng bất định tường minh [7]. Tiếp theo là các mô hình chuỗi-sang-chuỗi, mô hình gọn nhẹ và mô hình đa góc nhìn [8, 9, 10], và các công trình gần đây mở rộng ngữ cảnh được mô hình hóa đến cả chu kỳ giấc ngủ hoặc bổ sung tiền huấn luyện tương phản [11, 12]. Các công trình này cùng xác lập rằng ngữ cảnh chuỗi quan trọng. Chúng cũng minh họa vấn đề về tính so sánh: khác biệt về phiên bản dữ liệu, cách chia đối tượng và tiền xử lý giữa các công trình đủ lớn để việc so sánh chéo các bảng không thể thay thế một thí nghiệm loại bỏ thành phần trong cùng giao thức, điểm được nhấn mạnh trong một tổng quan gần đây [13].

Các hệ thống đơn kênh cũng khác nhau ở cách biểu diễn tín hiệu. SleepInceptionNet so sánh có hệ thống đầu vào thô, phổ và thời gian-tần số, rồi chọn mô hình Inception dùng wavelet liên tục trên kênh trung tâm, chấm từng epoch riêng lẻ [14]. Nghiên cứu này ủng hộ hai điểm liên quan: một kênh EEG có thể hỗ trợ chấm năm giai đoạn, và lựa chọn biểu diễn đầu vào là một phần của định nghĩa mô hình chứ không phải chi tiết triển khai trung tính. Van Der Donckt và cộng sự [15] còn chỉ ra rằng các kiến trúc học sâu ngày càng phức tạp không nhất thiết vượt một quy trình truyền thống được thiết kế cẩn thận khi đánh giá theo giao thức tương đồng, và một bộ phân loại dựa trên đặc trưng, huấn luyện trên nhiều đoàn hệ, đã tổng quát hóa được sang các bản ghi chưa thấy [16].

Phân giai đoạn giấc ngủ giữa các bộ dữ liệu là một vấn đề phương pháp luận đang được nghiên cứu tích cực. Các mô hình huấn luyện trên nhiều đoàn hệ và cấu hình kênh, như U-Sleep [17] và các mạng dư trên đoàn hệ hỗn hợp của Olesen và cộng sự [18], tìm kiếm độ vững thông qua sự đa dạng của dữ liệu huấn luyện; RobustSleepNet chấp nhận cấu hình điện cực bất kỳ với cùng mục đích [19], và U-Sleep vẫn hoạt động với các chuyển đạo nằm ngoài hướng dẫn chấm điểm [20]. Các phương pháp khác thì thích nghi với miền đích, bằng cách tinh chỉnh trên một mẫu đích nhỏ có nhãn [21], căn chỉnh đối kháng với ít hoặc không có nhãn đích [22], hoặc căn chỉnh đặc trưng giữa nhiều miền nguồn để không cần dữ liệu đích [23]. He và cộng sự [24] huấn luyện mạng học chuyển giao trên Sleep-EDF, SHHS1 và dữ liệu PhysioNet Challenge, còn ADAST dùng chú ý riêng theo miền, căn chỉnh đối kháng và tự huấn luyện lặp bằng nhãn giả trên dữ liệu đích không nhãn [25]. Nghiên cứu của chúng tôi giải quyết một câu hỏi hẹp hơn mà các cách tiếp cận này để ngỏ: trong một quy trình một nguồn, lựa chọn mô hình và tiền xử lý nào quyết định khả năng chuyển quần thể, chi phí của chúng là bao nhiêu, và tác động của chúng có đứng vững trên dữ liệu không dùng để đưa ra các lựa chọn đó hay không.

Sleep-EDF Expanded là benchmark công khai chuẩn cho EEG đơn kênh [26, 27, 28]. Sleep Heart Health Study (SHHS) là đoàn hệ đa trung tâm quy mô lớn được xây dựng để nghiên cứu rối loạn hô hấp khi ngủ và nguy cơ tim mạch [29], phân phối qua National Sleep Research Resource (NSRR) [30]. Hai bộ dữ liệu khác nhau về tuổi, bệnh đồng mắc, thiết bị ghi, cấu hình điện cực và phân bố nhãn, nên SHHS kiểm tra một dạng thay đổi đoàn hệ không thể hiện được bằng một phần giữ lại của Sleep-EDF. Chúng tôi dùng SHHS để đánh giá độ vững trước thay đổi này; một phép thử chuyển giao hồi cứu không phải kiểm định lâm sàng.

Hai hướng nghiên cứu khác giúp diễn giải kết quả. Dao động chậm có biên độ thay đổi theo không gian và lan truyền trên vỏ não [31], trong khi chấm giấc ngủ sâu dùng tiêu chí biên độ [32, 33]. Một phân tích SHHS gần đây khảo sát mối liên hệ giữa các tiêu chí đó với khác biệt về chấm N3 theo tuổi và giới [34]. Các nghiên cứu này cung cấp bối cảnh cho việc chuyển giữa các chuyển đạo và quần thể; thí nghiệm hiện tại không xác lập cơ chế đó. Khác biệt về tỷ lệ lớp cũng có thể ảnh hưởng đến dự đoán; hiệu chỉnh tiên nghiệm và hiệu chuẩn xác suất giải quyết những vấn đề liên quan nhưng khác nhau [35, 36].

## 3. Dữ liệu và phương pháp

### 3.1. Dữ liệu và nhãn

Tập con Sleep Cassette của Sleep-EDF Expanded được dùng ở đây gồm 153 bản ghi của 78 đối tượng; chúng tôi dùng chuyển đạo Fpz-Cz ở 100 Hz với epoch 30 giây (3 000 mẫu mỗi epoch). Nhãn được ánh xạ thành W, N1, N2, N3 và REM, gộp giai đoạn 3 và 4 ban đầu thành N3; các epoch Movement và Unknown giữ vị trí theo thời gian nhưng bị loại khỏi hàm mất mát và mọi chỉ số. Sau khi lấy cửa sổ, còn 195 767 epoch, trong đó 195 469 epoch có nhãn được đánh giá và 298 epoch là Movement/Unknown.

Cửa sổ đánh giá, áp dụng giống nhau cho cả hai đoàn hệ, kéo dài từ 30 phút trước epoch đầu tiên đến 30 phút sau epoch cuối cùng có nhãn N1, N2, N3 hoặc REM. Vì cửa sổ này ảnh hưởng mạnh đến tỷ lệ thức và mọi chỉ số tổng hợp, và vì các mốc của nó dùng nhãn tham chiếu, đây là một quy ước benchmark chứ không phải quy tắc suy luận có thể triển khai.

Việc chọn SHHS Visit-1 chấp nhận các giá trị 3–7 của trường chất lượng `overall_shhs1`; cả 5 804 người tham gia trong bản phát hành dữ liệu đều đáp ứng. Mã định danh người tham gia được xếp hạng bằng SHA-256 với seed chọn mẫu 42, và 220 người đầu tiên được phân vai trò: 5 người thích nghi, 15 người xác thực, 180 người kiểm tra và 20 người dự phòng. Nhóm xác thực đóng vai trò cổng kỹ thuật: toàn bộ lượt suy luận phải chạy xong không lỗi trên nhóm này trước khi xử lý những người kiểm tra, và không mô hình hay thiết lập nào được chọn dựa trên nhóm này. Nhóm thích nghi cung cấp năm bản ghi không nhãn dùng để ước lượng tiên nghiệm và cho ADAST. Chúng tôi gọi 180 người kiểm tra (tuổi $63.3 \pm 11.5$; 93 nam và 87 nữ) là *mẫu SHHS1 thứ nhất*. Mẫu này được chọn trước khi xem bất kỳ dự đoán nào, nhưng mọi phân tích và can thiệp tiếp theo đều được phát triển trên nó.

Để kiểm tra các phát hiện chính trên dữ liệu chưa ảnh hưởng đến chúng, chúng tôi lấy một *mẫu SHHS1 giữ lại* gồm những người tham gia xếp hạng 221 đến 720 trong cùng bảng xếp hạng; một người không có bản ghi được thay bằng người xếp hạng kế tiếp trước mọi bước xử lý. 500 người tham gia giữ lại (tuổi $62.8 \pm 11.5$; 249 nam và 251 nữ; bản ghi dài 5.5–9.1 giờ, trung vị 8.8 giờ) chưa được dùng cho bất kỳ bước nào trước đó của nghiên cứu, và tất cả đều qua kiểm tra kỹ thuật. Cỡ mẫu được quyết định bởi chi phí tải và xử lý bản ghi chứ không bởi tính toán lực thống kê; các khoảng tin cậy xác nhận có nửa độ rộng khoảng 0.006.

Ở cả hai mẫu, kênh EEG là C4-A1 ở 125 Hz, được lấy mẫu lại về 100 Hz bằng bộ lọc chống chồng phổ đa pha (tăng 4, giảm 5, cửa sổ Kaiser $\beta = 5.0$) áp dụng lên tín hiệu liên tục trước khi chia epoch. Nhãn SHHS được ánh xạ $0 \to$W, $1 \to$N1, $2 \to$N2, $\{3, 4\} \to$N3, $5 \to$REM, $\{6, 9\} \to$loại bỏ. Bảng 1 trình bày phân bố nhãn của ba mẫu.

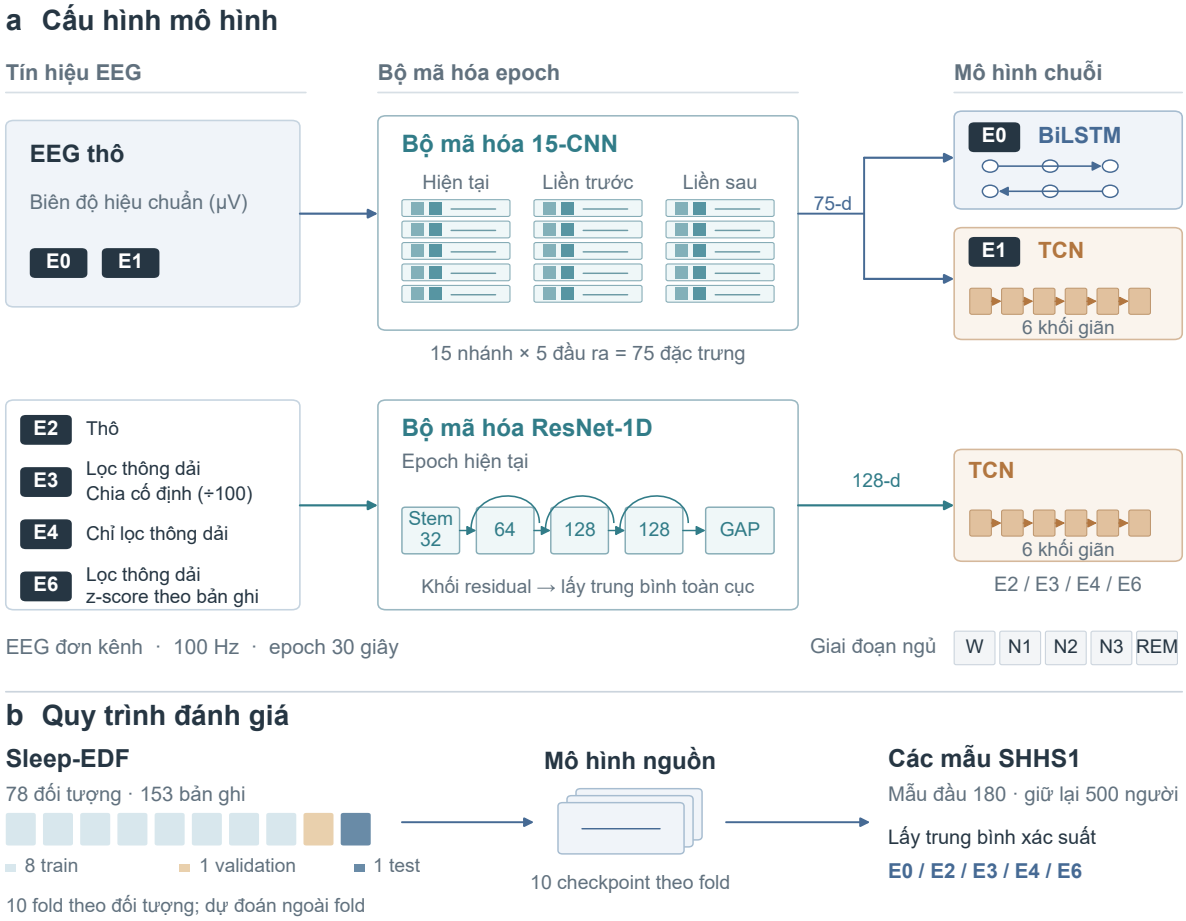
**Bảng 1.** Phân bố nhãn được đánh giá trong ba mẫu đánh giá. Tỷ số so sánh tỷ trọng trong mẫu SHHS1 giữ lại với tỷ trọng trong Sleep-EDF.

| | **Sleep-EDF** | | **SHHS1 thứ nhất** ($n = 180$) | | **SHHS1 giữ lại** ($n = 500$) | | |
|---|---|---|---|---|---|---|---|
| **Giai đoạn** | **Epoch** | **Tỷ trọng** | **Epoch** | **Tỷ trọng** | **Epoch** | **Tỷ trọng** | **Tỷ số** |
| W | 65 941 | 33.73% | 36 983 | 21.88% | 99 674 | 21.74% | 0.64 |
| N1 | 21 522 | 11.01% | 7 002 | 4.14% | 18 930 | 4.13% | 0.38 |
| N2 | 69 132 | 35.37% | 76 287 | 45.14% | 207 848 | 45.34% | 1.28 |
| N3 | 13 039 | 6.67% | 22 806 | 13.49% | 61 523 | 13.42% | 2.01 |
| REM | 25 835 | 13.22% | 25 934 | 15.34% | 70 434 | 15.36% | 1.16 |
| **Tổng** | **195 469** | **100%** | **169 012** | **100%** | **458 409** | **100%** | |

Cả hai mẫu SHHS1 có tỷ trọng N3 khoảng gấp đôi và tỷ trọng N1 bằng 0.38 lần so với Sleep-EDF; với mẫu thứ nhất, khoảng cách biến thiên toàn phần so với Sleep-EDF là 0.187 và $D_{\mathrm{KL}}(\mathrm{EDF} \,\|\, \mathrm{SHHS})$ là 0.101 nat.

### 3.2. Các điều kiện tiền xử lý

Hình 1 tóm tắt các cấu hình kiến trúc, ngữ cảnh và tiền xử lý được đánh giá cùng quy trình đánh giá chung. EEG đã hiệu chuẩn được xử lý liên tục trước khi chia epoch; các epoch thu được được mã hóa bằng bộ mã hóa 15-CNN hoặc ResNet-1D, rồi được mô hình hóa theo chuỗi bằng BiLSTM hoặc TCN.




**Hình 1. Các cấu hình mô hình và quy trình đánh giá.** (a) E0 và E1 dùng chung bộ mã hóa 15-CNN: năm nhánh cho mỗi epoch hiện tại, liền trước và liền sau tạo thành 75 đặc trưng cho BiLSTM hoặc TCN. E2, E3, E4 và E6 dùng các bộ mã hóa ResNet-1D epoch hiện tại được huấn luyện riêng cùng TCN. Các số trong ResNet là số kênh đầu ra; GAP là lấy trung bình toàn cục. Cả hai TCN có sáu khối giãn không nhân quả. E3 và E6 còn cắt biên độ tại $\pm 800\,\mu$V sau lọc thông dải (bước cắt không bao giờ kích hoạt); E3 chia cho 100, còn E6 dùng thống kê $z$-score của toàn bản ghi. (b) Sleep-EDF dùng mười fold theo đối tượng dùng chung, mỗi lượt có tám fold huấn luyện, một fold xác thực và một fold kiểm tra. Đánh giá SHHS1 lấy trung bình xác suất lớp của mười checkpoint fold nguồn trước khi chọn lớp dự đoán, không khớp mô hình trên miền đích; ô này liệt kê các cấu hình được đánh giá trên mẫu giữ lại, còn E1 chỉ được đánh giá trên mẫu thứ nhất. E6 dùng thống kê bản ghi đích không nhãn; E6R (bản sửa đổi A2, không vẽ) thay các thống kê đó bằng $z$-score trượt trên cửa sổ 90 phút. E5 là kiểm tra đồng nhất đầu vào, không phải một cấu hình hiệu năng bổ sung. Các ký hiệu biểu diễn kiến trúc và vai trò fold, không phải tín hiệu đo hay kích thước phân hoạch.

Mọi điều kiện tác động lên tín hiệu liên tục đã hiệu chuẩn theo microvolt trước khi chia epoch. Bốn điều kiện tín hiệu được dùng trong phân tích hiệu năng; điều kiện thứ năm (E5) chỉ dùng để kiểm tra, ghi nhận một thí nghiệm loại bỏ bước cắt biên độ đã lên kế hoạch:

- **Thô** (E0–E2): không lọc, không cắt, không đổi thang; giữ nguyên đơn vị $\mu$V.
- **Chỉ lọc thông dải** (E4): bộ lọc Butterworth thông dải không lệch pha, bậc 4, 0.5–30 Hz, triển khai bằng các tầng bậc hai với phép lọc tiến-lùi.
- **Lọc thông dải và cắt biên độ** (E5; chỉ kiểm tra): tín hiệu E4 tiếp tục được cắt cứng tại $\pm 800\,\mu$V. Đầu

vào E5 và E4 giống nhau từng bit trên cả 153 bản ghi Sleep-EDF, nên E5 được dừng sau fold 0, trước khi xem bất kỳ điểm số nào.

- **Lọc thông dải, cắt biên độ và chia cho 100** (E3): cùng phép lọc thông dải, tiếp theo cắt cứng tại $\pm 800\,\mu$V và chia cho hằng số 100. Không ước lượng thống kê nào ở cấp bản ghi hay đoàn hệ.
- **$z$-score theo bản ghi** (E6): cùng phép lọc và cắt, tiếp theo trừ trung bình và chia cho độ lệch chuẩn tính trên toàn bộ bản ghi đã lọc và cắt. Cách này không dùng nhãn đích nhưng dùng mọi mẫu của bản ghi đích, loại bỏ khác biệt biên độ tuyệt đối giữa các bản ghi và mang tính chuyển nạp (transductive) ở cấp bản ghi.

Không áp dụng bộ lọc notch: nhiễu điện lưới 50 Hz trong Sleep-EDF nằm tại tần số Nyquist của tín hiệu 100 Hz, còn nhiễu 60 Hz trong các bản ghi SHHS 125 Hz được bộ lọc chống chồng phổ của bước lấy mẫu lại làm suy giảm; cả hai đều nằm ngoài dải thông 0.5–30 Hz.

Bước cắt $\pm 800\,\mu$V không bao giờ kích hoạt: giá trị Sleep-EDF sau lọc thông dải không vượt $246\,\mu$V, mọi kênh EEG của mẫu SHHS1 giữ lại có dải vật lý $\pm 125\,\mu$V, và kiểm tra tiền xử lý của mẫu SHHS1 thứ nhất không ghi nhận mẫu tín hiệu nào bị cắt. Vì vậy E3 chỉ khác E4 ở hệ số 100. Lớp tích chập đầu tiên của ResNet-1D không có bias và đứng ngay trước một lớp chuẩn hóa theo lô, lớp này triệt tiêu phần lớn một hệ số thang đầu vào hằng số. Tính bất biến này chỉ là xấp xỉ: hằng số ổn định hữu hạn $\varepsilon$, cách khởi tạo thống kê tích lũy và độ chính xác số có thể ảnh hưởng đến đầu ra và quỹ đạo huấn luyện (Mục bổ sung S4). Vì vậy E3−E4 so sánh hai biến thể được huấn luyện riêng, có đổi thang cố định và chỉ lọc thông dải, chứ không phải hai lần chạy giống hệt nhau về mặt toán học. E3−E2 so sánh bước lọc cùng với bước đổi thang cố định, cộng với biến thiên giữa các lần huấn luyện; kết quả của E4 ủng hộ đóng góp của bước lọc khi không có bước đổi thang cố định.

Thống kê theo bản ghi của E6 được tính trên những khoảng thời gian rất khác nhau ở hai đoàn hệ. Bản ghi Sleep-EDF dài 17–24 giờ (trung vị 23 giờ), gồm cả những đoạn ban ngày dài nằm ngoài cửa sổ đánh giá, trong khi bản ghi SHHS1 chỉ bao phủ khoảng thời gian nằm trên giường ban đêm. Trong cửa sổ đánh giá, trung vị độ lệch chuẩn của đầu vào E6 là 0.77 ở Sleep-EDF nhưng 0.99 ở mẫu SHHS1 giữ lại (khoảng tứ phân vị 0.85–1.00). Như vậy, E6 đưa tín hiệu SHHS1 vào mô hình ở thang tương đối khoảng 1.3 lần so với lúc huấn luyện, ngoài việc loại bỏ khác biệt biên độ giữa các bản ghi. Vì vậy, một bản sửa đổi sau đó bổ sung E6R, tính $z$-score trên cửa sổ 90 phút có tâm để tín hiệu của hai đoàn hệ đến mô hình ở cùng thang tương đối (Mục 3.10).

### 3.3. Cấu hình mô hình

**Bảng 2.** Mã cấu hình thực nghiệm. Các mã biểu thị tổ hợp tín hiệu-mô hình, không phải thứ hạng hiệu năng hay chuỗi phiên bản mô hình.

| Mã | Điều kiện tín hiệu | Bộ mã hóa epoch | Mô hình chuỗi và vai trò |
|---|---|---|---|
| E0 | Thô | CNN 15 nhánh | BiLSTM; đối chứng nội bộ |
| E1 | Thô | CNN 15 nhánh | TCN; thay mô hình chuỗi và thiết lập huấn luyện |
| E2 | Thô | ResNet-1D | TCN; thay bộ mã hóa/ngữ cảnh và cách huấn luyện bộ mã hóa |
| E3 | Lọc thông dải + cắt + ÷100 | ResNet-1D | TCN; cấu hình lọc thông dải |
| E4 | Chỉ lọc thông dải | ResNet-1D | TCN; cấu hình lọc thông dải không đổi thang |
| E5 | Lọc thông dải + cắt | ResNet-1D | TCN; chỉ kiểm tra, đầu vào giống E4 |
| E6 | Lọc thông dải + cắt + $z$-score | ResNet-1D | TCN; chuẩn hóa theo bản ghi |
| E6R | Lọc thông dải + cắt + $z$-score 90 phút | ResNet-1D | TCN; chuẩn hóa theo cửa sổ (bản sửa đổi A2) |

Sáu cấu hình E0–E4 và E6 được đưa vào phân tích hiệu năng chính, còn E6R thuộc bản sửa đổi thứ hai. Bộ mã hóa đối chứng nối đầu ra softmax năm lớp của 15 nhánh CNN trải trên epoch hiện tại, liền trước và liền sau (C/P/N), cho 75 đặc trưng mỗi epoch; ResNet-1D tạo 128 đặc trưng chỉ từ epoch hiện tại. TCN sáu khối không nhân quả có trường tiếp nhận 253 epoch, còn BiLSTM đối chứng có 128 đơn vị ẩn mỗi chiều. Mọi mô hình đều chạy ngoại tuyến: mô hình chuỗi dùng ngữ cảnh của các epoch phía sau, còn lọc không lệch pha và chuẩn hóa E6 dùng các mẫu tín hiệu phía sau. Kích thước lớp và siêu tham số được nêu trong Phương pháp bổ sung S1.

### 3.4. Huấn luyện hai giai đoạn và đánh giá chéo theo đối tượng

78 đối tượng được chia thành mười fold không giao nhau theo đối tượng. Ở mỗi lượt, một fold làm fold kiểm tra, fold kế tiếp làm fold xác thực và các fold còn lại làm fold huấn luyện, nên hai đêm của cùng một người luôn cùng vai trò và fold kiểm tra không bao giờ tham gia chọn mô hình; mọi cấu hình dùng cùng phân hoạch. Huấn luyện có hai giai đoạn. Bộ mã hóa epoch dùng trọng số lớp tính từ các đối tượng huấn luyện và được chọn trên dữ liệu xác thực, theo hàm mất mát có trọng số nhỏ nhất với mỗi CNN đối chứng và macro-F1 lớn nhất với ResNet-1D; checkpoint được chọn dùng để trích đặc trưng (không tính gradient). Sau đó, mô hình chuỗi được huấn luyện trên các đặc trưng cố định này với hàm cross-entropy có mặt nạ và được chọn theo macro-F1 xác thực. E1 dùng lại bộ mã hóa E0 nhưng thay thiết lập tối ưu mô hình chuỗi, còn E2 thay cả cách tối ưu và chọn bộ mã hóa (Phương pháp bổ sung S1), nên các so sánh cố định phân hoạch và cách đánh giá chứ không cố định mọi lựa chọn huấn luyện. Mọi cấu hình được huấn luyện với seed 42 và 123; riêng E4 được huấn luyện thêm với seed 2025, 2027 và 2029 trong bản sửa đổi thứ hai. Trên cùng các bản ghi Sleep-EDF Fpz-Cz, E0 ở seed 42 đạt macro-F1 gộp 0.7754 và độ chính xác 0.8262, so với 0.7826 và 0.8409 được báo cáo cho ZleepAnlystNet với đánh giá chéo mười fold theo đối tượng [2], dù E0 được chọn trên các đối tượng xác thực giữ lại thay vì trên một phép chia ngẫu nhiên theo epoch của dữ liệu huấn luyện (Bảng bổ sung S3).

### 3.5. Phân tích thống kê

Mọi cấu hình đã hoàn tất chọn mô hình dựa trên xác thực trước khi đánh giá dự đoán kiểm tra seed 42. Trên Sleep-EDF, macro-F1 gộp là chỉ số chính, nhưng đơn vị suy luận là đối tượng. Bootstrap cụm theo đối tượng bắt cặp với 10 000 lần lấy mẫu lại cho khoảng phân vị của các chênh lệch [37], kiểm định hạng có dấu Wilcoxon hai phía [38] đánh giá chênh lệch theo đối tượng, và hiệu chỉnh Holm [39] được áp dụng cho bốn so sánh xác định trước E1−E0, E2−E1, E3−E2 và E3−E6; E3−E0 là hậu nghiệm. macro-F1 gộp được tính từ tổng ma trận nhầm lẫn, còn macro-F1 trung bình theo đối tượng lấy trung bình điểm của từng người; chỉ số dùng năm lớp cố định và gán giá trị không khi mẫu số rỗng. Số thắng/hòa/thua, mức trội dấu $(W - L)/(W + L)$ và kiểm định dấu chính xác mang tính mô tả. Mọi khoảng là khoảng tin cậy 95% cho từng so sánh riêng lẻ, tính với các mô hình đã huấn luyện được giữ cố định, nên không bao gồm biến thiên giữa các lần huấn luyện. Lần lặp seed 123, hoàn thành sau khi đã biết kết quả seed 42, được phân tích riêng.

Trên SHHS1, mỗi cấu hình được áp dụng mà không cập nhật trọng số (zero-shot): xác suất softmax của mười mô hình fold Sleep-EDF được lấy trung bình (ở độ chính xác float64) rồi mới chọn lớp có xác suất lớn nhất. Trên mẫu SHHS1 thứ nhất, tiêu chí chính xác định trước là macro-F1 trung bình theo đối tượng, với E3−E0 và E3−E6 là các so sánh chính theo cùng quy trình; các so sánh liên quan E1, E2 và E4 là thứ cấp hoặc hậu nghiệm, và các phân tích vùng ranh giới là chẩn đoán hậu nghiệm (Phương pháp bổ sung S1).

### 3.6. Giao thức xác nhận trên mẫu giữ lại

Trước khi tiền xử lý bất kỳ bản ghi giữ lại nào, chúng tôi công bố trên kho dự án công khai (ngày 10–10–2026) một giao thức cố định đoàn hệ, tiền xử lý, checkpoint, quy tắc tổ hợp, chỉ số, giả thuyết và quy tắc quyết định; chương trình phân tích cũng được công bố ở đó trước khi chạy (mã commit và dấu thời gian ở Mục bổ sung S3). Họ xác nhận gồm ba đối chiếu seed 42 trên macro-F1 trung bình theo đối tượng, đều kỳ vọng dương: H1, E3−E0; H2, E3−E6; và H3, E3−E2. Một giả thuyết được xác nhận nếu giá trị $p$ Wilcoxon hai phía sau hiệu chỉnh Holm nhỏ hơn 0.05 và khoảng bootstrap cụm theo đối tượng bắt cặp (10 000 lần lấy mẫu lại, seed 2040) nằm hoàn toàn trên không.

Giao thức cũng xác định các phân tích thứ cấp: lặp lại H1–H3 ở seed 123, E4−E3 cùng chênh lệch giữa

hai seed của E0, E3, E4 và E6, ADAST so với đối chứng tương ứng, độ thu hồi N3 và tỷ lệ N3→N2, một biến thể macro-F1 theo đối tượng chỉ tính các lớp hiện diện, và tóm tắt thang đầu vào của E6. Mười hai mô hình tổ hợp được đánh giá trên CPU với các checkpoint đã khóa: E0, E2, E3, E4 và E6 ở cả hai seed, cùng ADAST và đối chứng của nó; không chỉ số nào được tính trước khi có đủ mọi dự đoán. Các điểm lệch khỏi giao thức được liệt kê ở Mục bổ sung S3; không điểm nào làm thay đổi dự đoán.

### 3.7. Phân tích biên độ và thích nghi sau xác nhận

Sau phân tích xác nhận, một bản sửa đổi giao thức được công bố trên kho dự án trước khi chạy suy luận. Bản sửa đổi này xác định hai phân tích mô tả trên cùng 500 người tham gia, dùng E4 seed 42, tức dạng chỉ lọc thông dải của quy trình (Mục 4.4). Thứ nhất, đầu vào được nhân với 0.5, 0.75, 1.5 hoặc 2 trong khi bộ mã hóa giữ nguyên thống kê chuẩn hóa theo lô đã lưu, nhằm kiểm tra giai đoạn dự đoán phụ thuộc vào biên độ tín hiệu mạnh đến đâu. Bản sửa đổi nêu trước rằng nếu bỏ sót N3 chủ yếu là do sóng chậm của SHHS1 đi vào bộ mã hóa với biên độ nhỏ hơn dữ liệu huấn luyện, thì với hệ số lớn hơn 1, độ thu hồi N3 sẽ tăng và tỷ lệ N3→N2 sẽ giảm; một đáp ứng không đơn điệu sẽ bác bỏ cách giải thích chỉ dựa trên biên độ. Thứ hai, chuẩn hóa theo lô thích nghi (AdaBN) [40] thay thống kê chạy của mười lớp chuẩn hóa theo lô trong bộ mã hóa, lần lượt từng lớp, bằng thống kê của 20 000 epoch SHHS1 không nhãn; đây là một phương pháp thích nghi không nhãn cơ sở, không cập nhật trọng số. Chúng tôi cũng báo cáo độ lệch chuẩn theo bản ghi của đầu vào đã lọc ở cả hai đoàn hệ. Các điều kiện được so với E4 không sửa đổi bằng bootstrap cụm theo đối tượng bắt cặp (10 000 lần lấy mẫu lại, seed 2042), không kiểm định giả thuyết. Các điều kiện này được tính trên GPU thay vì CPU như bản sửa đổi ghi; xác suất trên GPU và CPU chênh nhau tối đa $1.4 \times 10^{-5}$ và giai đoạn dự đoán giống hệt nhau (Mục bổ sung S5).

### 3.8. Các thí nghiệm can thiệp

Sau khi phân tích các lỗi trên mẫu SHHS1 thứ nhất, chúng tôi đánh giá ba can thiệp trên chính mẫu đó; mỗi can thiệp được so với đối chứng tương ứng và đều lấy trung bình xác suất của mười mô hình fold: hiệu chuẩn nhiệt độ kèm hiệu chỉnh tiên nghiệm EM cho mười mô hình E3 seed 123, với tiên nghiệm ước lượng trên năm bản ghi thích nghi không nhãn; huấn luyện TCN có trọng số lớp trên bộ mã hóa E3 seed 123 đóng băng; và ADAST [25], thích nghi với các bản ghi đích không nhãn, so với một mô hình chỉ học nguồn cùng kiến trúc. ADAST được huấn luyện ở hai ngân sách học, 1 140 lượt cập nhật mỗi mô hình và 30 lượt duyệt trọn dữ liệu huấn luyện nguồn (huấn luyện toàn nguồn), và được đánh giá ở epoch 30. Việc chọn mô hình chỉ dùng dữ liệu xác thực của nguồn; nhãn đích chỉ được dùng để chấm điểm. Cặp mô hình toàn nguồn cũng được áp dụng nguyên trạng, không huấn luyện thêm, lên mẫu giữ lại. Phương pháp bổ sung S2 nêu cách khớp, chọn mô hình, ngân sách và các thí nghiệm phát triển.

### 3.9. Đánh giá vận hành

Thời gian suy luận được đo trên một GPU Tesla V100 cho mọi cấu hình, không tính I/O, tiền xử lý và huấn luyện: một lô gồm một chuỗi tổng hợp 100 epoch, 20 lượt khởi động và ba vòng 100 lượt đo theo thứ tự cấu hình xáo trộn, tóm tắt bằng trung vị của toàn bộ 300 lượt. Benchmark này đo quy trình truyền xuôi đã triển khai với một hình dạng tensor, không phải độ phức tạp thuật toán. Thời gian suy luận cả đêm trên CPU được đo hậu nghiệm bằng chính hàm suy luận của đánh giá trên mẫu giữ lại: một mô hình fold của E0 và một của E3, cấu hình dùng chung kiến trúc với E2, E4, E6 và E6R, chấm bản ghi giữ lại có độ dài trung vị (932 epoch, 7.8 giờ) trên một bộ xử lý máy tính xách tay (Intel Core i5-13500H, PyTorch 2.5.1) với một và với bốn luồng. Sau một lượt khởi động, mỗi mô hình được đo năm lượt theo thứ tự xen kẽ, không tính I/O, tiền xử lý và nạp mô hình, và trung vị được báo cáo (Mục bổ sung S9). Chi phí huấn luyện được ghi bằng thời gian thực (wall-clock) của huấn luyện và xác thực trên cả mười fold trong lượt chạy seed 123, trong đó mọi cấu hình được huấn luyện tuần tự trên cùng một GPU Tesla V100 với công thức huấn luyện và quy tắc dừng riêng (Phương pháp bổ sung S1).

### 3.10. Các phân tích mô tả bổ sung

Bản sửa đổi thứ hai (A2), được công bố trên kho mã trước mọi bước tiền xử lý, huấn luyện, suy luận hay phân tích của nó, xác định năm phân tích mô tả, cùng mọi tổ hợp, seed, thiết lập và quy tắc báo cáo từng kết quả (Mục bổ sung S6). A2 không kiểm định giả thuyết và không xét lại H1–H3. (A) E6R lặp lại E6 với

$z$-score trượt có tâm trên cửa sổ 90 phút ở seed 42 và 123, để kiểm tra xem thiếu hụt của E6 có phụ thuộc vào khoảng thời gian dùng để tính thống kê hay không. (B) E4 được huấn luyện thêm ba seed, tổng cộng năm seed, để mô tả biến thiên huấn luyện. (C) Từng mô hình fold của mỗi tổ hợp zero-shot cũng được chấm điểm riêng trên mẫu giữ lại, vì Sleep-EDF được đánh giá bằng một mô hình cho mỗi đối tượng còn SHHS1 bằng ensemble mười mô hình. (D) Hiệu chỉnh tiên nghiệm EM được lặp lại trên mẫu giữ lại với đúng mười mô hình E3 seed 123 và các nhiệt độ đã lưu, chỉ thay dữ liệu dùng để ước lượng tiên nghiệm đích: tập con ngẫu nhiên gồm 5, 20 và 100 bản ghi (mỗi mức 200 lần bốc), 20 000 epoch không nhãn của mẫu AdaBN, cả 500 bản ghi, và từng bản ghi riêng lẻ. (E) Thời gian huấn luyện của lượt chạy seed 123 được tách thành số bước tối ưu, thời gian mỗi bước đo trên GPU Tesla V100, và phần còn lại. 50 lần huấn luyện mới trên Sleep-EDF dùng phân hoạch, chương trình huấn luyện và công thức đã khóa, và các fold kiểm tra của chúng chỉ được mở một lần, sau khi mọi lần huấn luyện đã xong. Khoảng tin cậy là khoảng bootstrap cụm theo đối tượng có bắt cặp (10 000 lần lấy mẫu lại, seed 2043).

Cuối cùng, một phân tích mô tả hậu nghiệm nằm ngoài cả hai bản sửa đổi so sánh phổ công suất của đầu vào không lọc và đầu vào lọc thông dải trên 153 bản ghi Sleep-EDF và 500 bản ghi giữ lại (ước lượng Welch với đoạn Hann 20 s, chồng lấn 50%, lấy trung bình trên các epoch hợp lệ của từng cửa sổ đánh giá). Phổ không dùng mô hình và không dùng nhãn giai đoạn ngoài cửa sổ đánh giá (Mục bổ sung S7). Mô tả này sau đó được mở rộng theo giai đoạn tham chiếu. Với mỗi epoch hợp lệ của đầu vào lọc thông dải, độ lệch chuẩn và công suất trong dải 0.5–4 Hz được tính, và khả năng tách epoch N3 tham chiếu khỏi epoch N2 tham chiếu bằng từng đại lượng được tóm tắt bằng diện tích dưới đường cong ROC (AUC) trong từng đoàn hệ và bằng cách áp dụng lên SHHS1 ngưỡng cho độ chính xác cân bằng cao nhất trên Sleep-EDF. Phân tích này dùng giai đoạn tham chiếu nhưng không dùng mô hình hay dự đoán (Mục bổ sung S8).

## 4. Kết quả

### 4.1. Hiệu năng ngoài fold trên Sleep-EDF

**Bảng 3.** Hiệu năng kiểm tra ngoài fold trên Sleep-EDF (seed 42, gộp trên mọi fold).

| **Cấu hình** | macro-F1 | **Độ chính xác** | $\kappa$ | **F1 (N1)** |
|---|---|---|---|---|
| E0 | 0.7754 | 0.8262 | 0.7614 | 0.5009 |
| E1 | 0.7802 | 0.8315 | 0.7683 | 0.5115 |
| E2 | 0.7835 | 0.8341 | 0.7716 | 0.5180 |
| E3 | **0.7904** | **0.8363** | **0.7754** | **0.5276** |
| E4 | 0.7891 | 0.8360 | 0.7746 | 0.5270 |
| E6 | 0.7691 | 0.8230 | 0.7573 | 0.5124 |

E3 đạt điểm cao nhất ở cả bốn chỉ số tại seed 42 (Bảng 3); các so sánh bắt cặp được trình bày ở Bảng 4.

**Bảng 4.** So sánh bắt cặp xác định trước trên macro-F1 Sleep-EDF ($n = 78$ đối tượng). Hiệu chỉnh Holm áp dụng cho bốn dòng xác định trước; thống kê kiểm định dấu là kiểm tra độ vững bổ sung chưa hiệu chỉnh. E3−E0 là hậu nghiệm và nằm ngoài họ Holm.

| **So sánh** | **Δ**macro-F1 | $\mathrm{CI}_{95\%}$ | $\boldsymbol{p}_{\mathrm{Holm}}$ | **T/H/B** | $\boldsymbol{\Delta}_{\mathrm{sign}}$ | $\boldsymbol{p}_{\mathrm{sign}}$ |
|---|---|---|---|---|---|---|
| E1−E0 | 0.0048 | [−0.0009, 0.0102] | 0.1022 | 51/0/27 | +0.308 | 0.0088 |
| E2−E1 | 0.0033 | [−0.0024, 0.0088] | 0.1036 | 44/0/34 | +0.128 | 0.3082 |
| E3−E2 | 0.0070 | [0.0003, 0.0145] | 0.8989 | 37/0/41 | −0.051 | 0.7343 |
| E3−E6 | **0.0213** | **[0.0122, 0.0307]** | **0.0012** | 49/0/29 | **+0.256** | **0.0308** |
| *E3−E0 (hậu nghiệm)* | 0.0150 | [0.0057, 0.0259] | n/a | 49/0/29 | +0.256 | 0.0308 |

Trong các đối chiếu xác định trước, chỉ E3−E6 có khoảng bootstrap gộp nằm trên không cùng kết quả Wilcoxon có ý nghĩa sau Holm ($p = 0.0012$; Bảng 4; T/H/B là thắng/hòa/bại). Khoảng của E1−E0 và

E2−E1 chứa giá trị không, còn E3−E2 có khoảng gộp dương dù E3 chỉ cải thiện so với E2 ở 37 trên 78 đối tượng (Holm $p = 0.8989$), cho thấy một lợi ích gộp nhỏ chứ không phải lợi ích nhất quán theo đối tượng. Chênh lệch hậu nghiệm E3−E0 là 0.0150 phản ánh thay đổi kết hợp của kiến trúc, tiền xử lý và huấn luyện.

Chỉ số chi tiết theo lớp, ma trận nhầm lẫn Sleep-EDF và cả hai bảng độ nhạy theo seed được cung cấp ở các Bảng bổ sung S8–S11. Trên Sleep-EDF, N1 là lớp khó nhất của E3, và chênh lệch F1 E3−E6 lớn nhất nằm ở N3, +0.0628. Cả bốn chênh lệch xác định trước vẫn dương ở seed 123, nhưng chỉ E3−E6 có khoảng bootstrap hoàn toàn dương ở cả hai lần chạy; kết quả sau Holm của nó chỉ có ý nghĩa ở seed 42 và độ lớn giảm từ 0.0213 xuống 0.0102. Chiều của hiệu ứng nhất quán qua hai seed, nhưng mức hỗ trợ thống kê thì không.

### 4.2. Độ phức tạp, độ trễ và chi phí huấn luyện

**Bảng 5.** Benchmark truyền xuôi toàn quy trình trên Tesla V100 (fold 0, seed 42; lô 1, độ dài chuỗi 100). Thông lượng tính bằng epoch $s^{-1}$ và bộ nhớ cấp phát cực đại tính bằng MiB; không tính I/O và tiền xử lý.

| Mã | Tham số | Trung vị (ms) | Thông lượng | Bộ nhớ cực đại | Tăng tốc |
|---|---|---|---|---|---|
| E0 | 248 630 | 13.4315 | 7 445 | 58.81 | 1.00× |
| E1 | 640 950 | 12.5111 | 7 993 | 60.31 | 1.07× |
| E2 | 1 085 578 | 3.5750 | 27 972 | 75.54 | 3.76× |
| E3 | 1 085 578 | 3.5687 | 28 021 | 75.54 | 3.76× |
| E6 | 1 085 578 | 3.5756 | 27 967 | 75.54 | 3.76× |

Họ ResNet-1D-TCN chạy nhanh hơn 3.76× so với đối chứng CNN-BiLSTM trong benchmark truyền xuôi (Bảng 5) trong khi có số tham số gấp 4.37× và bộ nhớ cực đại cao hơn 16.73 MiB, nên cách triển khai này nhanh hơn nhưng không nhỏ hơn. E1, vẫn giữ bộ mã hóa E0, chỉ tăng tốc 1.07×; mức tăng lớn hơn đi cùng việc thay 15 nhánh CNN thực thi riêng rẽ bằng một bộ mã hóa ResNet-1D. Suy luận cả đêm trên CPU cho tỷ số tương tự: một mô hình fold chấm một đêm 932 epoch với trung vị 4.31 s ở E0 và 1.38 s ở E3 khi dùng một luồng (3.13×), và 1.75 s và 0.55 s khi dùng bốn luồng (3.18×; Bảng bổ sung S57). Một ensemble mười mô hình E3 vì vậy chấm một đêm trong khoảng 14 s trên một luồng xử lý, và cả hai quy trình đều đủ nhanh để chấm ngoại tuyến mà không cần GPU.

Khác biệt về chi phí huấn luyện còn lớn hơn nhiều so với khác biệt khi suy luận. Trong lượt chạy seed 123, huấn luyện và xác thực đủ mười fold mất 33 giờ 36 phút với E0 nhưng chỉ 3 giờ 17 phút với E3 và 2 giờ 45 phút với E2, tức nhanh hơn lần lượt 10.2× và 12.2× (Bảng 6). Như vậy, một vòng đánh giá chéo đầy đủ của quy trình ResNet-1D-TCN hoàn tất trong một buổi làm việc thay vì kéo dài hơn một ngày, giúp rút ngắn mọi vòng phát triển và kiểm tra. Phép phân tách trong bản sửa đổi A2 cho thấy chênh lệch này đến từ đâu. Mỗi fold, E0 huấn luyện 16 mạng, gồm 15 nhánh CNN và một BiLSTM, còn E3 huấn luyện một bộ mã hóa ResNet-1D và một TCN. Không nhánh CNN nào tiến gần giới hạn 1 000 epoch: dừng sớm kết thúc chúng sau trung bình 29.1 epoch, so với 19.0 epoch của các bộ mã hóa ResNet-1D của E3 (giới hạn 40). Vì vậy E0 chạy số bước tối ưu nhiều gấp 22.5× E3, trong khi mỗi bước của nó trung bình chỉ tốn 0.41 lần thời gian, vì một bước của CNN đối chứng (6.7 ms) rẻ hơn một bước của ResNet-1D (16.1 ms). Số bước nhân với thời gian đo được cho mỗi bước chiếm 59.5% thời gian thực của E0 và 66.1% của E3; phần còn lại gồm xác thực, trích đặc trưng, nạp dữ liệu và lưu checkpoint (Bảng bổ sung S53). Như vậy, tỷ số này phản ánh số mạng mà mỗi quy trình phải huấn luyện, không phải tốc độ tính toán mỗi bước, và không nên quy cho TCN hay cho hiệu quả mỗi bước của bộ mã hóa ResNet-1D.

**Bảng 6.** Thời gian thực (wall-clock) của huấn luyện và xác thực trên mười fold (seed 123; mọi cấu hình được huấn luyện tuần tự trên cùng một GPU Tesla V100). Tỷ số bằng thời gian của E0 chia cho thời gian của cấu hình. E1 dùng lại bộ mã hóa và đặc trưng đã lưu của E0, nên thời gian của nó chỉ gồm huấn luyện mô hình chuỗi. Số bước tối ưu được cộng trên mọi giai đoạn huấn luyện và mọi fold (bản sửa đổi A2).

| Mã | Mười fold | Trung bình mỗi fold | Số bước tối ưu | Nhanh hơn E0 |
|---|---|---|---|---|
| E0 | 33 giờ 36 phút | 3 giờ 22 phút | 10 692 557 | 1.0× |
| E1 (chỉ mô hình chuỗi) | 14 phút | 1 phút 26 giây | n/a | n/a |
| E2 | 2 giờ 45 phút | 16 phút 30 giây | 401 776 | 12.2× |
| E3 | 3 giờ 17 phút | 19 phút 40 giây | 474 809 | 10.2× |
| E4 | 2 giờ 56 phút | 17 phút 36 giây | 425 612 | 11.5× |
| E6 | 2 giờ 25 phút | 14 phút 28 giây | 344 928 | 13.9× |

Các phân tích biểu diễn và ngữ cảnh, gồm một thí nghiệm loại bỏ ngữ cảnh trên Sleep-EDF trong đó các nhóm đặc trưng epoch liền trước và liền sau không cho lợi ích phát hiện được ($\Delta\text{macro-F1} = 0.0010$, $\text{CI}_{95\%}$ $[-0.0046, 0.0066]$), được trình bày ở Hình bổ sung S1 và Bảng S22.

### 4.3. Đánh giá chuyển quần thể trên mẫu SHHS1 thứ nhất

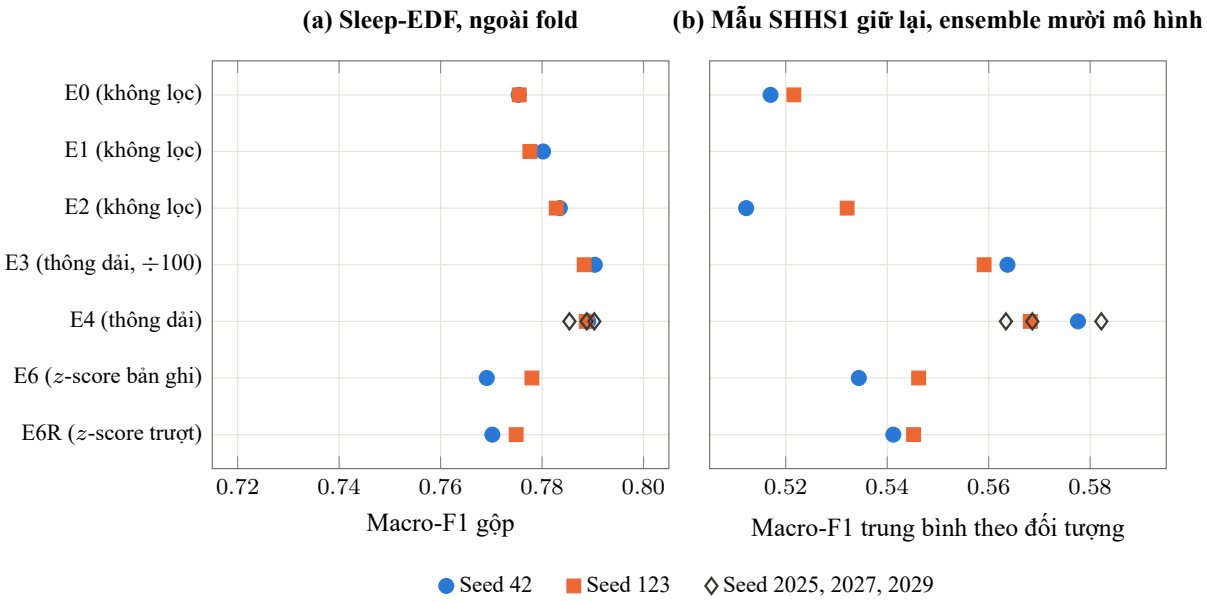
**Bảng 7.** So sánh bắt cặp chính trên mẫu SHHS1 thứ nhất (macro-F1 trung bình theo đối tượng, $n = 180$, seed 42).

| So sánh | Vai trò | $\Delta$ | $\text{CI}_{95\%}$ | $p_{\text{Holm}}$ | T/H/B | $\Delta_{\text{sign}}$ |
|---|---|---|---|---|---|---|
| E3−E0 | chính | 0.0412 | $[0.0314, 0.0512]$ | $2.65 \times 10^{-13}$ | 138/0/42 | +0.533 |
| E3−E6 | chính | 0.0274 | $[0.0182, 0.0370]$ | $1.87 \times 10^{-8}$ | 125/0/55 | +0.389 |

Trên mẫu SHHS1 thứ nhất, cả hai so sánh chính đều nghiêng về E3 (Bảng 7; hiệu năng mô tả ở Bảng bổ sung S5): E3 tốt hơn ở 138 và 125 trên 180 người tham gia, và lần lặp với seed 123 giữ nguyên chiều hiệu ứng cũng như ý nghĩa sau hiệu chỉnh Holm. So với E0, E3 còn tăng 0.0338 macro-F1 gộp, 0.0368 độ chính xác và 0.0461 $\kappa$. Trong các so sánh thứ cấp, E1−E0 nhỏ (+0.0065) và E2−E1 âm ($-0.0128$, khoảng nằm dưới không), nên thay đặc trưng C/P/N bằng đặc trưng ResNet-1D của epoch hiện tại không cải thiện khả năng chuyển quần thể khi tín hiệu không được lọc. Đối chiếu hậu nghiệm E3−E2, trong đó chỉ phép lọc đầu vào và hệ số đổi thang thay đổi, cho chênh lệch lớn nhất (+0.0475, $\text{CI}_{95\%}$ $[0.0372, 0.0579]$; E3 tốt hơn ở 147 trên 180 người tham gia). E4 (chỉ lọc thông dải) đạt điểm cao hơn E3 ở cả hai seed, lần lượt 0.0131 ($\text{CI}_{95\%}$ $[0.0111, 0.0153]$) và 0.0098 ($\text{CI}_{95\%}$ $[0.0073, 0.0125]$); Mục 4.4 liên hệ chênh lệch này với biến thiên huấn luyện (Bảng bổ sung S13–S15).

### 4.4. Đánh giá xác nhận trên mẫu SHHS1 giữ lại

Bảng 8 trình bày hiệu năng của các cấu hình trên mẫu giữ lại và Bảng 9 trình bày họ xác nhận. Hình 2 trình bày điểm số của mọi cấu hình và mọi seed huấn luyện trên cả hai đoàn hệ, còn Hình 3 đặt các đối chiếu xác nhận cạnh mức chênh lệch giữa hai lần huấn luyện của cùng một cấu hình.




**Hình 2. Điểm số của mọi cấu hình và mọi seed huấn luyện.** (a) macro-F1 gộp ngoài fold trên Sleep-EDF. (b) macro-F1 trung bình theo đối tượng của ensemble mười mô hình trên mẫu SHHS1 giữ lại ($n = 500$). Mỗi điểm là một lượt huấn luyện mười fold hoàn chỉnh; E4 có năm seed, còn E1 không được đánh giá trên mẫu giữ lại. Hai trục hoành cùng trải 0.09 nên có thể so sánh khoảng cách giữa hai ô, dù hai chỉ số được tổng hợp theo cách khác nhau. E6R và ba seed bổ sung của E4 thuộc bản sửa đổi A2. Giá trị lấy từ các Bảng bổ sung S10, S38 và S47.

**Bảng 8.** Mẫu SHHS1 giữ lại ($n = 500$; 458 409 epoch được đánh giá): hiệu năng của các cấu hình seed 42 và cặp ADAST. Khoảng là khoảng bootstrap cụm theo đối tượng cho macro-F1 trung bình theo đối tượng. Chỉ học nguồn là đối chứng tương ứng của ADAST, không phải E3.

| **Mã** | macro-F1 **theo đối tượng** ($CI_{95\%}$) | | macro-F1 **gộp** | **Độ chính xác** | $\kappa$ |
|---|---|---|---|---|---|
| E0 | 0.5170 | [0.5060, 0.5281] | 0.5612 | 0.6506 | 0.5129 |
| E2 | 0.5122 | [0.5001, 0.5241] | 0.5533 | 0.6512 | 0.5127 |
| E3 | 0.5637 | [0.5523, 0.5753] | 0.6030 | 0.6957 | 0.5710 |
| E4 | 0.5776 | [0.5662, 0.5893] | 0.6187 | 0.7103 | 0.5896 |
| E6 | 0.5344 | [0.5231, 0.5460] | 0.5711 | 0.6740 | 0.5389 |
| Chỉ học nguồn (toàn nguồn) | 0.4986 | [0.4901, 0.5072] | 0.5416 | 0.6844 | 0.5403 |
| ADAST (toàn nguồn) | 0.5415 | [0.5310, 0.5521] | 0.5852 | 0.6798 | 0.5625 |

**Bảng 9.** Họ xác nhận trên mẫu SHHS1 giữ lại (macro-F1 trung bình theo đối tượng, $n = 500$). H1–H3 dùng seed 42 và họ Holm gồm ba kiểm định; seed 123 tạo một họ Holm thứ cấp riêng. Một giả thuyết được xác nhận nếu $p_{\text{Holm}} < 0.05$ và khoảng nằm trên không. Cột cuối nhắc lại ước lượng trên mẫu SHHS1 thứ nhất.

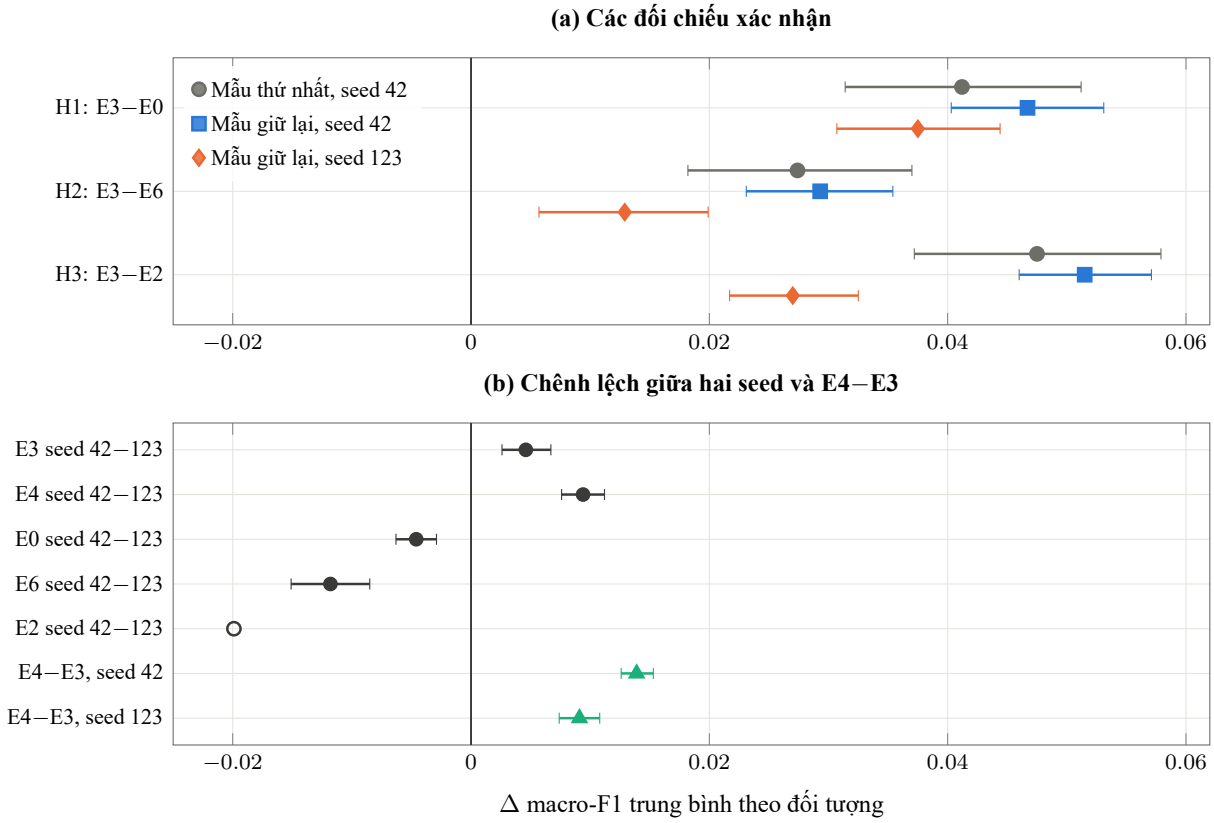
| | **So sánh** | **Δ** | $CI_{95\%}$ | $p_{\text{Holm}}$ | **T/H/B** | **Xác nhận** | **Mẫu thứ nhất** |
|---|---|---|---|---|---|---|---|
| H1 | E3−E0 | 0.0467 | [0.0403, 0.0531] | $2.0 \times 10^{-37}$ | 380/0/120 | có | 0.0412 |
| H2 | E3−E6 | 0.0293 | [0.0231, 0.0354] | $2.8 \times 10^{-22}$ | 342/0/158 | có | 0.0274 |
| H3 | E3−E2 | 0.0515 | [0.0460, 0.0571] | $1.2 \times 10^{-50}$ | 395/1/104 | có | 0.0475 |
| *Seed 123 (thứ cấp)* | | | | | | | |
| | E3−E0 | 0.0375 | [0.0307, 0.0444] | $1.1 \times 10^{-22}$ | 345/0/155 | n/a | n/a |
| | E3−E6 | 0.0129 | [0.0057, 0.0199] | $1.7 \times 10^{-5}$ | 285/0/215 | n/a | n/a |
| | E3−E2 | 0.0270 | [0.0217, 0.0325] | $1.8 \times 10^{-18}$ | 327/1/172 | n/a | n/a |

Cả ba giả thuyết xác định trước đều được xác nhận (Bảng 9, Hình 3a), và ước lượng trên mẫu giữ lại gần với ước lượng của mẫu thứ nhất. E3 tốt hơn ở 380, 342 và 395 trên 500 người tham gia; macro-F1 trung bình theo đối tượng của E3 là 0.5637 trên mẫu giữ lại, so với 0.5680 trên mẫu thứ nhất. Ở seed 123, cả ba đối chiếu vẫn dương với khoảng nằm hoàn toàn trên không. Kết quả của cả mười hai mô hình tổ hợp và các phân tích thứ cấp được trình bày ở các Bảng bổ sung S38–S43.

Trong mẫu giữ lại, 39 người có ít nhất một giai đoạn không xuất hiện trong nhãn tham chiếu, thường gặp nhất là N3 (34 người). Khi chỉ lấy trung bình macro-F1 trên các giai đoạn có mặt trong nhãn tham chiếu của từng người, ba ước lượng xác nhận là 0.0482, 0.0296 và 0.0535, và quyết định không đổi. Gộp mẫu thứ nhất và mẫu giữ lại (680 người tham gia; chỉ mang tính mô tả) cho 0.0452, 0.0288 và 0.0504.

ResNet-1D-TCN trên tín hiệu không lọc (E2) đạt điểm gần đối chứng: macro-F1 trung bình theo đối tượng 0.5122 so với 0.5170 của E0 ở seed 42, và 0.5321 so với 0.5216 ở seed 123. Vì vậy phần lớn lợi thế của E3 so với E0 gắn với thay đổi phép lọc đầu vào, không phải với thay đổi bộ mã hóa và mô hình chuỗi. So sánh E2 với E0 này mang tính mô tả và không thuộc họ xác nhận.

Biến thiên giữa các lần huấn luyện có cùng bậc độ lớn với một số đối chiếu giữa các cấu hình (Hình 3b). Hiệu macro-F1 trung bình theo đối tượng giữa seed 42 và seed 123 là $+0.0046$ ($\mathrm{CI}_{95\%}$ $[0.0026, 0.0067]$) với E3, $+0.0094$ ($[0.0076, 0.0112]$) với E4, $-0.0046$ ($[-0.0063, -0.0029]$) với E0 và $-0.0118$ ($[-0.0151, -0.0085]$) với E6; E2 không lọc, không thuộc nhóm xác định trước này, chênh $-0.0199$. Cả bốn khoảng đều không chứa giá trị không, dù hai mô hình trong mỗi cặp có cùng cấu hình: khoảng tính với mô hình cố định không phản ánh biến thiên giữa các lần huấn luyện. E4 cao hơn E3 0.0139 ($[0.0126, 0.0153]$) ở seed 42 và 0.0091 ($[0.0074, 0.0108]$) ở seed 123. Giao thức kỳ vọng E4−E3 không vượt các chênh lệch giữa hai seed; kỳ vọng này đúng ở seed 123 nhưng không đúng ở seed 42, nơi E4−E3 lớn hơn cả bốn chênh lệch giữa seed xác định trước. Với năm seed của bản sửa đổi A2 (Mục 4.5), chênh lệch giữa các seed của E4 lên tới 0.0189, nên cả hai giá trị của E4−E3 đều nằm trong biến thiên huấn luyện của E4.




**Hình 3. Các đối chiếu xác nhận so với biến thiên giữa các lần huấn luyện.** (a) Chênh lệch macro-F1 trung bình theo đối tượng của H1–H3 trên mẫu SHHS1 thứ nhất ($n$ = 180, seed 42) và trên mẫu giữ lại ($n$ = 500, seed 42 và 123). (b) Chênh lệch giữa hai seed huấn luyện của cùng một cấu hình (seed 42 trừ seed 123) và E4−E3 ở từng seed trên mẫu giữ lại; E2 không có khoảng tin cậy xác định trước nên chỉ vẽ điểm ước lượng (vòng tròn rỗng). Thanh ngang là khoảng bootstrap cụm theo đối tượng 95%; hai ô dùng cùng trục hoành. Số liệu lấy từ Bảng 9, Bảng 7 và các Bảng bổ sung S16 và S40.

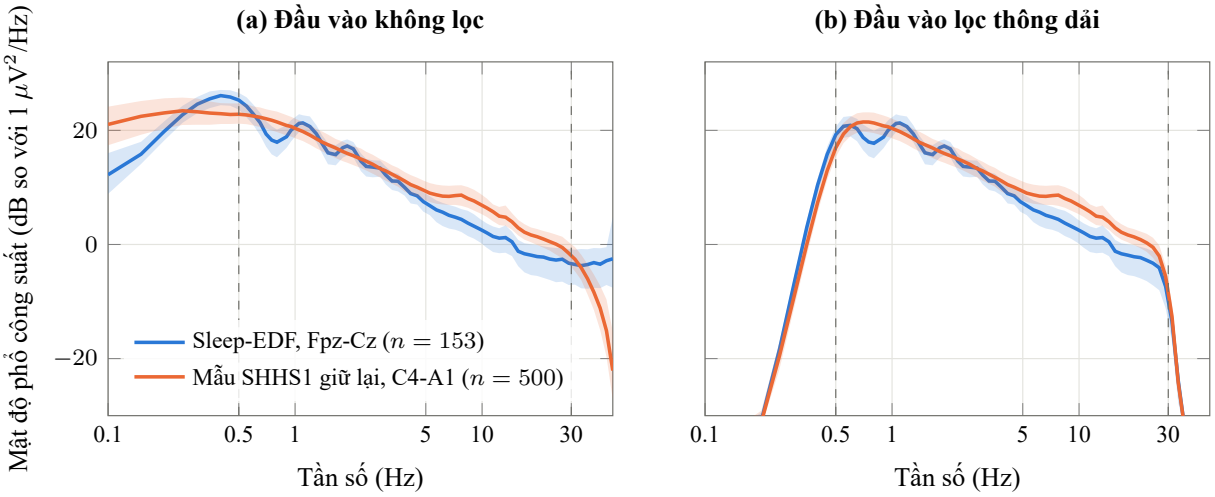
Trọng số đã huấn luyện phù hợp với tính bất biến xấp xỉ theo thang đầu vào (Bảng bổ sung S44). Với cùng seed và fold, kernel lớp đầu của E3 và E4 có độ tương tự cosine 0.909–0.974 và trung vị độ tương tự trên các tensor trọng số bộ mã hóa là 0.696–0.863, so với các giá trị từ −0.112 đến 0.012 giữa hai seed của cùng cấu hình. Phương sai tích lũy (running variance) ở lớp chuẩn hóa đầu tiên của E4 lớn hơn của E3 khoảng $10^4$ lần, đúng như hệ số 100 dự đoán, và quy tắc dừng sớm chọn epoch khác nhau cho E3 và E4 ở 8 trên 20 cặp seed-fold. Như vậy, thay đổi thang đầu vào đã bị triệt tiêu phần lớn, và E4−E3 nằm trong khoảng năm seed quan sát được của E4. Ngược lại, H1 và H3 lớn hơn mọi chênh lệch giữa seed đã báo cáo ở cả hai seed, còn H2 ở seed 123 (0.0129) gần với chênh lệch giữa seed của E4 và E6.

### 4.5. Phổ đầu vào, phạm vi chuẩn hóa và biến thiên huấn luyện

Phân tích đầu tiên dưới đây là một mô tả hậu nghiệm về đầu vào; hai phân tích còn lại thuộc bản sửa đổi thứ hai (Mục 3.10) và mang tính mô tả.

**Thành phần phổ của đầu vào.** Phổ của đầu vào cho thấy bộ lọc loại bỏ những gì (Hình 4; Mục bổ sung S7). Trong tín hiệu không lọc, trung vị 26.4% công suất của một bản ghi Sleep-EDF (khoảng tứ phân vị 21.4–33.2%) và 21.0% công suất của một bản ghi SHHS1 giữ lại (14.4–28.9%) nằm dưới 0.5 Hz, còn 3.1% và 1.1% nằm trên 30 Hz. Hai đoàn hệ khác nhau nhiều nhất ở ngoài dải thông: phổ trung vị của SHHS1 cao hơn Sleep-EDF 3.2–8.8 dB trong khoảng 0.1 đến 0.2 Hz và thấp hơn 7.7–19.6 dB ở trên 40 Hz, so với chênh lệch từ −2.5 đến +4.4 dB trong dải 0.5–30 Hz. Lọc thông dải loại bỏ thành phần ngoài dải ở cả hai đoàn hệ, để lại 98.6% và 99.4% công suất còn lại nằm trong dải thông, và không làm thay đổi chênh lệch trong dải. Như vậy, bộ lọc loại bỏ đúng các dải tần mà bản ghi không lọc của hai đoàn hệ khác nhau nhiều nhất.

**Phạm vi chuẩn hóa.** Trong cửa sổ đánh giá, trung vị độ lệch chuẩn theo bản ghi của đầu vào E6R là



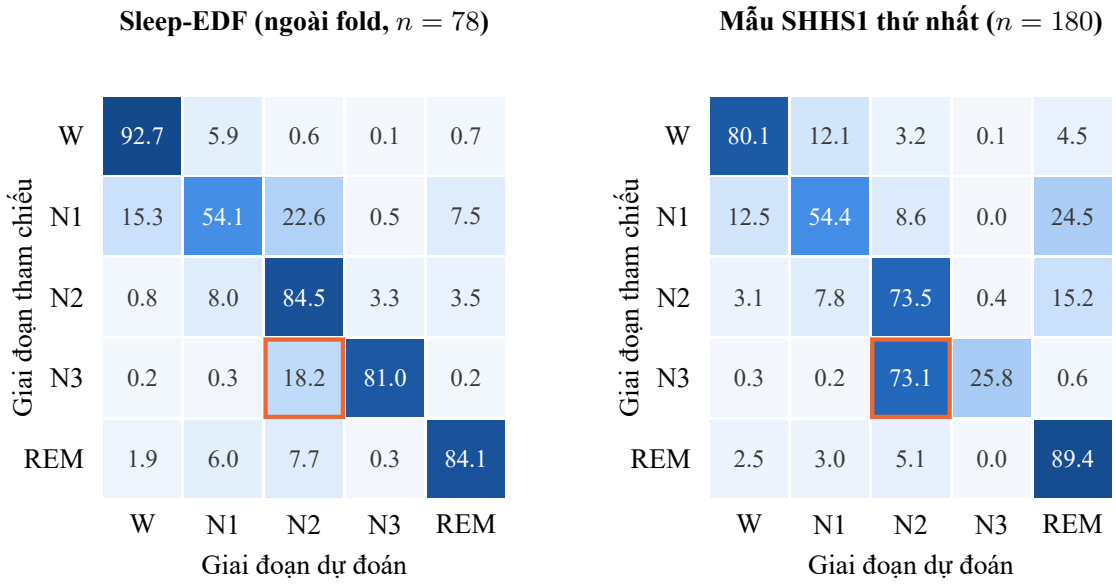

**Hình 4. Phổ công suất của đầu vào mô hình ở hai đoàn hệ.** Trung vị qua các bản ghi (đường) và khoảng tứ phân vị (vùng tô) của mật độ phổ công suất Welch trong cửa sổ đánh giá, với (a) đầu vào không lọc của E0–E2 và (b) đầu vào lọc thông dải của E4. Đường gạch đánh dấu dải thông 0.5–30 Hz. Phân tích mô tả hậu nghiệm; không dùng mô hình. Số liệu lấy từ Mục bổ sung S7.

0.987 ở Sleep-EDF và 0.993 ở mẫu giữ lại, so với 0.770 và 0.992 của E6, nên sai lệch thang của E6 đã được loại bỏ. Tác động lên khả năng chuyển quần thể thì nhỏ: E6R trừ E6 bằng 0.0068 ($CI_{95\%}$ $[0.0012, 0.0124]$) về macro-F1 trung bình theo đối tượng ở seed 42 và $-0.0010$ ($[-0.0071, 0.0051]$) ở seed 123, và E6R đạt 0.5412 và 0.5452. E4 cao hơn E6R ở cả hai seed, 0.0364 ($[0.0313, 0.0415]$) và 0.0230 ($[0.0177, 0.0282]$), và E3 cũng vậy, 0.0225 ($[0.0171, 0.0278]$) và 0.0139 ($[0.0083, 0.0194]$). Theo quy tắc đã khóa, nhận định rằng giữ biên độ đã hiệu chuẩn chuyển quần thể tốt hơn $z$-score vì vậy được giữ nguyên. Chuẩn hóa theo cửa sổ còn làm độ thu hồi N3 thấp hơn E6, chỉ còn 0.1395 và 0.1515 (chênh lệch $-0.0591$ và $-0.0503$), với tỷ lệ N3→N2 là 84.2% và 82.8%, trong khi E4 vượt E6R về độ thu hồi N3 0.1346 và 0.1059. Trên Sleep-EDF, E6R đạt macro-F1 gộp 0.7702 và 0.7749, gần E6 (0.7691 và 0.7780) và thấp hơn E4 (0.7891 và 0.7887).

**Seed huấn luyện.** Qua năm seed của E4, macro-F1 trung bình theo đối tượng trên mẫu giữ lại có trung bình 0.5720, độ lệch chuẩn 0.0077 và khoảng 0.5634–0.5822, trong khi macro-F1 gộp trên Sleep-EDF có độ lệch chuẩn 0.0018 (khoảng 0.7854–0.7903); hai độ trải này dùng cách tổng hợp khác nhau (điểm trung bình theo đối tượng của ensemble so với điểm gộp ngoài fold) nên không so sánh trực tiếp được. Chín trong mười khoảng chênh lệch giữa từng cặp seed không chứa giá trị không, và chênh lệch tuyệt đối lớn nhất là 0.0189. Cả 20 chênh lệch giữa một seed của E4 với E0 hoặc E2 ở một trong hai seed đều lớn hơn, 0.0313–0.0700, mọi khoảng đều trên 0.026, nên theo quy tắc đã khóa các đối chiếu cấu hình này vượt khoảng chênh lệch giữa các seed quan sát được của E4 (Bảng bổ sung S47–S50).

### 4.6. Lỗi chung của các mô hình và vị trí của lỗi theo thời gian

macro-F1 gộp của E3 giảm từ 0.7904 trên Sleep-EDF xuống 0.6099 trên mẫu SHHS1 thứ nhất, tức giảm 0.1805. Vì hai đoàn hệ được đánh giá theo cách khác nhau (dự đoán ngoài fold so với tổ hợp mười mô hình), chúng tôi chỉ phân tích chênh lệch này theo lớp ở mức mô tả. Trên mẫu giữ lại, chênh lệch tương ứng là 0.1875 khi dùng ensemble và 0.2107 khi chấm từng mô hình fold riêng lẻ như trên Sleep-EDF (xem bên dưới). A→B ký hiệu một epoch có nhãn tham chiếu A bị dự đoán là B. N3 chiếm phần lớn tổn thất (Hình 5): F1 N3 của E3 giảm từ 0.8085 xuống 0.4055, với precision (tỷ lệ dự đoán N3 là đúng) 0.9440 nhưng độ thu hồi chỉ 0.2582. E0 có độ thu hồi gần như giống hệt (0.2610) và tỷ lệ N3→N2 tương tự (72.3% so với 73.1%; Bảng bổ sung S6).




**Hình 5. Ma trận nhầm lẫn của E3 (seed 42) trước và sau khi chuyển quần thể.** Mỗi ô là phần trăm epoch của một giai đoạn tham chiếu (hàng) được dự đoán thành từng giai đoạn (cột); mỗi hàng cộng lại bằng 100%. Ô viền cam là lỗi N3→N2, tăng từ 18.2% trên Sleep-EDF lên 73.1% trên mẫu SHHS1 thứ nhất. Số đếm lấy từ các Bảng bổ sung S9 và S18.

Mẫu giữ lại lặp lại đúng kiểu lỗi này: tỷ lệ N3→N2 là 72.3% với E0 ($CI_{95\%}$ 70.1–74.4%), 72.7% với E3 (70.7–74.7%), 71.1% với E4 và 77.1% với E6; độ thu hồi N3 lần lượt là 0.2565, 0.2549, 0.2742 và 0.1987, còn precision N3 nằm trong khoảng 0.85–0.88, mỗi giá trị có khoảng tin cậy rộng khoảng 0.10, so với 0.90 đến 0.94 trên mẫu thứ nhất.

Trong một phép tính giả định (oracle) trên ma trận nhầm lẫn của E3 ở mẫu thứ nhất, nếu sửa đúng toàn bộ ô N3→N2 thì macro-F1 gộp sẽ tăng lên 0.7444, bù được 74.5% mức sụt giảm khi chuyển quần thể; con số tương ứng cho N2→REM, nhóm lỗi lớn thứ hai, là 0.6596 (27.5%). Các con số này dựa trên nhãn tham chiếu, không cộng dồn được và không thể đạt được trong thực tế. Độ thu hồi N3 thấp không chỉ xảy ra gần các điểm đổi nhãn tham chiếu (0.0633 với E0 và 0.0733 với E3, so với 0.6121 và 0.6326 trên Sleep-EDF) mà cả ở vùng ổn định (0.4008 và 0.3900), và $z$-score theo bản ghi cũng không khắc phục được thiếu hụt này (độ thu hồi N3 của E6 là 0.2005). Định nghĩa vùng và mọi kết quả theo lớp được trình bày ở các Bảng bổ sung S17–S21.

**Mô hình đơn và ensemble.** Trong bản sửa đổi thứ hai, từng mô hình fold cũng được chấm riêng. Các mô hình fold của cùng một tổ hợp chênh nhau tới 0.18 về macro-F1 trung bình theo đối tượng trên mẫu giữ lại, và ensemble mười mô hình vượt trung bình các mô hình đơn của nó 0.0121–0.0327 ở mọi tổ hợp, mọi khoảng đều trên không (Bảng bổ sung S51). Độ thu hồi N3 của mô hình đơn nhỉnh hơn của ensemble (với E3 seed 42, 0.2637 so với 0.2549), nên ensemble không gây ra thiếu hụt N3. Tính bằng mô hình đơn, mức sụt macro-F1 gộp từ Sleep-EDF sang mẫu giữ lại là 0.2107 và 0.2134 với E3 ở seed 42 và 123, so với 0.1875 và 0.1902 khi dùng ensemble; phép so sánh giữa hai đoàn hệ ở trên vì vậy đánh giá thấp tổn thất khi chuyển quần thể của một mô hình đơn khoảng 0.02.

### 4.7. Kết quả can thiệp

Trên mẫu SHHS1 thứ nhất, hiệu chuẩn nhiệt độ gần như không thay đổi macro-F1 trung bình theo đối tượng (0.5590 lên 0.5595), trong khi thêm hiệu chỉnh tiên nghiệm EM làm giảm còn 0.4899 (chênh lệch $-0.0696$, $CI_{95\%}$ $[-0.0793, -0.0600]$): tiên nghiệm khớp được đặt N3 gần ngưỡng sàn và tổ hợp không dự đoán epoch N3 nào (Bảng bổ sung S23). Trọng số lớp nâng độ thu hồi N3 từ 0.2345 lên 0.3225 (chênh lệch 0.0880, $CI_{95\%}$ $[0.0805, 0.0954]$) và F1 N3 từ 0.3759 lên 0.4795, nhưng giảm độ thu hồi N2 từ 0.7260 xuống 0.6728 và độ chính xác từ 0.6892 xuống 0.6663, để macro-F1 trung bình theo đối tượng gần như không đổi (chênh lệch $-0.0016$, $CI_{95\%}$ $[-0.0049, 0.0017]$); can thiệp này chỉ tác động lên bộ phân loại

chuỗi (Bảng bổ sung S24).

Ở ngân sách nhỏ, ADAST nâng độ thu hồi N3 từ 0.3195 lên 0.4269 nhưng giảm macro-F1 trung bình theo đối tượng từ 0.4949 xuống 0.4497 (chênh lệch $-0.0452$, $\mathrm{CI}_{95\%}$ $[-0.0558, -0.0347]$), không đưa ra dự đoán N1 nào và cũng làm giảm hiệu năng nguồn. Ở ngân sách toàn nguồn, hiệu ứng đảo chiều: macro-F1 trung bình theo đối tượng tăng từ 0.5010 lên 0.5455 (chênh lệch 0.0445, $\mathrm{CI}_{95\%}$ $[0.0352, 0.0539]$; chênh lệch giữa hai hiệu ứng ngân sách 0.0897, $\mathrm{CI}_{95\%}$ $[0.0767, 0.1023]$) và độ thu hồi N3 tăng từ 0.2432 lên 0.6111, trong khi độ thu hồi N1 và N2 giảm; độ thu hồi REM tăng nhưng precision REM giảm, nên F1 REM giảm từ 0.6231 xuống 0.5744. Trên dữ liệu kiểm tra ngoài fold của nguồn, macro-F1 trung bình theo đối tượng giảm từ 0.6613 xuống 0.6281. Mọi lớp, quy tắc checkpoint và ngân sách được trình bày ở các Bảng bổ sung S7, S26, S36 và S37.

Mẫu giữ lại lặp lại kết quả của ngân sách toàn nguồn. ADAST vượt đối chứng 0.0429 về macro-F1 trung bình theo đối tượng ($\mathrm{CI}_{95\%}$ $[0.0374, 0.0484]$) và nâng độ thu hồi N3 từ 0.2366 lên 0.6161, trong khi F1 N1, N2 và REM giảm 0.0190, 0.0445 và 0.0568. Tuy nhiên, xét giá trị tuyệt đối, ADAST vẫn thấp hơn các quy trình lọc thông dải zero-shot: macro-F1 trung bình theo đối tượng của nó thấp hơn E3 0.0222 ($[-0.0284, -0.0160]$) và thấp hơn E4 0.0361 ($[-0.0423, -0.0299]$). Cả hai nhánh ADAST đều dùng đầu vào của E3, nên khoảng cách này chủ yếu phản ánh kiến trúc nền của ADAST và cách huấn luyện nó, chứ không phải bản thân việc thích nghi: khi chưa thích nghi, cùng kiến trúc nền đó (đối chứng chỉ học nguồn tương ứng) đạt 0.4986, thấp hơn E3 0.0651 (Bảng 8), và việc thích nghi bù lại được 0.0429 trong khoảng chênh đó.

**Cỡ mẫu của ước lượng tiên nghiệm EM.** Bản sửa đổi thứ hai lặp lại hiệu chỉnh tiên nghiệm trên mẫu giữ lại với tiên nghiệm ước lượng từ các mẫu có cỡ tăng dần. Ở đó, tiên nghiệm đã lưu ước lượng từ năm bản ghi thích nghi một lần nữa đặt N3 ở mức sàn, và ensemble sau hiệu chỉnh không dự đoán N3 nào. Ước lượng tiên nghiệm từ mẫu lớn hơn không giải quyết được vấn đề: với 20 000 epoch của mẫu AdaBN hoặc với cả 500 bản ghi, tiên nghiệm N3 trung bình qua các fold là 0.030 và 0.029, chỉ khoảng một phần năm tỷ lệ N3 tham chiếu 0.134, và độ thu hồi N3 giảm từ 0.240 khi không hiệu chỉnh xuống 0.134 và 0.129, với macro-F1 trung bình theo đối tượng 0.517 và 0.516 so với 0.559. Các tập con ngẫu nhiên gồm 5, 20 và 100 bản ghi hội tụ về cùng một tiên nghiệm (trung vị 0.028–0.029) trong khi độ trải thu hẹp dần (Bảng bổ sung S52). Theo quy tắc đã khóa, sự sụp đổ vì vậy được quy cho việc giả định dịch chuyển nhãn không đúng khi có dịch chuyển đặc trưng, không phải do mẫu thích nghi quá nhỏ.

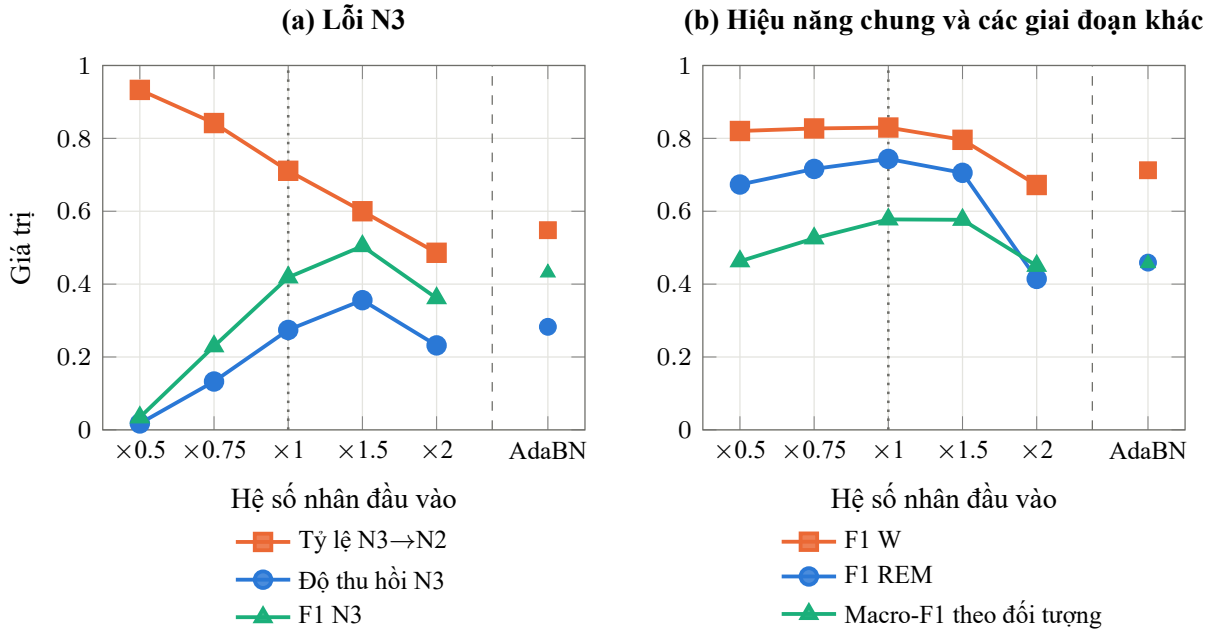
### 4.8. Độ nhạy theo biên độ và thích nghi chuẩn hóa theo lô

Tín hiệu SHHS1 sau lọc thông dải không nhỏ hơn tín hiệu Sleep-EDF: độ lệch chuẩn theo bản ghi có trung vị 16.50 $\mu$V, khoảng tứ phân vị 13.72–21.26, trên mẫu giữ lại và 14.36 $\mu$V, khoảng tứ phân vị 11.63–16.82, trên Sleep-EDF.

Các epoch N3 tham chiếu cũng không mất độ tương phản biên độ so với N2 (Mục bổ sung S8). Trung vị theo bản ghi của độ lệch chuẩn epoch N3 là 20.8 $\mu$V (khoảng tứ phân vị 16.3–23.3) trên Sleep-EDF và 18.8 $\mu$V (16.9–21.1) trên mẫu giữ lại, so với 11.5 $\mu$V (9.4–13.7) và 13.0 $\mu$V (11.7–14.7) ở N2. Trong cùng một bản ghi, epoch N3 có độ lệch chuẩn gấp 1.62 (1.44–1.80) và 1.43 (1.34–1.54) lần epoch N2 và có công suất trong dải 0.5–4 Hz cao hơn 4.9 và 4.2 dB. Độ tương phản vì vậy nhỏ hơn ở SHHS1 nhưng vẫn lớn. Chỉ riêng độ lệch chuẩn của epoch đã tách epoch N3 tham chiếu khỏi epoch N2 tham chiếu với AUC 0.940 trên Sleep-EDF và 0.892 trên mẫu giữ lại, và ngưỡng cho độ chính xác cân bằng cao nhất trên Sleep-EDF (16.5 $\mu$V) đặt 84.0% trong số 61,523 epoch N3 của mẫu giữ lại ở phía trên và 82.2% epoch N2 của mẫu giữ lại ở phía dưới (77.4% và 88.8% với công suất 0.5–4 Hz). Mô tả hai lớp này không phải một bộ phân loại năm giai đoạn, nhưng nó cho thấy khác biệt biên độ giữa N3 và N2 mà một ngưỡng của Sleep-EDF dựa vào vẫn có mặt ở phần lớn epoch N3 của SHHS1, trong khi các mô hình chỉ nhận ra khoảng một phần tư số epoch đó.

Dù vậy, biên độ đầu vào ảnh hưởng mạnh đến việc phân tách N2 với N3 (Hình 6; số liệu đầy đủ ở các Bảng bổ sung S45 và S46). Khi hệ số đầu vào tăng từ 0.5 lên 2, tỷ lệ epoch N3 tham chiếu bị dự đoán thành N2 giảm đơn điệu từ 93.3% xuống 48.6%. Tuy nhiên, độ thu hồi N3 chỉ tăng đến hệ số 1.5, từ 0.2742 lên 0.3559, chênh 0.0817 với $\mathrm{CI}_{95\%}$ $[0.0665, 0.0974]$. Ở hệ số 2, nó giảm còn 0.2318 vì khi đó 28.2% epoch N3 tham chiếu bị phân loại thành thức, và độ thu hồi REM giảm từ 0.876 xuống 0.276. Ở hệ số 1.5, mức

tăng F1 N3 0.0859, $CI_{95\%}$ $[0.0697, 0.1020]$, bị bù trừ bởi F1 N1, REM và thức thấp hơn, và macro-F1 trung bình theo đối tượng không đổi ($-0.0011$, $CI_{95\%}$ $[-0.0099, 0.0075]$). Các hệ số nhỏ hơn 1 làm độ thu hồi N3 giảm còn 0.1327 và 0.0176. Đáp ứng vì vậy đơn điệu với tỷ lệ N3→N2 nhưng không đơn điệu với độ thu hồi N3; theo tiêu chí xác định trước, điều này bác bỏ cách giải thích bỏ sót N3 chỉ bằng biên độ.




**Hình 6. Độ nhạy theo biên độ và AdaBN của E4 (seed 42) trên mẫu SHHS1 giữ lại ($n$ = 500).** Đầu vào đã lọc được nhân với 0.5–2 trong khi bộ mã hóa giữ nguyên thống kê chuẩn hóa theo lô đã lưu; ×1 (đường chấm) là E4 không sửa đổi. AdaBN thay thống kê chuẩn hóa theo lô bằng thống kê của SHHS1 không nhãn và được vẽ tách riêng bên phải đường gạch. (a) Tỷ lệ N3→N2 giảm đơn điệu khi tăng biên độ, nhưng độ thu hồi N3 chỉ tăng đến ×1.5. (b) Macro-F1 trung bình theo đối tượng không cao hơn E4 ở bất kỳ hệ số nào, và F1 của thức và REM giảm mạnh ở ×2 và với AdaBN. Các chỉ số theo lớp được gộp trên epoch; phân tích mô tả, không kiểm định giả thuyết. Số liệu lấy từ Bảng bổ sung S45.

AdaBN làm macro-F1 trung bình theo đối tượng thay đổi $-0.1206$, $CI_{95\%}$ $[-0.1295, -0.1116]$, mà không thay đổi độ thu hồi N3 một cách phát hiện được (chênh lệch 0.0086, $CI_{95\%}$ $[-0.0052, 0.0222]$). Precision lớp thức giảm từ 0.853 xuống 0.589 và độ thu hồi REM từ 0.876 xuống 0.312. AdaBN cũng thấp hơn ADAST 0.0844 với $CI_{95\%}$ $[0.0759, 0.0929]$, và thấp hơn đối chứng chỉ học nguồn tương ứng của ADAST 0.0416 với $CI_{95\%}$ $[0.0333, 0.0498]$. Mục bổ sung S5 trình bày mọi lớp và đối chiếu.

## 5. Thảo luận

### 5.1. Những gì các so sánh quy trình xác lập

Đánh giá xác nhận ủng hộ ba kết luận về các quy trình được đánh giá. Thứ nhất, cấu hình ResNet-1D-TCN trên đầu vào lọc thông dải chuyển sang SHHS1 tốt hơn đối chứng CNN-BiLSTM, và lợi thế này, quan sát lần đầu trên 180 người tham gia, đã được xác nhận trên 500 người tham gia mà dữ liệu chưa ảnh hưởng đến bất kỳ phân tích nào. Nó cũng rẻ hơn nhiều khi phát triển và khi sử dụng: huấn luyện và xác thực mười fold chỉ mất khoảng 3.3 giờ thay vì 33.6 giờ trên cùng một GPU, và suy luận nhanh hơn 3.76× trong benchmark GPU và 3.1× khi chấm cả đêm trên CPU. Với một quy trình phải huấn luyện lại cho mỗi biến thể tiền xử lý, mỗi seed và mỗi fold, việc giảm thời gian huấn luyện là một ưu điểm thực tế. Nó có được vì đối chứng huấn luyện 15 mạng mã hóa mỗi fold, mỗi mạng dừng sớm sau khoảng 30 epoch, nên cần số bước tối ưu nhiều gấp 22.5×, chứ không phải vì một bước của ResNet-1D rẻ hơn; thực tế một bước của CNN đối chứng còn tốn ít thời gian hơn. Tỷ số này vì vậy mô tả hai quy trình như đã định nghĩa, không phải hiệu quả mỗi bước của kiến trúc.

Thứ hai, lọc thông dải đóng góp phần lớn lợi thế này. Cùng mô hình trên đầu vào không lọc đạt kết quả gần đối chứng trên mẫu giữ lại, và trên mẫu thứ nhất, cả việc thay mô hình chuỗi (E1−E0) lẫn thay đặc trưng/ngữ cảnh (E2−E1) đều không tạo lợi ích tương đương. Cách lọc tín hiệu vì vậy là một phần đáng kể quyết định khả năng chuyển quần thể của các mô hình này, không phải chi tiết triển khai.

Thứ ba, giữ biên độ đã hiệu chuẩn (E3) chuyển quần thể tốt hơn $z$-score theo bản ghi (E6). Vì thống kê của E6 trải trên khoảng 23 giờ bản ghi phần lớn ban ngày ở Sleep-EDF nhưng chỉ đêm ngủ ở SHHS1, hai đoàn hệ đến E6 ở thang tương đối khác nhau, nên riêng E6 không phải phép kiểm tra sạch về chuẩn hóa. Khớp khoảng thời gian bằng cửa sổ 90 phút (E6R) loại bỏ sai lệch này nhưng hầu như không thay đổi khả năng chuyển quần thể, và cả hai cấu hình lọc thông dải vẫn cao hơn E6R ở cả hai seed. Thiếu hụt của $z$-score vì vậy không bắt nguồn từ khoảng thời gian bị lệch; độ thu hồi N3 thấp hơn của E6R gợi ý rằng việc loại bỏ biên độ tuyệt đối làm mất thông tin mà mô hình dùng để nhận ra N3. E6R cũng loại bỏ các thay đổi biên độ chậm hơn cửa sổ của nó, nên phép so sánh này chỉ áp dụng cho hai dạng $z$-score này, không cho mọi cách chuẩn hóa có thể có.

Đây là các so sánh giữa cấu hình hoàn chỉnh, gồm cả thiết lập huấn luyện. Các đối chiếu đã xác nhận xác lập tác động của bước lọc lên khả năng chuyển quần thể, và phổ đầu vào chỉ ra nơi tác động này có thể phát sinh: bản ghi không lọc của hai đoàn hệ khác nhau nhiều nhất ở dưới 0.5 Hz và trên 30 Hz, đúng các dải mà bộ lọc loại bỏ, trong khi phổ trong dải của chúng chỉ lệch nhau vài decibel dù có lọc hay không. Các so sánh áp dụng cho toàn bộ bộ lọc 0.5–30 Hz và không tách riêng hai biên của nó.

### 5.2. Biến thiên huấn luyện và đối chiếu E3−E4

Trên mẫu giữ lại, hai seed huấn luyện của cùng một cấu hình chênh nhau 0.005 đến 0.012 về macro-F1 trung bình theo đối tượng ở bốn cấu hình xác định trước và 0.020 ở E2, và cả bốn khoảng giữa seed xác định trước đều không chứa giá trị không. Năm seed của E4 trải trên 0.019 (độ lệch chuẩn 0.0077), và chín trong mười khoảng chênh lệch từng cặp không chứa giá trị không. Các khoảng này phản ánh độ bất định do lấy mẫu người tham gia với các mô hình đã huấn luyện, không bao gồm biến thiên khi huấn luyện mô hình mới, nên một chênh lệch được ước lượng chính xác giữa hai mô hình đã huấn luyện vẫn có thể chỉ ngang mức chênh lệch giữa các seed huấn luyện.

E4−E3 là một ví dụ. Hai biến thể khác nhau ở một hệ số thang đầu vào cố định mà chuẩn hóa theo lô triệt tiêu phần lớn, và checkpoint của chúng giống nhau hơn nhiều so với mô hình huấn luyện bằng seed khác; tuy vậy, $\varepsilon$ hữu hạn, cách khởi tạo thống kê tích lũy và độ chính xác số vẫn khiến quá trình huấn luyện của chúng tách ra. Chênh lệch macro-F1 trung bình theo đối tượng trên SHHS1 của chúng, 0.009–0.014, nằm trong khoảng năm seed của E4. H2 ở seed 123 (0.0129) cũng tương đương một số chênh lệch giữa seed, nên ý nghĩa thống kê theo người tham gia của nó cần được đọc cùng với độ nhạy trước việc huấn luyện lại.

Mọi chênh lệch giữa một seed của E4 với E0 hoặc E2 (0.031–0.070) đều vượt chênh lệch lớn nhất giữa các seed của E4, nên lợi thế của quy trình lọc thông dải so với các cấu hình này nhất quán qua các seed đã đánh giá, dù năm và hai seed chưa mô tả được toàn bộ phân phối của tác động huấn luyện lại. Báo cáo độ trải huấn luyện bên cạnh khoảng tin cậy theo người tham gia giúp thể hiện rõ cả hai nguồn bất định.

Trong sử dụng thực tế, chúng tôi khuyến nghị E4 chỉ lọc thông dải như phương án đơn giản hơn trong các cấu hình đã đánh giá: bước cắt không bao giờ kích hoạt trên dữ liệu này, và E4 chuyển quần thể tốt mà không cần bước đổi thang cố định. E3 vẫn là tham chiếu cho các giả thuyết xác nhận vì giao thức đã cố định nó trước khi xử lý dữ liệu giữ lại; các phân tích E4 và seed hỗ trợ, nhưng không thay thế, các đối chiếu đó.

### 5.3. Bỏ sót N3 vẫn tồn tại bên cạnh cải thiện tổng hợp

Dù E3 có lợi thế tổng thể, phân tích theo lớp cho thấy một lỗi chung của mọi mô hình. Cả E0 và E3 đều phân loại hơn 72% epoch N3 tham chiếu thành N2 trên cả hai mẫu SHHS1, với độ thu hồi N3 khoảng 0.26 dù precision trên 0.85; E4 (chỉ lọc thông dải) và E6 ($z$-score theo bản ghi) cũng mắc cùng kiểu lỗi. Phép tính oracle cho thấy N3→N2 là nguồn tổn thất lớn nhất của E3, và phân tích vùng ranh giới cho thấy thiếu hụt này không chỉ nằm gần các điểm đổi nhãn tham chiếu mà còn xuất hiện cả trong các vùng N3 ổn định. Như vậy, dù chuyển quần thể tốt hơn về tổng thể, E3 vẫn giữ nguyên lỗi lớn nhất ở cấp giai đoạn. Thiếu hụt này không đặc thù cho cách triển khai hiện tại: các mô hình ZleepAnlystNet gốc huấn luyện trên Sleep-EDF Fpz-Cz chỉ đạt F1 N3 0.43 trên 200 bản ghi SHHS từ kênh C3-A2, một chuyển đạo khác với chuyển đạo

dùng ở đây [2].

Hai đoàn hệ khác nhau cùng lúc về chuyển đạo EEG, quần thể, điều kiện ghi đo và cách chấm điểm. Cấu trúc không gian của sóng chậm và tiêu chí chấm N3 dựa trên biên độ là lý do để khảo sát các khác biệt này [31, 34]. Khảo sát quét biên độ kiểm tra trực tiếp một trong các yếu tố đó. Tín hiệu SHHS1 đã lọc không nhỏ hơn tín hiệu Sleep-EDF, nhưng quyết định giữa N2 và N3 của mô hình phụ thuộc mạnh vào biên độ đầu vào: khuếch đại đầu vào chuyển các epoch N3 tham chiếu từ dự đoán N2 sang N3 và, khi vượt hệ số 1.5, sang thức. Hành vi này phù hợp với một ranh giới quyết định dựa vào biên độ sóng chậm, tương tự các quy tắc chấm điểm. Tuy nhiên, không hệ số đơn lẻ nào khôi phục được N3 mà không làm suy giảm các giai đoạn khác, và hệ số thuận lợi nhất vẫn để 60% epoch N3 bị phân loại thành N2. Một khác biệt biên độ toàn cục vì vậy không đủ để giải thích. Việc sóng chậm mất biên độ ở C4-A1 cũng không đủ: với một ngưỡng chọn trên Sleep-EDF, chỉ riêng biên độ epoch đã đặt 84% epoch N3 của SHHS1 về phía N3, hơn ba lần độ thu hồi N3 của các mô hình đã huấn luyện. Tín hiệu biên độ phân biệt N3 với N2 vì vậy vẫn có trong tín hiệu đích, và các mô hình không dùng nó theo cách một ngưỡng cố định sẽ dùng. Các mô hình dựa vào đặc tính nào khác của N3 trên Sleep-EDF, và khác biệt giữa những người chấm đóng góp đến đâu, nằm ngoài những gì thiết kế hiện tại tách được.

Các can thiệp tác động lên lỗi N3 theo những cách khác nhau. Hiệu chỉnh tiên nghiệm EM làm mất hẳn dự đoán N3. Điều này không phải do tiên nghiệm chỉ được ước lượng từ năm bản ghi: với tiên nghiệm từ cả 500 bản ghi giữ lại, EM vẫn ước lượng tỷ lệ N3 là 0.029 so với 0.134 và làm giảm độ thu hồi N3. Vì mô hình bỏ sót N3 sau khi chuyển quần thể, đầu ra của nó đánh giá thấp N3, và EM, vốn giả định hai đoàn hệ chỉ khác nhau về tỷ lệ lớp, truyền sai lệch này vào tiên nghiệm; khi có dịch chuyển đặc trưng, giả định dịch chuyển nhãn không còn đúng. Trọng số lớp nâng độ thu hồi N3 nhưng phải đánh đổi độ thu hồi N2 và độ chính xác. Hiệu ứng của ADAST đổi dấu giữa hai ngân sách học; với huấn luyện toàn nguồn, nó tăng độ thu hồi N3 hơn gấp đôi và vượt đối chứng tương ứng trên cả hai mẫu SHHS1, nhưng làm giảm F1 N1, N2 và REM cùng hiệu năng trên đoàn hệ nguồn. ADAST được đánh giá đúng như bản đã công bố, với kiến trúc nền của chính nó, nên tác động của nó là phần tăng so với đối chứng tương ứng; điểm tuyệt đối thấp hơn E3 và E4 zero-shot phản ánh khác biệt về kiến trúc nền và không được diễn giải là tác động của việc thích nghi. AdaBN, áp dụng trực tiếp lên các mô hình E4, không cải thiện độ thu hồi N3 và làm giảm hiệu năng tổng hợp do dịch chuyển ranh giới của thức và REM. Như vậy, thích nghi ở cấp đoàn hệ hoặc không tác động đến lỗi N3, hoặc chỉ giảm được nó bằng cách hy sinh các giai đoạn khác. Việc hiệu ứng đổi dấu giữa hai ngân sách cũng cho thấy cần báo cáo ngân sách học khi so sánh với một phương pháp thích nghi miền không giám sát; còn việc độ thu hồi REM tăng mà F1 REM không tăng cho thấy mọi cải thiện về độ thu hồi cần được xem cùng với precision.

### 5.4. Vị trí của nghiên cứu và giới hạn tổng quát hóa

Nghiên cứu này kết hợp các so sánh bắt cặp giữa các quy trình, chi phí tính toán, phân tích lỗi khi chuyển quần thể và một đánh giá xác nhận trên những người tham gia giữ lại. Nó bổ sung cho các công trình về biểu diễn đầu vào, quy trình truyền thống và học sâu, và huấn luyện đa đoàn hệ [14, 15, 17, 18]. E0 là bản tái triển khai thiết kế ZleepAnlystNet theo giao thức đã nêu và đạt điểm thấp hơn 0.0072 so với macro-F1 Sleep-EDF đã công bố của thiết kế đó. Trên Sleep-EDF, các cấu hình lọc thông dải nằm trong khoảng kết quả đơn kênh đã công bố (Bảng 10); vì cấu trúc fold, cách chia tập xác thực, cách cắt đoạn thức và cách chọn mô hình khác nhau giữa các nghiên cứu, bảng này chỉ định vị các quy trình trong bài chứ không phải một bảng xếp hạng. Các so sánh chính đánh giá khả năng chuyển quần thể không cập nhật trọng số. ADAST đánh giá cập nhật trọng số trên miền đích so với một đối chứng chỉ học nguồn tương ứng, còn AdaBN đánh giá thống kê chuẩn hóa trên miền đích không cập nhật trọng số.

Phạm vi của các phát hiện như sau. Nghiên cứu đánh giá việc chuyển từ một đoàn hệ nguồn sang một đoàn hệ đích; mẫu giữ lại gồm những người tham gia mới nhưng vẫn thuộc nghiên cứu SHHS1, cùng cấu hình điện cực và quy trình chấm điểm, nên nó xác nhận các phát hiện trong phạm vi SHHS1. Giao thức xác nhận được lưu trên kho mã công khai của tác giả, và dấu thời gian của máy chủ GitHub xác lập việc nó có trước phân tích. Các thí nghiệm can thiệp được thiết kế sau khi đã khảo sát lỗi của mẫu SHHS1 thứ nhất, còn phân tích biên độ, AdaBN và bản sửa đổi thứ hai được xác định sau kết quả xác nhận; các phân tích này mang tính mô tả. Năm seed mô tả độ trải của biến thiên huấn luyện chứ không phải đuôi phân phối của

**Bảng 10.** Kết quả đơn kênh đã công bố trên các bản ghi cassette Sleep-EDF Expanded gồm 78 đối tượng (Fpz-Cz) và các cấu hình trong bài ở seed 42. Giá trị đã công bố là của các nghiên cứu gốc, theo tổng hợp trong [12]; giá trị của ZleepAnlystNet lấy từ [2]. Giao thức đánh giá khác nhau giữa các nghiên cứu.

| **Mô hình** | **Độ chính xác (%)** | macro-F1 **(%)** | $\kappa$ |
|---|---|---|---|
| SleepEEGNet [41] | 80.0 | 73.6 | 0.73 |
| SleepTransformer [7] | 81.4 | 74.3 | 0.743 |
| SeqSleepNet [8] | 82.6 | 76.4 | 0.760 |
| TinySleepNet [9] | 83.1 | 78.1 | 0.77 |
| XSleepNet [10] | 84.0 | 77.9 | 0.778 |
| ZleepAnlystNet [2] | 84.1 | 78.3 | 0.779 |
| SleePyCo [12] | 84.6 | 79.0 | 0.787 |
| E0 (CNN-BiLSTM, không lọc) | 82.6 | 77.5 | 0.761 |
| E3 (ResNet-1D-TCN, lọc thông dải, đổi thang cố định) | 83.6 | 79.0 | 0.775 |
| E4 (ResNet-1D-TCN, chỉ lọc thông dải) | 83.6 | 78.9 | 0.775 |

nó. Sleep-EDF được chấm bằng dự đoán ngoài fold còn SHHS1 bằng ensemble mười mô hình, nên phép so sánh giữa hai đoàn hệ kết hợp khác biệt về đoàn hệ và về quy trình đánh giá, trong đó phần do ensemble khoảng 0.02. Các mô hình dùng ngữ cảnh tương lai, nên thời gian truyền xuôi mô tả xử lý ngoại tuyến. Kết quả theo lớp được gộp trên người tham gia, không phân tích phân tầng theo giới hoặc tuổi. Đánh giá trên các đoàn hệ, cấu hình điện cực và nhóm con khác sẽ cho thấy tác động của phép lọc và mô hình lỗi N3 có tổng quát hóa hay không.

## 6. Kết luận

Theo một giao thức chung, quy trình ResNet-1D-TCN trên EEG lọc thông dải chạy nhanh hơn ba đến bốn lần so với đối chứng CNN-BiLSTM, chỉ cần khoảng một phần mười thời gian huấn luyện vì mỗi fold chỉ huấn luyện hai mạng thay vì mười sáu, và chuyển từ Sleep-EDF sang SHHS1 tốt hơn. Lợi thế của nó, quan sát lần đầu trên 180 người tham gia, đã được xác nhận trên 500 người tham gia giữ lại ngoài quá trình phát triển: macro-F1 trung bình theo đối tượng cải thiện 0.0467 so với đối chứng, 0.0293 so với $z$-score theo bản ghi và 0.0515 so với cùng mô hình trên đầu vào không lọc, và qua năm seed của biến thể chỉ lọc thông dải và hai seed của mỗi cấu hình so sánh, các đối chiếu của nó với đối chứng và với mô hình không lọc vượt khoảng chênh lệch giữa các seed quan sát được. Lọc thông dải đóng góp phần lớn lợi ích khi chuyển quần thể và loại bỏ các dải tần mà bản ghi không lọc của hai đoàn hệ khác nhau nhiều nhất, còn $z$-score vẫn kém hơn khi thống kê của nó bao phủ cùng một khoảng thời gian ở hai đoàn hệ. Vì bước cắt không bao giờ kích hoạt và chuẩn hóa theo lô triệt tiêu phần lớn một hệ số thang hằng số, chỉ lọc thông dải là dạng đơn giản hơn của quy trình. Mọi quy trình zero-shot đều phân loại phần lớn epoch N3 thành N2. Quyết định này phụ thuộc mạnh vào biên độ đầu vào, dù phần lớn epoch N3 của SHHS1 vẫn tách được khỏi N2 bằng một ngưỡng biên độ chọn trên Sleep-EDF, và không biện pháp nào trong số đổi thang, hiệu chỉnh tiên nghiệm, trọng số lớp, thích nghi chuẩn hóa theo lô và thích nghi miền đối kháng giảm được lỗi này mà không làm giảm hiệu năng ở các giai đoạn khác. Vì vậy, khi so sánh các quy trình phân giai đoạn giấc ngủ, cần báo cáo chi phí tính toán, lỗi theo từng giai đoạn và biến thiên giữa các lần huấn luyện, đồng thời xác nhận kết quả trên dữ liệu không tham gia vào quá trình đưa ra các so sánh đó.

### Khả năng tái lập và truy cập dữ liệu

Mã nguồn, giao thức, phân hoạch dữ liệu và các phân tích tổng hợp có trong kho dự án tại `https://github.com/quanuiter/SleepTCN`. Sleep-EDF Expanded được cung cấp qua PhysioNet (`https://physionet.org/content/sleep-edfx/1.0.0/`); quyền truy cập SHHS và điều kiện sử dụng do NSRR quản lý (`https://sleepdata.org/datasets/shhs`). Vì quyền truy cập bản ghi nguồn do nhà cung cấp dữ liệu kiểm soát, kho mã và gói bản thảo không chứa bản ghi hay dự đoán SHHS cấp người tham gia.

Giao thức xác nhận, chương trình phân tích và các bản sửa đổi A1 và A2 đều được commit lên kho mã trước khi chạy; mã commit và một dấu thời gian do máy chủ GitHub ghi, độc lập với siêu dữ liệu commit của tác giả, được liệt kê ở các Mục bổ sung S3, S5 và S6. Người tham gia giữ lại được chọn bằng một phép xếp hạng băm có thể tái tạo từ danh sách người tham gia NSRR, và các bản kê suy luận ghi giá trị SHA-256 của giao thức, đầu vào đã tiền xử lý và checkpoint mô hình. Chi tiết đối chiếu nguồn gốc của mẫu SHHS1 thứ nhất có trong tài liệu bổ sung và danh mục hiện vật của kho mã.

**Đạo đức nghiên cứu**

Nghiên cứu này là phân tích thứ cấp trên dữ liệu kho lưu trữ đã khử định danh; không tuyển thêm người tham gia. Quyền truy cập dữ liệu SHHS được cấp qua National Sleep Research Resource theo thỏa thuận sử dụng dữ liệu của tổ chức này. Phân tích thứ cấp trên dữ liệu kho đã khử định danh này không cần phê duyệt đạo đức bổ sung.

**Tài trợ và lời cảm ơn**

Nghiên cứu này được hỗ trợ bởi Quỹ Hỗ trợ Nghiên cứu Khoa học của Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh. Sleep Heart Health Study (SHHS) được hỗ trợ bởi các thỏa thuận hợp tác của National Heart, Lung, and Blood Institute: U01HL53916 (University of California, Davis), U01HL53931 (New York University), U01HL53934 (University of Minnesota), U01HL53937 và U01HL64360 (Johns Hopkins University), U01HL53938 (University of Arizona), U01HL53940 (University of Washington), U01HL53941 (Boston University) và U01HL63463 (Case Western Reserve University). National Sleep Research Resource được hỗ trợ bởi National Heart, Lung, and Blood Institute (R24 HL114473, 75N92019R002).

**Tuyên bố đóng góp của tác giả theo CRediT**

Ngô Nhật Quân: Hình thành ý tưởng, Phương pháp luận, Phần mềm, Quản lý dữ liệu, Phân tích chính thức, Thực hiện nghiên cứu, Trực quan hóa, Viết bản thảo đầu tiên, Rà soát và biên tập bản thảo. Phạm Thái Sơn: Kiểm chứng, Thực hiện nghiên cứu, Trực quan hóa, Rà soát và biên tập bản thảo. Tri Nguyen Ho Duy: Hướng dẫn nghiên cứu, Rà soát và biên tập bản thảo. Tri Nguyen: Hướng dẫn nghiên cứu, Rà soát và biên tập bản thảo.

**Tuyên bố xung đột lợi ích**

Các tác giả tuyên bố không có xung đột lợi ích.

**Tuyên bố về AI tạo sinh và công nghệ hỗ trợ bằng AI**

Trong quá trình thực hiện công trình, các tác giả đã sử dụng OpenAI Codex và Anthropic Claude. OpenAI Codex hỗ trợ biên tập ngôn ngữ, tổ chức bản thảo, kiểm tra tính nhất quán giữa mã nguồn và kết quả, vẽ biểu đồ có thể tái lập, chuẩn bị sơ đồ thiết kế nghiên cứu dạng vector, và triển khai các chương trình phân tích, suy luận và huấn luyện cùng các kiểm thử xác minh. Anthropic Claude hỗ trợ rà soát mã, soạn giao thức xác nhận trên mẫu giữ lại, triển khai các chương trình tiền xử lý, suy luận và phân tích cho mẫu giữ lại, các phân tích của bản sửa đổi, phân tích phổ, phân tích theo giai đoạn và đo thời gian trên CPU cùng kiểm thử, viết mã vẽ Hình 2–6 từ số liệu đã khóa, và biên tập ngôn ngữ bản thảo. Mọi kết quả số được các chương trình này tính từ bộ dữ liệu đã ghi và checkpoint mô hình; không kết quả nào do mô hình ngôn ngữ cung cấp. Sau khi dùng các công cụ này, các tác giả đã rà soát và chỉnh sửa phần triển khai, thiết kế thực nghiệm, kết quả và văn bản khi cần và chịu hoàn toàn trách nhiệm về nội dung công bố.

## Tài liệu tham khảo

[1] R. S. Rosenberg and S. Van Hout, “The American Academy of Sleep Medicine inter-scorer reliability program: sleep stage scoring,” *Journal of Clinical Sleep Medicine*, vol. 9, no. 1, pp. 81–87, 2013. doi: https://doi.org/10.5664/jcsm.2350.

[2] N. Jirakittayakorn, Y. Wongsawat, and S. Mitrirattanakul, “ZleepAnlystNet: a novel deep learning model for automatic sleep stage scoring based on single-channel raw EEG data using separating training,” *Scientific Reports*, vol. 14, no. 1, Art. no. 9859, 2024. doi: https://doi.org/10.1038/s41598-024-60796-y.

[3] S. Bai, J. Z. Kolter, and V. Koltun, "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling," *arXiv preprint arXiv:1803.01271*, 2018. doi: https://doi.org/10.48550/arXiv.1803.01271.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016. doi: https://doi.org/10.1109/CVPR.2016.90.

[5] A. Supratak, H. Dong, C. Wu, and Y. Guo, "DeepSleepNet: A model for automatic sleep stage scoring based on raw single-channel EEG," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 25, no. 11, pp. 1998–2008, 2017. doi: https://doi.org/10.1109/TNSRE.2017.2721116.

[6] E. Eldele, Z. Chen, C. Liu, M. Wu, C.-K. Kwoh, X. Li, and C. Guan, "An attention-based deep learning approach for sleep stage classification with single-channel EEG," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29, pp. 809–818, 2021. doi: https://doi.org/10.1109/TNSRE.2021.3076234.

[7] H. Phan, K. Mikkelsen, O. Y. Chén, P. Koch, A. Mertins, and M. De Vos, "SleepTransformer: Automatic sleep staging with interpretability and uncertainty quantification," *IEEE Transactions on Biomedical Engineering*, vol. 69, no. 8, pp. 2456–2467, 2022. doi: https://doi.org/10.1109/TBME.2022.3147187.

[8] H. Phan, F. Andreotti, N. Cooray, O. Y. Chén, and M. De Vos, "SeqSleepNet: End-to-end hierarchical recurrent neural network for sequence-to-sequence automatic sleep staging," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 27, no. 3, pp. 400–410, 2019. doi: https://doi.org/10.1109/TNSRE.2019.2896659.

[9] A. Supratak and Y. Guo, "TinySleepNet: An efficient deep learning model for sleep stage scoring based on raw single-channel EEG," in *42nd Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 641–644, 2020. doi: https://doi.org/10.1109/EMBC44109.2020.9176741.

[10] H. Phan, O. Y. Chén, M. C. Tran, P. Koch, A. Mertins, and M. De Vos, "XSleepNet: Multi-view sequential model for automatic sleep staging," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 9, pp. 5903–5915, 2022. doi: https://doi.org/10.1109/TPAMI.2021.3070057.

[11] H. Phan, K. P. Lorenzen, E. Heremans, O. Y. Chén, M. C. Tran, P. Koch, A. Mertins, M. Baumert, K. B. Mikkelsen, and M. De Vos, "L-SeqSleepNet: Whole-cycle long sequence modeling for automatic sleep staging," *IEEE Journal of Biomedical and Health Informatics*, vol. 27, no. 10, pp. 4748–4757, 2023. doi: https://doi.org/10.1109/JBHI.2023.3303197.

[12] S. Lee, Y. Yu, S. Back, H. Seo, and K. Lee, "SleePyCo: Automatic sleep scoring with feature pyramid and contrastive learning," *Expert Systems with Applications*, vol. 240, p. 122551, 2024. doi: https://doi.org/10.1016/j.eswa.2023.122551.

[13] H. Phan and K. Mikkelsen, "Automatic sleep staging of EEG signals: recent development, challenges, and future directions," *Physiological Measurement*, vol. 43, no. 4, Art. no. 04TR01, 2022. doi: https://doi.org/10.1088/1361-6579/ac6049.

[14] S. Haghayegh, K. Hu, K. Stone, S. Redline, and E. Schernhammer, "Automated sleep stages classification using convolutional neural network from raw and time-frequency electroencephalogram signals: Systematic evaluation study," *Journal of Medical Internet Research*, vol. 25, Art. no. e40211, 2023. doi: https://doi.org/10.2196/40211.

[15] J. Van Der Donckt, J. Van Der Donckt, E. Deprost, N. Vandenbussche, M. Rademaker, G. Vandewiele, and S. Van Hoecke, "Do not sleep on traditional machine learning: Simple and interpretable techniques are competitive to deep learning for sleep scoring," *Biomedical Signal Processing and Control*, vol. 81, Art. no. 104429, 2023. doi: https://doi.org/10.1016/j.bspc.2022.104429.

[16] R. Vallat and M. P. Walker, "An open-source, high-performance tool for automated sleep staging," *eLife*, vol. 10, p. e70092, 2021. doi: https://doi.org/10.7554/eLife.70092.

[17] M. Perslev, S. Darkner, L. Kempfner, M. Nikolic, P. J. Jennum, and C. Igel, "U-Sleep: resilient high-frequency sleep staging," *npj Digital Medicine*, vol. 4, no. 1, p. 72, 2021. doi: https://doi.org/10.1038/s41746-021-00440-5.

[18] A. N. Olesen, P. J. Jennum, E. Mignot, and H. B. D. Sorensen, "Automatic sleep stage classification with deep residual networks in a mixed-cohort setting," *Sleep*, vol. 44, no. 1, Art. no. zsaa161, 2021. doi: https://doi.org/10.1093/sleep/zsaa161.

[19] A. Guillot and V. Thorey, "RobustSleepNet: Transfer learning for automated sleep staging at scale," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29, pp. 1441–1451, 2021. doi: https://doi.org/10.1109/TNSRE.2021.3098968.

[20] L. Fiorillo, G. Monachino, J. van der Meer, M. Pesce, J. D. Warncke, M. H. Schmidt, C. L. A. Bassetti, A. Tzovara, P. Favaro, and F. D. Faraci, "U-Sleep's resilience to AASM guidelines," *npj Digital Medicine*, vol. 6, no. 1, p. 33, 2023. doi: https://doi.org/10.1038/s41746-023-00784-0.

[21] H. Phan, O. Y. Chén, P. Koch, Z. Lu, I. McLoughlin, A. Mertins, and M. De Vos, "Towards more accurate automatic sleep staging via deep transfer learning," *IEEE Transactions on Biomedical Engineering*, vol. 68, no. 6, pp. 1787–1798, 2021. doi: https://doi.org/10.1109/TBME.2020.3020381.

[22] E. R. M. Heremans, H. Phan, P. Borzée, B. Buyse, D. Testelmans, and M. De Vos, "From unsupervised to semi-supervised adversarial domain adaptation in electroencephalography-based sleep staging," *Journal of Neural Engineering*, vol. 19, no. 3, p. 036044, 2022. doi: https://doi.org/10.1088/1741-2552/ac6ca8.

[23] J. Wang, S. Zhao, H. Jiang, S. Li, T. Li, and G. Pan, "Generalizable sleep staging via multi-level domain alignment," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, pp. 265–273, 2024. doi: https://doi.org/10.1609/aaai.v38i1.27779.

[24] Z. He, M. Tang, P. Wang, L. Du, X. Chen, G. Cheng, and Z. Fang, "Cross-scenario automatic sleep stage classification using transfer learning and single-channel EEG," *Biomedical Signal Processing and Control*, vol. 81, Art. no. 104501, 2023. doi: https://doi.org/10.1016/j.bspc.2022.104501.

[25] E. Eldele, M. Ragab, Z. Chen, M. Wu, C.-K. Kwoh, X. Li, and C. Guan, "ADAST: Attentive cross-domain EEG-based sleep staging framework with iterative self-training," *IEEE Transactions on Emerging Topics in Computational Intelligence*, vol. 7, no. 1, pp. 210–221, 2023. doi: https://doi.org/10.1109/TETCI.2022.3189695.

[26] B. Kemp, A. H. Zwinderman, B. Tuk, H. A. C. Kamphuisen, and J. J. L. Oberyé, "Analysis of a sleep-dependent neuronal feedback loop: the slow-wave microcontinuity of the EEG," *IEEE Transactions on Biomedical Engineering*, vol. 47, no. 9, pp. 1185–1194, 2000. doi: https://doi.org/10.1109/10.867928.

[27] B. Kemp, "Sleep-EDF Database Expanded, version 1.0.0." PhysioNet, 2013. Accessed 1 October 2026, doi: https://doi.org/10.13026/C2X676.

[28] T. Pollard, B. E. Moody, L.-w. H. Lehman, B. J. Gow, C. Fernandes, C. Xie, A. Johnson, R. G. Mark, and T. Heldt, "PhysioNet as a global platform for biomedical research," *Nature Health*, vol. 1, no. 8, pp. 792–795, 2026. doi: https://doi.org/10.1038/s44360-026-00096-z.

[29] S. F. Quan, B. V. Howard, C. Iber, J. P. Kiley, F. J. Nieto, G. T. O'Connor, D. M. Rapoport, S. Redline, J. Robbins, J. M. Samet, and P. W. Wahl, "The Sleep Heart Health Study: design, rationale, and methods," *Sleep*, vol. 20, no. 12, pp. 1077–1085, 1997. doi: https://doi.org/10.1093/sleep/20.12.1077.

[30] G.-Q. Zhang, L. Cui, R. Mueller, S. Tao, M. Kim, M. Rueschman, S. Mariani, D. Mobley, and S. Redline, "The National Sleep Research Resource: towards a sleep data commons," *Journal of the American Medical Informatics Association*, vol. 25, no. 10, pp. 1351–1358, 2018. doi: https://doi.org/10.1093/jamia/ocy064.

[31] M. Massimini, R. Huber, F. Ferrarelli, S. Hill, and G. Tononi, "The sleep slow oscillation as a traveling wave," *Journal of Neuroscience*, vol. 24, no. 31, pp. 6862–6870, 2004. doi: https://doi.org/10.1523/JNEUROSCI.1318-04.2004.

[32] A. Rechtschaffen and A. Kales, eds., *A Manual of Standardized Terminology, Techniques and Scoring System for Sleep Stages of Human Subjects*. Bethesda, MD: U.S. National Institute of Neurological Diseases and Blindness, Neurological Information Network, 1968. NLM catalogue record, Available at: https://www.ncbi.nlm.nih.gov/nlmcatalog/173471.

[33] R. B. Berry, R. Brooks, C. E. Gamaldo, S. M. Harding, R. M. Lloyd, S. F. Quan, M. M. Troester, and B. V. Vaughn, *The AASM Manual for the Scoring of Sleep and Associated Events: Rules, Terminology and Technical Specifications, Version 2.4*. Darien, IL: American Academy of Sleep Medicine, 2017. Publisher's version announcement, Available at: https://aasm.org/resources/pdf/scoring-manual-update-april-2017.pdf.

[34] S. Davidson, R. Sharman, S. D. Kyle, and L. Tarassenko, "Is it time to revisit the scoring of slow wave (N3) sleep?" *Sleep*, vol. 48, no. 10, Art. no. zsaf063, 2025. doi: https://doi.org/10.1093/sleep/zsaf063.

[35] M. Saerens, P. Latinne, and C. Decaestecker, "Adjusting the outputs of a classifier to new a priori probabilities: A simple procedure," *Neural Computation*, vol. 14, no. 1, pp. 21–41, 2002. doi: https://doi.org/10.1162/089976602753284446.

[36] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, vol. 70 of *Proceedings of Machine Learning Research*, pp. 1321–1330, PMLR, 2017. Available at: https://proceedings.mlr.press/v70/guo17a.html.

[37] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall, 1994. doi: https://doi.org/10.1201/9780429246593.

[38] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945. doi: https://doi.org/10.2307/3001968.

[39] S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979. Available at: https://www.jstor.org/stable/4615733.

[40] Y. Li, N. Wang, J. Shi, X. Hou, and J. Liu, "Adaptive batch normalization for practical domain adaptation," *Pattern Recognition*, vol. 80, pp. 109–117, 2018. doi: https://doi.org/10.1016/j.patcog.2018.03.005.

[41] S. Mousavi, F. Afghah, and U. R. Acharya, "SleepEEGNet: Automated sleep stage scoring with sequence to sequence deep learning approach," *PLOS ONE*, vol. 14, no. 5, p. e0216456, 2019. doi: https://doi.org/10.1371/journal.pone.0216456.